

Лабораторна робота №1

Визначення доцільності створення (сфера використання / застосування)

Мета роботи: для планованого проєкту обґрунтувати доцільність створення (сфера використання / застосування) за методами «Критичних запитань» та SMART.

Проект: «Система для автоматичної нормалізації суржику та діалектних форм української мови».

1. Метод «Критичних запитань»

Метод «Критичних запитань» передбачає послідовну відповідь на ключові запитання щодо проєкту, які дозволяють визначити його доцільність, межі та зацікавлені сторони.

1.1. Яку проблему вирішує проєкт?

Українська мова характеризується високою варіативністю: поряд із літературною нормою поширені регіональні діалекти (гуцульський, бойківський, закарпатський тощо) та російсько-український суржик. Внутрішня міграція, яка посилилась після початку повномасштабної війни, призводить до того, що люди з різних регіонів частіше опиняються в нових мовних середовищах, де діалектні слова, суржикові конструкції або локальні форми можуть бути незрозумілими у побуті, навчанні чи роботі.

Водночас наявні інструменти автоматичної корекції української мови орієнтовані переважно на стандартні орфографічні та граматичні помилки, тоді як семантична нормалізація діалектних або суржикових конструкцій підтримується рідко і часто реалізується правилами (rule-based) підходами, які не забезпечують достатнього покриття.

Таким чином, проєкт вирішує проблему **відсутності автоматизованого інструменту для нормалізації діалектних та суржикових форм до літературної української мови з використанням сучасних нейромережевих підходів.**

1.2. Які потреби задовольняє проєкт?

Проєкт задовольняє кілька ключових потреб. По-перше, це потреба у зрозумілому спілкуванні між носіями різних діалектів та літературної мови: абітурієнти, студенти, внутрішні мігранти потребують простого інструменту для нормалізації коротких текстів (повідомлень, оголошень, чатів). По-друге, розробники NLP-систем потребують модуля нормалізації, оскільки діалектні та суржикові вхідні тексти знижують якість роботи пайплайнів, побудованих на літературній українській. По-третє, нормалізація покращує якість україномовних текстових корпусів для подальшого навчання моделей. Нарешті, дослідники потребують відтвореного baseline-рішення для задачі діалектної нормалізації української мови.

1.3. Яка сфера застосування проєкту?

Сфера застосування проєкту охоплює нормалізацію коротких текстів (повідомлення, оголошення, чати, коментарі) з діалектних форм та суржику до літературної української. Підтримуються декілька українських діалектів: гуцульський (як базовий), а також бойківський та закарпатський, та російсько-український суржик. Система надає веб-інтерфейс для вибору типу вхідного тексту (конкретний діалект або суржик) та отримання нормалізованого результату. Вона може використовуватися як окремий інструмент або як компонент більших NLP-систем.

1.4. Хто є зацікавленими сторонами?

Основними зацікавленими сторонами є кінцеві користувачі - студенти, абітурієнти та мігранти з діалектних регіонів, яким потрібен інструмент для нормалізації повсякденних текстів. Також це дослідники NLP, які працюють із обробкою природної мови для української, зокрема з низькоресурсними мовними варіантами, та розробники програмного забезпечення, яким потрібен модуль нормалізації як компонент у ширшій системі (чат-боти, пошукові системи, системи аналізу тексту). Окрему зацікавленість має науковий керівник та кафедра - з академічної точки зору щодо результатів дослідження та апробації методів.

1.5. Що є за межами сфери застосування?

За межами проєкту залишаються: повний переклад з інших мов (російської, польської тощо), оскільки система працює лише з діалектами та суржиком; нормалізація довгих документів (наукових статей, книг), бо орієнтація на короткі тексти; розпізнавання усного мовлення (ASR), оскільки система працює виключно з текстовими вхідними даними. Також не передбачається повне комерційне розгортання з масштабуванням на великі навантаження, покриття всіх діалектів української мови та створення вичерпного лінгвістичного корпусу - використовуються лише наявні ресурси та синтетичне розширення.

1.6. Трикутник конкурентних обмежень

Трикутник обмежень (час, ресурси, якість) для проєкту:

Час. Проєкт обмежений термінами виконання бакалаврської кваліфікаційної роботи (один навчальний семестр). Етапи: побудова baseline-моделі для гуцульського діалекту, масштабування на мультидіалектний корпус, донавчання LLM, створення інтерфейсу.

Ресурси. Обчислювальні ресурси обмежені: baseline-модель (seq2seq) тренується на CPU; донавчання Lora LLM (12B параметрів) потребує GPU з ≥ 24 GB відеопам'яті та техніки QLoRA для зменшення вимог до пам'яті. Дані обмежені: для більшості діалектів відсутні великі ручні корпуси, тому використовується синтетичне розширення.

Якість. Цільова якість вимірюється метриками BLEU, chrF++, TER та COMET. Baseline на гуцульському діалекті досягає BLEU ≈ 51 . Контрольні набори формуються з ручних (не синтетичних) прикладів для забезпечення об'єктивності оцінки.

Пріоритетність: у контексті бакалаврської роботи пріоритет надається якості дослідження та відтворюваності результатів, потім - дотриманню термінів, і останнім - мінімізації ресурсних витрат (за рахунок QLoRA замість повного донавчання).

2. Метод SMART

Метод SMART дозволяє оцінити мету проєкту за п'ятьма критеріями: конкретність (Specific), вимірюваність (Measurable), наявність виконавця (Assignable),

реалістичність (Realistic), обмеженість у часі (Time-related).

2.1. S - Specific (Конкретність)

Мета проєкту сформульована конкретно: *розробити та експериментально оцінити систему автоматичної нормалізації українських діалектів (гуцульського, бойківського, закарпатського) та російсько-українського суржику до літературної української мови на основі нейронних моделей.*

Конкретність забезпечується чітким визначенням вхідних даних (тексти діалектами та суржиком), вихідних даних (нормалізований текст літературною українською), підходу (seq2seq baseline + інструкційне донавчання Lora LLM із LoRA/QLoRA) та результату (працююча система з веб-інтерфейсом).

2.2. M - Measurable (Вимірюваність)

Результати проєкту є вимірюваними за допомогою стандартних метрик оцінювання якості машинного перекладу та текстового редагування. Використовуються: BLEU - модифікована n-грамна точність (baseline для гуцульського діалекту досягає ≈ 51); chrF++ - символна F-міра, більш придатна для морфологічно багатих мов; TER - кількість редагувань, необхідних для приведення гіпотези до еталону; COMET - нейромережева метрика, що корелює з людськими оцінками якості. Контрольні набори (validation/test) сформовані з вручну анотованих пар, що забезпечує об'єктивність вимірювань.

2.3. A - Assignable (Наявність виконавця)

Проєкт виконується студентом групи ШІ-42 Ковалем Денисом Петровичем у рамках бакалаврської кваліфікаційної роботи за спеціальністю 122 «Комп'ютерні науки» під керівництвом наукового керівника. Виконавець має необхідні компетенції у галузі машинного навчання, обробки природної мови та програмування мовою Python. Виконавець відповідає за збір і підготовку даних, реалізацію моделей, проведення експериментів, створення інтерфейсу та оформлення результатів. Науковий керівник забезпечує методичне спрямування, контроль якості дослідження та рецензування.

2.4. R - Realistic (Реалістичність)

Реалістичність проєкту обґрунтовується кількома факторами. Для гуцульського діалекту доступні вручну анотований паралельний корпус, синтетичний корпус

та діалектний словник; для інших діалектів і суржику використовується синтетичне розширення на базі літературних речень із датасету Spivavtor. Підхід базується на усталених техніках: seq2seq Transformer для baseline, інструкційне донавчання LLM, LoRA/QLoRA для параметро-ефективного навчання. Lora LLM є відкритою україномовною моделлю з адаптованим токенизатором, що суттєво спрощує донавчання. Baseline тренується на CPU, а QLoRA дозволяє донавчати 12B-модель на GPU з 24 GB відеопам'яті. Існують також релевантні дослідження (Vuuko Mistral для діалектного перекладу, UA-GEC для граматичної корекції), які підтверджують працездатність обраного підходу.

2.5. T - Time-related (Обмеженість у часі)

Проект обмежений термінами виконання бакалаврської кваліфікаційної роботи. Етапи виконання включають: аналіз предметної області та огляд літератури; збір та підготовку даних для гуцульського діалекту з побудовою та оцінкою baseline-моделі; формування мультидіалектного корпусу із синтетичним розширенням для бойківського, закарпатського діалектів та суржику; інструкційне донавчання Lora LLM з LoRA/QLoRA та експериментальне оцінювання; розробку веб-інтерфейсу (Gradio) та інтеграцію системи; оформлення результатів та підготовку до захисту.

Висновки

У ході виконання лабораторної роботи було обґрунтовано доцільність створення системи для автоматичної нормалізації суржику та діалектних форм української мови за двома методами.

Метод «Критичних запитань» дозволив визначити: проблему (відсутність інструментів нормалізації діалектів і суржику), потреби користувачів (зрозуміле спілкування, компонент NLP-пайплайнів), сферу застосування (короткі тексти, декілька діалектів, веб-інтерфейс), зацікавлені сторони (кінцеві користувачі, дослідники, розробники) та межі проєкту. Аналіз трикутника обмежень показав, що пріоритет надається якості дослідження з дотриманням академічних термінів.

Метод SMART підтвердив, що мета проєкту є конкретною (чітко визначені вхід/вихід, підхід, результат), вимірюваною (BLEU, chrF++, TER, COMET), забезпеченою виконавцем (студент під керівництвом наукового керівника), ре-

алістичною (наявність даних, перевірених методів, базових моделей) та обмеженою у часі (семестр виконання бакалаврської роботи).

Обидва методи свідчать про доцільність реалізації проєкту.