

Лабораторна робота №1

Визначення доцільності створення (сфера використання / застосування)

Мета роботи: для планованого проєкту обґрунтувати доцільність створення (сфера використання / застосування) за методами «Критичних запитань» та SMART.

Проект: «Система для автоматичної нормалізації суржику та діалектних форм української мови».

Виконав: студент групи ІІІ-42 Коваль Денис Петрович.

1. Метод «Критичних запитань»

Метод «Критичних запитань» передбачає послідовну відповідь на ключові запитання щодо проєкту, які дозволяють визначити його доцільність, межі та зацікавлені сторони.

1.1. Яку проблему вирішує проєкт?

Українська мова характеризується високою варіативністю: поряд із літературною нормою поширені регіональні діалекти (гуцульський, бойківський, закарпатський тощо) та російсько-український суржик. Внутрішня міграція, яка посилилась після початку повномасштабної війни, призводить до того, що люди з різних регіонів частіше опиняються в нових мовних середовищах, де діалектні слова, суржикові конструкції або локальні форми можуть бути незрозумілими у побуті, навчанні чи роботі.

Водночас наявні інструменти автоматичної корекції української мови орієнтовані переважно на стандартні орфографічні та граматичні помилки, тоді як семантична нормалізація діалектних або суржикових конструкцій підтримується рідко і часто реалізується правилорієнтованими (rule-based) підходами, які не забезпечують достатнього покриття.

Таким чином, проєкт вирішує проблему **відсутності автоматизованого інструменту для нормалізації діалектних та суржикових форм до літературної української мови** з використанням сучасних нейромережевих підходів.

1.2. Які потреби задовольняє проєкт?

Проєкт задовольняє такі потреби:

- потреба у зрозумілому спілкуванні між носіями різних діалектів та літературної мови — абітурієнти, студенти, внутрішні мігранти потребують простого інструменту для нормалізації коротких текстів (повідомлень, оголошень, чатів);
- потреба розробників NLP-систем у модулі нормалізації — діалектні та суржикові вхідні тексти знижують якість роботи пайплайнів, побудованих на літературній українській;
- потреба у підвищенні якості україномовних текстових даних — нормалізація покращує якість корпусів для подальшого навчання моделей;
- потреба дослідників у відтворюваному baseline-рішенні для задачі діалектної нормалізації української мови.

1.3. Яка сфера застосування проєкту?

Сфера застосування проєкту охоплює:

- нормалізацію коротких текстів (повідомлення, оголошення, чати, коментарі) з діалектних форм та суржику до літературної української;
- підтримку декількох українських діалектів: гуцульського (як базового), а також бойківського та закарпатського;
- підтримку нормалізації російсько-українського суржику;
- надання веб-інтерфейсу для вибору типу вхідного тексту (конкретний діалект або суржик) та отримання нормалізованого результату;
- використання як окремого інструменту або як компоненту більших NLP-систем.

1.4. Хто є зацікавленими сторонами?

- **Кінцеві користувачі** — студенти, абітурієнти та мігранти з діалектних регіонів, яким потрібен інструмент для нормалізації повсякденних текстів;
- **Дослідники NLP** — науковці, які працюють із обробкою природної мови для української, зокрема з низькоресурсними мовними варіантами;

- **Розробники програмного забезпечення** — інженери, яким потрібен модуль нормалізації як компонент у ширшій системі (чат-боти, пошукові системи, системи аналізу тексту);
- **Науковий керівник та кафедра** — академічна зацікавленість у результатах дослідження та апробації методів.

1.5. Що є за межами сфери застосування?

За межами проєкту залишаються:

- повний переклад з інших мов (російської, польської тощо) — система працює лише з діалектами та суржиком;
- нормалізація довгих документів (наукових статей, книг) — орієнтація на короткі тексти;
- розпізнавання усного мовлення (ASR) — система працює виключно з текстовими вхідними даними;
- повне комерційне розгортання з масштабуванням на великі навантаження;
- покриття всіх діалектів української мови — лише обрані діалекти та суржик;
- створення вичерпного лінгвістичного корпусу — використовуються наявні ресурси та синтетичне розширення.

1.6. Трикутник конкурентних обмежень

Трикутник обмежень (час, ресурси, якість) для проєкту:

- **Час** — проєкт обмежений термінами виконання бакалаврської кваліфікаційної роботи (один навчальний семестр). Етапи: побудова baseline-моделі для гуцульського діалекту, масштабування на мультидіалектний корпус, донавчання LLM, створення інтерфейсу.
- **Ресурси** — обчислювальні ресурси обмежені: baseline-модель (seq2seq) тренується на CPU; донавчання Lora LLM (12B параметрів) потребує GPU з ≥ 24 GB відеопам'яті та техніки QLoRA для зменшення вимог до пам'яті. Дані обмежені: для більшості діалектів відсутні великі ручні корпуси, тому використовується синтетичне розширення.
- **Якість** — цільова якість вимірюється метриками BLEU, chrF++, TER та

COMET. Baseline на гуцульському діалекті досягає BLEU ≈ 51 . Контрольні набори формуються з ручних (не синтетичних) прикладів для забезпечення об'єктивності оцінки.

Пріоритетність: у контексті бакалаврської роботи пріоритет надається якості дослідження та відтворюваності результатів, потім — дотриманню термінів, і останнім — мінімізації ресурсних витрат (за рахунок QLoRA замість повного донавчання).

2. Метод SMART

Метод SMART дозволяє оцінити мету проєкту за п'ятьма критеріями: конкретність (Specific), вимірюваність (Measurable), наявність виконавця (Assignable), реалістичність (Realistic), обмеженість у часі (Time-related).

2.1. S — Specific (Конкретність)

Мета проєкту сформульована конкретно: *розробити та експериментально оцінити систему автоматичної нормалізації українських діалектів (гуцульського, бойківського, закарпатського) та російсько-українського суржику до літературної української мови на основі нейронних моделей.*

Конкретність забезпечується чітким визначенням:

- вхідних даних — тексти діалектами та суржиком;
- вихідних даних — нормалізований текст літературною українською;
- підходу — seq2seq baseline + інструкційне донавчання Lora LLM із LoRA/QLoRA;
- результату — працююча система з веб-інтерфейсом.

2.2. M — Measurable (Вимірюваність)

Результати проєкту є вимірюваними за допомогою стандартних метрик оцінювання якості машинного перекладу та текстового редагування:

- **BLEU** — модифікована n-грамна точність; baseline для гуцульського діалекту досягає ≈ 51 ;
- **chrF++** — символна F-міра, більш придатна для морфологічно багатих мов;

- **TER** — кількість редагувань, необхідних для приведення гіпотези до еталону;
- **COMET** — нейромережева метрика, що корелює з людськими оцінками якості.

Контрольні набори (validation/test) сформовані з вручну анотованих пар, що забезпечує об'єктивність вимірювань.

2.3. A — Assignable (Наявність виконавця)

Проект виконується студентом групи ІІІ-42 Ковалем Денисом Петровичем у рамках бакалаврської кваліфікаційної роботи за спеціальністю 122 «Комп'ютерні науки» під керівництвом наукового керівника. Виконавець має необхідні компетенції у галузі машинного навчання, обробки природної мови та програмування мовою Python.

Розподіл відповідальності:

- **Виконавець** — збір і підготовка даних, реалізація моделей, проведення експериментів, створення інтерфейсу, оформлення результатів;
- **Науковий керівник** — методичне спрямування, контроль якості дослідження, рецензування.

2.4. R — Realistic (Реалістичність)

Реалістичність проекту обґрунтовується такими факторами:

- **Наявність даних** — для гуцульського діалекту доступні вручну анотований паралельний корпус, синтетичний корпус та діалектний словник; для інших діалектів і суржику використовується синтетичне розширення на базі літературних речень із датасету Spivavtor;
- **Перевірені методи** — підхід базується на усталених техніках: seq2seq Transformer для baseline, інструкційне донавчання LLM, LoRA/QLoRA для параметро-ефективного навчання;
- **Наявність базової моделі** — Lora LLM є відкритою україномовною моделлю з адаптованим токенизатором, що суттєво спрощує донавчання для української;
- **Достатні обчислювальні ресурси** — baseline тренується на CPU, а QLoRA дозволяє донавчати 12B-модель на GPU з 24 GB відеопам'яті;

- **Методологічна підтримка** — існують релевантні дослідження (Vuuko Mistral для діалектного перекладу, UA-GEC для граматичної корекції), які підтверджують працездатність обраного підходу.

2.5. T — Time-related (Обмеженість у часі)

Проект обмежений термінами виконання бакалаврської кваліфікаційної роботи.
Етапи виконання:

1. Аналіз предметної області та огляд літератури.
2. Збір та підготовка даних для гуцульського діалекту; побудова та оцінка baseline-моделі.
3. Формування мультидіалектного корпусу; синтетичне розширення для бойківського, закарпатського діалектів та суржику.
4. Інструкційне донавчання Lora LLM з LoRA/QLoRA; експериментальне оцінювання.
5. Розробка веб-інтерфейсу (Gradio) та інтеграція системи.
6. Оформлення результатів та підготовка до захисту.

Висновки

У ході виконання лабораторної роботи було обґрунтовано доцільність створення системи для автоматичної нормалізації суржику та діалектних форм української мови за двома методами.

Метод «Критичних запитань» дозволив визначити: проблему (відсутність інструментів нормалізації діалектів і суржику), потреби користувачів (зрозуміле спілкування, компонент NLP-пайплайнів), сферу застосування (короткі тексти, декілька діалектів, веб-інтерфейс), зацікавлені сторони (кінцеві користувачі, дослідники, розробники) та межі проєкту. Аналіз трикутника обмежень показав, що пріоритет надається якості дослідження з дотриманням академічних термінів.

Метод SMART підтвердив, що мета проєкту є конкретною (чітко визначені вхід/вихід, підхід, результат), вимірюваною (BLEU, chrF++, TER, COMET), забезпеченою виконавцем (студент під керівництвом наукового керівника), реалістичною (наявність даних, перевірених методів, базових моделей) та обмеженою у часі (семестр виконання бакалаврської роботи).

Обидва методи свідчать про доцільність реалізації проєкту.