

Лабораторна робота №2

ОСОБЛИВОСТІ ПОБУДОВИ ПРОЦЕСУ УПРАВЛІННЯ ПРОЄКТАМИ (ФОРМУВАННЯ КОНЦЕПТУАЛЬНИХ ПОНЯТЬ ПРОЄКТУ). ОБҐРУНТУВАННЯ СФЕРИ ЗАСТОСУВАННЯ ТА ОБ'ЄМУ РОБІТ ПРОЄКТУ.

Мета роботи: ознайомитись з основними процесами управління проектами, особливостями побудови процесу управління проектом та роллю менеджера в цих процесах. Навчитись окреслювати основні та додаткові етапи роботи.

Проект: «Система для автоматичної нормалізації суржику та діалектних форм української мови».

1. Формування концептуальних понять проекту

1.1. Визначення проекту

Проект «Система для автоматичної нормалізації суржику та діалектних форм української мови» - це тимчасове зусилля, спрямоване на створення унікального програмного продукту: нейромережевої системи, що перетворює тексти, написані українськими діалектами (гуцульським, бойківським, закарпатським) та російсько-українським суржилом, на літературну українську мову. Проект реалізується в рамках бакалаврської кваліфікаційної роботи за спеціальністю 122 «Комп'ютерні науки» у Національному університеті «Львівська політехніка».

1.2. Команда проекту та ролі

Керівник проекту (виконавець): студент групи ШІ-42 Коваль Денис Петрович. Відповідає за планування, виконання всіх технічних етапів, контроль якості та оформлення результатів. Оскільки проект є індивідуальною бакалаврською роботою, виконавець суміщає ролі менеджера проекту, розробника та аналітика даних.

Науковий керівник (спонсор): Сивоконь Олексій Олегович, асистент кафедри систем штучного інтелекту, ІКНІ. Забезпечує методичне спрямування, контроль відповідності дослідження академічним стандартам, рецензування результатів. У термінології PMBOK виконує роль спонсора, який «розчищає шлях» у питаннях доступу до ресурсів та консультацій.

1.3. Ромб конкурентних обмежень

Ромб конкурентних обмежень проєкту визначається чотирма вершинами:

Кошти. Проєкт є академічним і не має виділеного фінансового бюджету. Основні витрати - обчислювальні ресурси: baseline тренується на CPU (безкоштовно), донавчання LLM потребує GPU з ≥ 24 GB відеопам'яті (QLoRA знижує вимоги). Використовуються відкриті дані та моделі.

Час. Обмежений одним навчальним семестром з фіксованою датою захисту бакалаврської роботи.

Якість. Вимірюється метриками BLEU, chrF++, TER, COMET на контрольних наборах з вручну анотованих пар. Baseline для гуцульського діалекту досягає BLEU ≈ 51 .

Результат. Працююча система нормалізації з веб-інтерфейсом, що підтримує 3 діалекти та суржик, з документованими результатами експериментів.

2. Етапи проєкту та контрольні списки (checklists)

Відповідно до процесу управління проєктами (PMBOK), проєкт проходить п'ять етапів: ініціювання, планування, виконання, контроль та закриття. Для кожного етапу сформовано опорний технічний контрольний список (checklist) із очікуваними результатами.

2.1. Ініціювання

На етапі ініціювання визначається доцільність проєкту та формується його загальне бачення. Основні результати:

Checklist-елемент	Результат
Визначення проблеми (відсутність інструменту нормалізації діалектів/суржику)	Опис проблеми та актуальності
Визначення сфери застосування (7 базових питань)	Документ сфери застосування
Формулювання мети за SMART	Конкретна, вимірювана мета
Визначення зацікавлених сторін	Перелік стейкхолдерів
Узгодження теми з науковим керівником	Затверджена тема БКР

Checklist-елемент	Результат
Попередній огляд доступних ресурсів (дані, моделі)	Перелік ключових джерел

2.2. Планування

На етапі планування деталізуються роботи, визначаються ресурси, ризики та розклад. Основні результати:

Checklist-елемент	Результат
Огляд літератури (NMT, GEC, діалектна нормалізація, суржик)	Аналітичний огляд джерел
Аналіз наборів даних (ручний корпус, синтетика, словник, Spivavtor)	Опис джерел даних та їх ролей
Вибір архітектур (seq2seq baseline, Lora LLM з QLoRA)	Обґрунтований вибір моделей
Визначення метрик якості (BLEU, chrF++, TER, COMET)	Набір метрик з цільовими значеннями
Визначення технологічного стеку (Python, PyTorch, HF Transformers, PEFT, Gradio)	Перелік інструментів
Формування розкладу етапів	План-графік робіт
Ідентифікація ризиків	Реєстр ризиків
Визначення вимог до обчислювальних ресурсів	Специфікація (CPU для baseline, GPU ≥ 24 GB для LLM)

2.3. Виконання

Етап виконання - це безпосередня реалізація запланованих робіт. Основні результати:

Checklist-елемент	Результат
Збір та підготовка даних для гуцульського діалекту	Паралельний корпус (ручний + синтетичний), словник

Checklist-елемент	Результат
Побудова та навчання baseline seq2seq моделі	Навчена модель, BLEU ≈ 51
Аналіз помилок baseline	Звіт про типові помилки
Формування мультидіалектного корпусу (бойківський, закарпатський, суржик)	Розширений корпус із синтетикою на базі Spivavtor
Синтетична генерація пар (словниково-керована, правилена, LLM з RAG)	Набори синтетичних пар із контролем якості
Інструкційне донавчання Lora LLM з QLoRA	Донавчена модель
Оцінювання якості на контрольних наборах	Таблиця метрик по діалектах/суржику
Розробка веб-інтерфейсу (Gradio)	Працюючий демо-інтерфейс

2.4. Контроль

Етап контролю відбувається паралельно з виконанням і забезпечує відстеження прогресу та реагування на відхилення. Основні результати:

Checklist-елемент	Результат
Відстеження відповідності розкладу	Звіт про дотримання термінів
Моніторинг метрик якості на validation-наборах під час навчання	Графіки loss, BLEU по епохах
Перевірка якості синтетичних даних (фільтрація, аудит)	Лог відфільтрованих прикладів
Контроль розбиття train/validation/test (ручні дані лише у val/test)	Підтвердження коректності розбиття
Відстеження змін у вимогах або підході	Журнал змін
Регулярні консультації з науковим керівником	Протоколи обговорень

2.5. Закриття

На етапі закриття фіксуються результати, оформлюється документація та передається досвід. Основні результати:

Checklist-елемент	Результат
Оформлення тексту бакалаврської кваліфікаційної роботи	Готовий документ БКР
Фіксація фінальних метрик якості по всіх діалектах та суржику	Таблиця результатів
Публікація коду та даних у репозиторії	Відкритий репозиторій
Підготовка презентації до захисту	Слайди
Фіксація отриманого досвіду (lessons learned)	Розділ висновків у БКР
Захист бакалаврської роботи	Оцінка

3. Ризики та перешкоди

Нижче подано ключові ризики, які можуть виникнути при розробленні проєкту, та заходи з їх мінімізації.

№	Ризик	Ймовірність / Вплив	Заходи мінімізації
1	Недостатній обсяг ручних даних для діалектів (крім гуцульського)	Висока / Високий	Синтетичне розширення на базі Spivavtor, словникових правил та LLM-генерації з RAG-підказками
2	Низька якість синтетичних даних (нереалістичні конструкції)	Середня / Високий	Фільтрація дублікатів, контроль довжин, словникова валідація, вибіркового ручний аудит
3	Недостатні обчислювальні ресурси для донавчання LLM (12B параметрів)	Середня / Високий	Використання QLoRA для зменшення вимог до відеопам'яті; fallback на менші моделі

№	Ризик	Ймовірність / Вплив	Заходи мінімізації
4	Затримка на етапі підготовки даних, що скорочує час на донавчання	Середня / Середній	Паралельне формування корпусів для різних діалектів; чіткий план-графік з контрольними точками
5	Catastrophic forgetting при мультидіалектному навчанні	Середня / Середній	Стратифіковане балансування семплінгу за діалектами, окремі контрольні набори для кожного різновиду
6	Метрики не відображають реальну якість нормалізації	Низька / Середній	Використання нейронних метрик (COMET) поряд із класичними; вибіркова ручна оцінка
7	Зміна або недоступність зовнішніх ресурсів (моделі, датасети на HuggingFace)	Низька / Високий	Локальне кешування всіх ключових даних та моделей на початку проєкту
8	Невідповідність результатів академічним вимогам до оформлення	Низька / Середній	Регулярні консультації з науковим керівником, дотримання шаблону оформлення

Висновки

У ході виконання лабораторної роботи було сформовано концептуальні поняття проєкту: визначено його як тимчасове зусилля зі створення унікального програмного продукту, описано команду (виконавець та науковий керівник) та ромб конкурентних обмежень (кошти, час, якість, результат).

Для кожного з п'яти етапів управління проєктом (ініціювання, планування, виконання, контроль, закриття) розроблено технічні контрольні списки (checklists) з конкретними елементами та очікуваними результатами. Контрольні списки прив'язані до реальних артефактів проєкту: від корпусів даних і навчених моделей до метрик якості та демо-інтерфейсу.

Ідентифіковано 8 ключових ризиків проєкту з оцінкою ймовірності та впливу, для кожного запропоновано конкретні заходи мінімізації. Найбільш критичними є: дефіцит ручних даних для діалектів (мінімізується синтетичним розширенням), обмеженість обчислювальних ресурсів (мінімізується QLoRA) та ризик затримки на підготовці даних (мінімізується паралельною роботою та контрольними точками).