

Лабораторна робота №4

АНАЛІЗ РИЗИКІВ ПРОЄКТУ ТА ПОБУДОВА МАТРИЦІ УПРАВЛІННЯ РИЗИКАМИ ПРОЄКТУ

Мета роботи: ознайомитись з основними підходами до побудови контрольного листа (списку) ризиків проєкту. Навчитись чітко, лаконічно та однозначно формулювати ризики у відповідності до поставлених в проєкті задач.

Проект: «Система для автоматичної нормалізації суржику та діалектних форм української мови».

1. Ідентифікація ризиків проєкту

Управління ризиками є одним із найбільш критичних факторів успіху проєкту. Після визначення цілей, стейкхолдерів та складності реалізації проєкту з'являється можливість більш детально усвідомити та систематизувати ризики. Ефективне управління ризиками дозволяє вчасно завершити проєкт у межах бюджету та відповідно до очікувань зацікавлених сторін.

Для ідентифікації ризиків проєкту «Система автоматичної нормалізації суржику та діалектних форм» застосовано такі методи: огляд аналогічних NLP-проєктів та академічних публікацій (UA-GEC, Vuyko Mistral, Helsinki NLP); консультація з науковим керівником щодо технічних обмежень; аналіз блок-схеми пайплайну генерації даних та тренування моделі; проведення «негативного мозкового штурму» – що може піти не так на кожному з п'яти етапів проєкту; SWOT-аналіз специфіки роботи з малоресурсними діалектами.

За результатами ідентифікації визначено 12 ризиків, що охоплюють технічні, ресурсні, організаційні та якісні виміри проєкту.

2. Реєстр ризиків

Кожен ризик оцінено за двома параметрами: ймовірність виникнення (P) та вплив на проєкт (I), кожен за шкалою 1–3 (1 – низький, 2 – середній, 3 – високий). Значущість ризику (Score) розраховується як добуток $P \times I$.

Таблиця 1

Реєстр ризиків проєкту

ID	Ризик	P	I	Score	K	Стратегія
R01	Нестача паралельних діалектних даних для тренування	3	3	9	Ч	Пом'якшення
R02	Низька якість синтетичних даних, згенерованих LLM (галюцинації, помилки перекладу)	3	2	6	Ч	Пом'якшення
R03	Перенавчання (overfitting) моделі через малий обсяг реальних діалектних текстів	2	3	6	Ч	Пом'якшення
R04	Недостатні обчислювальні ресурси для fine-tuning Lora LLM (12B параметрів)	2	2	4	Ж	Пом'якшення
R05	Зміна умов доступу до API (OpenRouter, rate limits, відключення безкоштовних моделей)	2	2	4	Ж	Уникнення
R06	Помилки та неточності у вихідних словниках та корпусах (транскарпатський, гуцульський)	2	2	4	Ж	Пом'якшення
R07	Невідповідність автоматичної метрики BLEU реальній якості нормалізації	3	1	3	Ж	Прийняття

ID	Ризик	P	I	Score	K	Стратегія
R08	Відсутність носіїв діалекту для людської оцінки якості (human evaluation)	3	1	3	Ж	Пом'якшення
R09	Зміна вимог наукового керівника або кафедри на пізніх стадіях проєкту	1	3	3	Ж	Пом'якшення
R10	Технічні збої GPU-сервера під час тривалого тренування моделі	2	1	2	З	Прийняття
R11	Складність інтеграції seq2seq-модуля та Lora LLM у єдиний пайплайн нормалізації	1	2	2	З	Пом'якшення
R12	Обмеження авторських прав на джерельні тексти українського корпусу	1	2	2	З	Уникнення

3. Матриця управління ризиками

Матриця управління ризиками розміщує кожен ризик у двовимірному просторі за осями ймовірності (P) та впливу (I). Колір квадранта визначає пріоритет реагування: ЧЕРВОНИЙ – вирішити або пом'якшити негайно; ЖОВТИЙ – розробити план дій; ЗЕЛЕНИЙ – моніторинг.

Ймовірність (P)	Вплив на проєкт (I)		
	1 – низький	2 – середній	3 – високий
3 – високий	Score 3 R07, R08	Score 6 R02	Score 9 R01
2 – середній	Score 2 R10	Score 4 R04, R05, R06	Score 6 R03
1 – низький	Score 1 –	Score 2 R11, R12	Score 3 R09

Стратегії реагування на ризики:

Таблиця 2

Стратегії ризику

Стратегія	Пояснення
Уникнення	Усунути загрозу, усунувши причину її виникнення
Передача	Перекласти відповідальність за ризик на третю сторону
Пом'якшення	Зменшити ймовірність та (або) вплив ризику – розробити план пом'якшення та резервний план
Прийняття	Прийняти ризик та створити резерви на випадок непередбачених ситуацій

4. Плани реагування на ризики

4.1. Плани дій для ЧЕРВОНИХ ризиків

R01 – Нестача паралельних діалектних даних (Score 9). Головна загроза проєкту – відсутність готових великих паралельних корпусів для гуцульського, бойківського, закарпатського діалектів та суржику. План пом'якшення: (а) автоматична генерація синтетичних пар за допомогою LLM на основі правил та діалектних словників (вже реалізовано для гуцульського діалекту, BLEU $\approx$ 51); (б) парсинг відкритих джерел – транскарпатського словника (7 469 словникових статей), гуцульських текстів із Вікіпедії; (в) аугментація даних – back-translation та варіативні трансформації. Термін: до 28 лютого 2026 р. Відповідальний: Коваль Д.П.

Резервний план: якщо обсяг реальних даних залишиться менше 5 000 пар – обмежити область дослідження до двох діалектів (гуцульський + суржик) та використати виключно синтетичні дані з підвищеним контролем якості.

R02 – Низька якість синтетично згенерованих даних (Score 6). LLM може генерувати переклади з галюцинаціями, граматичними помилками або без відображення цільових діалектних ознак. План пом'якшення: (а) автоматична фільтрація за BLEU-схожістю, довжиною відповіді та наявністю діалектних маркерів; (б) ручна перевірка вибірки (2–5%) на кожній ітерації; (в) порівняльне тестування кількох моделей (Mistral, Gemma) та промптів. Термін: постійно в процесі генерації. Відповідальний: Коваль Д.П.

Резервний план: перехід на більш детальний промпт із few-shot прикладами та зменшення batch_size до 5 речень.

R03 – Перенавчання моделі (Score 6). Малий обсяг реальних діалектних даних може призвести до overfitting під час fine-tuning. План пом'якшення: (а) застосування QLoRA-квантизації (4-bit) для регуляризації; (б) моніторинг validation loss на кожній епосі; (в) рання зупинка (early stopping) при відсутності покращення; (г) аугментація даних та cross-validation. Термін: реалізувати перед запуском першого тренування. Відповідальний: Коваль Д.П.

Резервний план: зменшення кількості тренувальних епох та збільшення dropout. Перехід до повного seq2seq-підходу без fine-tuning LLM при критичній нестачі даних.

4.2. Плани дій для ЖОВТИХ ризиків

R04 – Недостатні обчислювальні ресурси (Score 4). Fine-tuning Lora LLM (12В параметрів) вимагає значних GPU-ресурсів. Поточне рішення: QLoRA 4-bit квантизація знижує потребу до 16 ГБ VRAM. Резервний план: використання Vast.ai або Google Colab Pro для оренди GPU A100.

R05 – Зміна умов доступу до API (Score 4). OpenRouter може змінити умови безкоштовного доступу. Стратегія уникнення: паралельне тестування локальних моделей (Mistral-7B через llama.cpp); зберігання всіх згенерованих даних локально після першої генерації.

R06 – Помилки у словниках та корпусах (Score 4). Вихідні словники можуть містити помилки транслітерації або застарілі форми. План: ручна верифікація 10% записів; автоматична перевірка через SpaCy та UkrainianNLP.

R07 – Невідповідність BLEU реальній якості (Score 3). BLEU не завжди відображає якість нормалізації для діалектів. Прийняття: додатково використовувати метрику chrF та людську оцінку на вибірці 50 речень.

R08 – Відсутність носіїв діалекту для оцінки (Score 3). Людська оцінка потребує носіїв мови. Пом'якшення: залучити студентів-філологів із Прикарпаття або учасників ТМШ через соціальні мережі.

R09 – Зміна вимог на пізніх стадіях (Score 3). Науковий керівник або кафедра можуть змінити вимоги після початку тренування. Пом'якшення: щотижневі зустрічі з науковим керівником; фіксація вимог у протоколі зустрічей на кожному етапі.

4.3. Зелені ризики – моніторинг

Ризики R10 (технічні збої сервера), R11 (складність інтеграції модулів) та R12 (авторські права) мають низький пріоритет. Для них достатньо регулярного моніторингу на щотижневих зустрічах. Конкретні дії: регулярне збереження checkpoints моделі кожні 500 кроків тренування (R10); модульна архітектура пайплайну з чіткими інтерфейсами (R11); використання виключно відкритих корпусів із ліцензіями CC-BY (R12).

5. Зведений план управління ризиками

Таблиця 3

Зведена таблиця управління ризиками

ID	Ризик (скор.)	P	I	Score	Дія	Відповід.	Термін
R01	Нестача діалектних даних	3	3	9	LLM-генерація + парсинг словників	Коваль Д.П.	Лютий 2026
R02	Низька якість LLM-даних	3	2	6	Авто-фільтрація + вибіркова перевірка	Коваль Д.П.	Постійно
R03	Перенавчання моделі	2	3	6	QLoRA + early stopping	Коваль Д.П.	До тренування

ID	Ризик (скор.)	P	I	Score	Дія	Відповід.	Термін
R04	Брак GPU-ресурсів	2	2	4	Vast.ai / Colab Pro	Коваль Д.П.	За потреби
R05	Зміна умов API	2	2	4	Локальні моделі (llama.cpp)	Коваль Д.П.	Березень 2026
R06	Помилки у словниках	2	2	4	Верифікація 10% записів	Коваль Д.П.	Лютий 2026
R07	BLEU $\neq$ реальна якість	3	1	3	chrF + human eval (50 речень)	Коваль Д.П.	Квітень 2026
R08	Відсутність носіїв мови	3	1	3	Залучення філологів / ТМШ	Коваль Д.П.	Квітень 2026
R09	Зміна вимог замовника	1	3	3	Щотижневі зустрічі	Коваль Д.П., Сивоконь О.О.	Постійно
R10	Збої GPU-сервера	2	1	2	Checkpoints кожні 500 кроків	Коваль Д.П.	Постійно
R11	Складність інтеграції	1	2	2	Модульна архітектура	Коваль Д.П.	Травень 2026
R12	Авторські права	1	2	2	Тільки CC-BY корпуси	Коваль Д.П.	Лютий 2026