

Лабораторна робота 1

ВИЗНАЧЕННЯ СФЕРИ ЗАСТОСУВАННЯ (КОМЕРЦІЙНОСТІ) ПРОЄКТУ НА ОСНОВІ 7 БАЗОВИХ ПИТАНЬ. ВИЗНАЧЕННЯ ЦІЛЕЙ ПРОЄКТУ ЗА СИСТЕМОЮ SMART.

Мета роботи: ознайомитись з принципами визначення характеристик проєкту на основі 7 базових питань. Навчитись визначити цілей проєкту за системою SMART.

Проект: «Вдосконалення токенизатора української мови для великих мовних моделей».

Виконав: студент групи ІІІ-42 Мирош Андрій.

1. Визначення сфери застосування на основі 7 базових питань

Метод «Критичних запитань» передбачає послідовну відповідь на 7 ключових запитань щодо проєкту, які дозволяють визначити його доцільність, межі та зацікавлені сторони.

1.1. Хто?

Зацікавленими сторонами проєкту є:

- **Розробники LLM та NLP-систем** — інженери, які адаптують великі мовні моделі до української мови і потребують ефективного токенизатора, що зменшує довжину токен-послідовностей та покращує використання контекстного вікна;
- **Дослідники NLP** — науковці, які порівнюють токенизатори різних LLM на українських корпусах і потребують стандартизованого інструментарію та метрик оцінювання;
- **Розробники україномовних сервісів** — команди, які створюють чат-ботів, пошукові системи та інші текстові продукти для української мови і хочуть обрати оптимальний токенизатор;
- **Науковий керівник та кафедра** — академічна зацікавленість у результатах дослідження ефективності токенизації;
- **Виконавець** — студент групи ІІІ-42 Мирош Андрій, який реалізує проєкт у рамках бакалаврської кваліфікаційної роботи.

1.2. Що?

Проект передбачає вдосконалення (розробку та налаштування) спеціалізованого ВРЕ-токенізатора української мови та побудову відтворюваного конвеєру порівняння його якості з токенізаторами сучасних LLM. Конкретно створюються:

- локальний ВРЕ-токенізатор зі словником 32 000 одиниць, навчений на українських текстах;
- уніфікована процедура попередньої обробки тексту (Unicode NFC-нормалізація, уніфікація апострофів);
- набір метрик оцінювання: token fertility (середнє та p95), частка UNK/OOV, частка byte fallback, round-trip fidelity;
- MVP-система з модульною архітектурою (завантаження корпусу, токенізація, обчислення метрик);
- CLI-інтерфейс для інтерактивного тестування токенізатора та запуску обчислень на корпусі.

1.3. Де?

Проект реалізується на кафедрі систем штучного інтелекту Національного університету «Львівська політехніка». Розробка ведеться локально з використанням Python-екосистеми (Hugging Face Transformers, SentencePiece). Обчислення не потребують GPU — всі експерименти працюють лише з токенізацією («текст → токени» та «токени → текст»), без запуску повноцінних мовних моделей. Код та результати розміщені у відкритому репозиторії на GitHub.

1.4. Коли?

Проект обмежений термінами виконання бакалаврської кваліфікаційної роботи (один навчальний семестр). Етапи виконання:

1. Аналіз літературних джерел та формування вимог до токенізації українських текстів.
2. Аналіз та вибір корпусу для порівняння (Kobza Corpus).
3. Реалізація/адаптація локального ВРЕ-токенізатора та уніфікованої попередньої обробки.
4. Визначення та реалізація метрик (token fertility, UNK/OOV, byte fallback, round-trip fidelity).

5. Експериментальне порівняння з токенизаторами 5 поширених LLM на 100 000 зразках корпусу.
6. Аналіз результатів, оформлення та підготовка до захисту.

1.5. Чому?

Токенізація є одним із ключових вузлів у пайплайні сучасних LLM: вона визначає спосіб перетворення тексту на дискретні індекси словника та безпосередньо впливає на довжину послідовностей у токенах, використання контекстного вікна, швидкодію та обчислювальні витрати. Для української мови, яка характеризується розвиненою словозміною, продуктивним словотворенням та специфічними орфографічними особливостями (наприклад, варіативність апострофа), стандартні «англоцентричні» токенизатори часто дають неефективне представлення — довші послідовності токенів на слово.

Незважаючи на зростання кількості українських NLP-ресурсів, стандартизованого інструментарію для порівняння токенизаторів саме на українських текстах не існує. Тому створення спеціалізованого токенизатора та відтворюваного конвеєру оцінювання є актуальним завданням.

1.6. Як?

Підхід складається з таких кроків:

1. **Підготовка даних** — завантаження корпусу Kobza з Hugging Face у потоковому режимі (streaming), застосування єдиної нормалізації (Unicode NFC + уніфікація апострофів), сегментація слів за пробілами.
2. **Токенізація** — уніфікований інтерфейс для локального BPE-токенизатора та токенизаторів LLM (через Hugging Face AutoTokenizer); контроль відсутності службових токенів (BOS/EOS) для чистоти метрик.
3. **Обчислення метрик** — автоматичний прогін корпусу кожним токенизатором, обчислення token fertility (середнє, p95), частки UNK, частки byte fallback та round-trip fidelity.
4. **Порівняння** — 6 токенизаторів (Local BPE, aya-expanse-8b, gemma-3-12b-it, Llama-3.1-8B, Phi-4-mini, Qwen2.5-7B) на 100 000 зразках; збереження результатів у структурованому форматі для візуалізації.

1.7. Скільки?

Проект має один основний результат — MVP-система порівняння токенизаторів. Кількісні характеристики:

- 1 локальний ВРЕ-токенизатор зі словником 32 000 одиниць;
- порівняння з 5 токенизаторами поширених LLM;
- оцінювання на 100 000 зразках корпусу Kobza;
- 4 метрики оцінювання (token fertility mean/p95, UNK rate, byte fallback rate, round-trip fidelity);
- 1 CLI-інструмент для тестування;
- відкритий репозиторій із кодом та результатами.

1.8. Як ми знаємо, що досягли цілей?

Успішність проекту визначається за такими критеріями:

- локальний ВРЕ-токенизатор навчений і демонструє нижчу середню token fertility порівняно з токенизаторами LLM (ціль: <2 токени/слово);
- метрики обчислені для всіх порівнюваних токенизаторів на одному корпусі з однаковою попередньою обробкою;
- результати відтворювані: запуск конвеєру на тому ж корпусі дає ідентичні значення метрик;
- CLI-інтерфейс функціонує та дозволяє токенизувати довільний текст і запускати обчислення метрик;
- виявлені сильні та слабкі сторони кожного токенизатора задокументовані.

1.9. Що виходить за рамки?

За межами проекту залишаються:

- навчання або запуск повноцінних мовних моделей — оцінюється лише токенизація («текст → токени» та «токени → текст»);
- оцінювання впливу токенизатора на downstream-задачі (генерація, класифікація тощо);
- розробка нових алгоритмів субсловної сегментації — використовується стандартний ВРЕ;
- оптимізація продуктивності/швидкості токенизатора;

- покриття інших мов, окрім української;
- комерційне розгортання або інтеграція у виробничі системи.

1.10. Трикутник конкурентних обмежень

Після визначення сфери застосування можна заповнити трикутник конкурентних обмежень (час, ресурси, якість):

- **Час** — проєкт обмежений термінами виконання бакалаврської кваліфікаційної роботи (один навчальний семестр). Ключовий ризик — затримка на етапі інтеграції різних токенізаторів через відмінності в API та форматах.
- **Ресурси** — обчислювальні витрати мінімальні: усі експерименти працюють на CPU, оскільки виконується лише токенізація, а не інференс моделей. Основний ресурс — час розробника. Дані доступні безкоштовно (Kobza Corpus на Hugging Face).
- **Якість** — цільова якість визначається відтворюваністю конвеєру та інформативністю метрик. Ключовий показник — token fertility: ціль для локального токенізатора < 2 токени/слово. Також важлива коректність round-trip fidelity (ціль: 100%).

Пріоритетність: у контексті бакалаврської роботи пріоритет надається якості порівняння та відтворюваності результатів, потім — дотриманню термінів, і останнім — обсягу покриття (кількість токенізаторів та корпусів).

2. Визначення цілей проєкту за системою SMART

Метод SMART дозволяє оцінити мету проєкту за п'ятьма критеріями: конкретність (Specific), вимірюваність (Measurable), наявність виконавця (Assignable), реалістичність (Realistic), обмеженість у часі (Time-related).

2.1. S — Specific (Конкретність)

Мета проєкту сформульована конкретно: *вдосконалити спеціалізований BPE-токенізатор української мови та побудувати відтворюваний конвеєр порівняння його якості з токенізаторами сучасних LLM за набором стандартизованих метрик на українському корпусі.*

Конкретність забезпечується чітким визначенням:

- що саме створюється — локальний BPE-токенізатор (32К словник) та MVP-система оцінювання;
- з чим порівнюється — з токенізаторами 5 поширених LLM (aya-expanse-8b, gemma-3-12b-it, Llama-3.1-8B, Phi-4-mini, Qwen2.5-7B);
- на яких даних — корпус Kobza (100 000 зразків);
- за якими критеріями — token fertility, UNK/byte fallback, round-trip fidelity;
- у якому форматі — CLI-інструмент + структуровані результати для візуалізації.

2.2. M — Measurable (Вимірюваність)

Результати проєкту є вимірюваними за допомогою чітко визначених метрик:

- **Token fertility (середнє)** — середня кількість токенів на слово; ціль для локального токенізатора < 2 (досягнутий результат: 1.803);
- **Token fertility (p95)** — 95-й перцентиль фертильності; ціль ≤ 5 (досягнутий результат: 4);
- **Частка UNK** — відсоток невідомих токенів; ціль 0%;
- **Частка byte fallback** — відсоток «сирих» байтових токенів;
- **Round-trip fidelity** — частка рядків, що точно відтворюються після encode $\rightarrow$ decode; ціль 100%.

Усі метрики обчислюються автоматично на одному корпусі з однаковою попередньою обробкою, що забезпечує об'єктивність порівняння.

2.3. A — Assignable (Наявність виконавця)

Проєкт виконується студентом групи ШІ-42 Мирошем Андрієм у рамках бакалаврської кваліфікаційної роботи за спеціальністю 122 «Комп'ютерні науки» під керівництвом Яковини В. С. Виконавець має необхідні компетенції у галузі обробки природної мови та програмування мовою Python.

Розподіл відповідальності:

- **Виконавець** — реалізація токенізатора, побудова конвеєру оцінювання, проведення експериментів, аналіз результатів, створення CLI, оформлення звіту;
- **Науковий керівник** — методичне спрямування, контроль якості дослідження, рецензування.

2.4. R — Realistic (Реалістичність)

Реалістичність проєкту обґрунтовується такими факторами:

- **Наявність даних** — корпус Kobza є загальнодоступним на Hugging Face, охоплює різні домени та стилі мовлення, репрезентує реальну українську мову;
- **Перевірені методи** — BPE є стандартним підходом до субсловної токенизації, підтримується SentencePiece; Hugging Face AutoTokenizer забезпечує єдиний інтерфейс до токенизаторів LLM;
- **Мінімальні обчислювальні вимоги** — усі експерименти працюють на CPU, не потребують GPU, що робить проєкт доступним для виконання на будь-якому комп'ютері;
- **Наявність попередніх досліджень** — існують роботи з оцінювання ефективності токенизації для української на токенизаторах foundational-моделей, що підтверджують актуальність підходу та надають орієнтири для порівняння;
- **Відкритість** — весь код розміщено у відкритому репозиторії, що забезпечує відтворюваність.

2.5. T — Time-related (Обмеженість у часі)

Проєкт обмежений термінами виконання бакалаврської кваліфікаційної роботи. Основні етапи:

1. Аналіз літератури та формування вимог до токенизації.
2. Вибір корпусу та реалізація попередньої обробки.
3. Реалізація локального BPE-токенизатора та уніфікованого інтерфейсу.
4. Реалізація метрик та конвеєру порівняння.
5. Проведення експериментів на корпусі Kobza (100 000 зразків).
6. Аналіз результатів, оформлення та підготовка до захисту.

Кожен етап має чітку послідовність та залежності. Наявність кінцевої дати (захист бакалаврської роботи) забезпечує фокусування зусиль.

Висновки

У ході виконання лабораторної роботи було обґрунтовано доцільність створення спеціалізованого BPE-токенізатора української мови та конвеєру порівняння за двома методами.

Метод 7 базових питань дозволив визначити: зацікавлені сторони (розробники LLM, дослідники NLP, розробники україномовних сервісів), суть проєкту (BPE-токенізатор + MVP-система порівняння з CLI), місце реалізації (НУ «Львівська політехніка», CPU-based експерименти), часові рамки (навчальний семестр), обґрунтування актуальності (неефективність «англоцентричних» токенізаторів для української), спосіб реалізації (BPE + уніфікований інтерфейс + набір метрик), кількісні показники та критерії успіху. Також визначено межі проєкту (лише токенізація, без downstream-задач) та заповнено трикутник обмежень із пріоритетом на якість та відтворюваність.

Метод SMART підтвердив, що мета проєкту є конкретною (BPE-токенізатор 32K + порівняння з 5 LLM-токенізаторами на Kobza), вимірюваною (token fertility < 2 , p95 ≤ 5 , UNK 0%, round-trip 100%), забезпеченою виконавцем (студент під керівництвом наукового керівника), реалістичною (наявність даних, CPU-based, перевірені методи) та обмеженою у часі (семестр виконання бакалаврської роботи).

Обидва методи свідчать про доцільність реалізації проєкту.