

Зміст

ВСТУП		3
РОЗДІЛ 1.	АКТУАЛЬНІСТЬ ТЕМИ ТА МЕТА РОБОТИ	4
	1.1 Актуальність теми	4
	1.2 Конкретизована мета та завдання проєкту	4
РОЗДІЛ 2.	АНАЛІТИЧНИЙ ОГЛЯД НАЯВНИХ ДАНИХ	6
	2.1 Стан задачі обробки діалектної мови в NLP	6
	2.2 Аналіз існуючих підходів та інструментів	6
РОЗДІЛ 3.	ОБГРУНТУВАННЯ СФЕРИ ЗАСТОСУВАННЯ ТА КОНЦЕПТУАЛЬНИХ ПОНЯТЬ	8
	3.1 Метод «Критичних запитань»	8
	3.2 Метод SMART	9
	3.3 Концептуальні поняття проєкту	9
	3.4 Складність проєкту з точки зору управління	10
РОЗДІЛ 4.	ЗАЦІКАВЛЕНІ СТОРОНИ ТА ФОРМУВАННЯ ВИ- МОГ	11
	4.1 Повний перелік зацікавлених сторін	11
	4.2 Сітка оцінки зацікавлених сторін (Power/Interest) . .	12
	4.3 Вимоги стейкхолдерів та фази виконання	12
	4.4 Матриця розподілу відповідальності (RAM)	13
РОЗДІЛ 5.	ПЛАНУВАННЯ ТА КОНТРОЛЬНІ СПИСКИ ПРОЄ- КТУ	15
	5.1 Контрольні списки фаз PMBOK	15
	5.2 Структура розбиття робіт (WBS)	17
	5.3 Мережева діаграма та розрахунок критичного шляху	18
	5.4 Матриця комунікацій проєкту	19
	5.5 Діаграма Ганта	20
РОЗДІЛ 6.	АНАЛІЗ РИЗИКІВ ПРОЄКТУ	21
	6.1 Ідентифікація ризиків	21

6.2	Реєстр ризиків	21
6.3	Матриця управління ризиками	22
6.4	Плани реагування на ризики	23
6.5	Зведений план управління ризиками	24
РОЗДІЛ 7.	ПОСЛІДОВНІСТЬ ВИКОНАННЯ РОБІТ	26
7.1	Технічний стек та інструменти	26
7.2	Підготовка даних	26
7.3	Навчання моделей	27
7.4	Оцінювання та веб-інтерфейс	27
7.5	Закриття проєкту та представлення замовникам . .	28
РОЗДІЛ 8.	ПРЕДСТАВЛЕННЯ ТА СИСТЕМАТИЗАЦІЯ РЕ- ЗУЛЬТАТІВ	29
8.1	Результати навчання моделей	29
8.2	Загальні висновки за результатами моделювання . .	30
ВИСНОВКИ		31
СПИСОК ВИКОРИСТАНИХ ДЖЕРЕЛ		33

ВСТУП

Розвиток цифрових технологій і широке впровадження методів штучного інтелекту в задачі обробки природної мови відкривають нові можливості для вирішення прикладних мовних проблем. Одним із таких завдань є нормалізація регіональних діалектів та мовних суржиків до літературної норми – задача, яка набуває особливої актуальності в контексті масового впровадження NLP-систем в освіту, медіа та державне управління.

Українська мова характеризується значною діалектною варіативністю: гучульський, бойківський та закарпатський діалекти мають суттєві лексичні й граматичні відмінності від літературної норми. Поряд із ними широко поширений суржик – суміш елементів української та російської мов, що ускладнює роботу сучасних NLP-пайплайнів, налаштованих на стандартну літературну мову. Внутрішнє переміщення людей, яке різко посилилось після початку повномасштабного вторгнення, актуалізує потребу в практичних інструментах міжрегіонального мовного порозуміння.

Метою цієї розрахунково-графічної роботи є формування повної технічної та комунікаційної документації для ІТ-проєкту «Система для автоматичної нормалізації суржику та діалектних форм української мови» – від обґрунтування доцільності й ідентифікації стейкхолдерів до аналізу ризиків, побудови мережевого графіку та закриття проєкту. Документування охоплює всі п'ять фаз управління проєктом відповідно до методології PMBOK [1] і відображає реальний стан виконаних і запланованих робіт.

РОЗДІЛ 1. АКТУАЛЬНІСТЬ ТЕМИ ТА МЕТА РОБОТИ

1.1. Актуальність теми

Проблема автоматичної нормалізації діалектних та змішаних форм мови є актуальною з кількох взаємопов'язаних причин.

Соціальний аспект. Внутрішнє переміщення мільйонів людей внаслідок воєнних подій призвело до зіткнення регіональних діалектів у нових для носіїв мовних середовищах. Відсутність зрозумілих цифрових інструментів перекладу і нормалізації ускладнює процеси адаптації, навчання та комунікації.

Технологічний аспект. Сучасні NLP-системи – автоматичне виправлення тексту, пошукові системи, чат-боти, системи розпізнавання мовлення – розроблені переважно для літературної норми. Введення діалектних або суржикових текстів суттєво знижує їх якість. Відсутність спеціалізованих модулів нормалізації є вузьким місцем у всьому NLP-пайплайні.

Науковий аспект. Для більшості діалектів української мови відсутні великі анотовані паралельні корпуси. Дослідження у цій галузі відрізняється низькоресурсністю, що ускладнює застосування стандартних методів навчання. Синтетична генерація даних за допомогою великих мовних моделей є перспективним підходом для компенсації дефіциту реальних пар.

Конкурентний аспект. На початок проєкту відсутні відкриті україномовні системи нормалізації, що охоплювали б декілька діалектів і суржик з використанням сучасних нейронних архітектур. Найближчі аналоги – Vuyko Mistral та UA-GEC [6] – вирішують суміжні, але не ідентичні задачі.

1.2. Конкретизована мета та завдання проєкту

Мета проєкту: розробити та експериментально оцінити систему автоматичної нормалізації українських діалектів (гуцульського, бойківського, закарпатського) та російсько-українського суржику до літературної форми на основі нейронних моделей.

Для досягнення мети необхідно виконати такі завдання:

1. Провести аналіз предметної галузі та огляд існуючих підходів до нормалізації діалектних текстів.
2. Сформувати паралельний корпус для гуцульського діалекту (ручні та синтетичні дані).

3. Навчити baseline seq2seq модель (umt5-base) та отримати кількісні метрики якості.
4. Розширити корпус до мультидіалектного через синтетичну генерацію на основі LLM.
5. Виконати інструкційне донавчання моделі MatayLM з використанням QLoRA [5].
6. Провести порівняльне оцінювання за метриками BLEU, chrF++, TER та COMET.
7. Розробити веб-інтерфейс на базі NiceGUI [7] для демонстрації системи.
8. Сформувавати повну технічну та управлінську документацію проєкту.

РОЗДІЛ 2. АНАЛІТИЧНИЙ ОГЛЯД НАЯВНИХ ДАНИХ

2.1. Стан задачі обробки діалектної мови в NLP

Задача нормалізації діалектних і змішаних текстів є відносно новим напрямком у ширшій галузі обробки природної мови (NLP). Серед суміжних завдань виділяють: граматичну корекцію тексту (GEC), машинний переклад (MT) та лексичну нормалізацію. Різниця полягає в тому, що нормалізація діалекту вимагає системного знання морфологічних, лексичних і фонетичних відмінностей конкретного діалекту від стандартної форми мови.

Для грецької, арабської, шотландської та норвезької мов існують спеціалізовані нормалізаційні системи, проте для регіональних діалектів та суржику української мови такі системи практично відсутні. Даний проєкт є одним із перших систематичних досліджень у цій підгалузі.

Задача нормалізації формально визначається як: дано текст x у діалектній формі (або суржику), знайти відповідну нормалізовану форму y літературною мовою. На відміну від граматичної корекції, нормалізація діалекту потребує передусім лексичних заміन, а не граматичних виправлень. Це зближує задачу з монолінгвальним машинним перекладом.

2.2. Аналіз існуючих підходів та інструментів

Існуючі підходи до нормалізації та суміжних задач поділяються на три класи.

Правилові підходи (rule-based). Використовують словники відповістей і граматичні правила для замінів. Перевагами є прозорість і можливість ручного редагування. Недоліком є обмежене покриття і нечутливість до контексту [1]. Для гуцульського діалекту розроблено транскарпатський словник (7 469 словникових статей), що є ключовим ресурсом даного проєкту.

Статистичні та нейронні seq2seq моделі. Застосовуються до задачі як до задачі MT: модель навчається на паралельних корпусах і відображає діалектний текст у літературний. Архітектура Transformer [2] стала стандартом для подібних задач. Модель mT5 [3] (multilingual Text-to-Text Transfer Transformer) підтримує українську мову і є основою для baseline системи проєкту (umt5-base). Helsinki-NLP пропонує попередньо навчені моделі перекладу для ряду мов.

Інструкційне донавчання LLM. Найсучасніший підхід – використання великих мовних моделей із інструкційним донавчанням (instruction fine-tuning).

Для мінімізації обчислювальних витрат застосовується LoRA [4] і QLoRA [5]. Для україномовних задач перспективною є модель MamayLM (Gemma-3-4B-IT, INSAIT-Institute), яка пройшла передтренування та інструкційне налаштування на україномовних корпусах. Робота з нею реалізується через бібліотеки HuggingFace Transformers [7] та PEFT.

Суміжні результати для української мови:

- UA-GEC [6] – корпус та система граматичної корекції для літературної української мови. Забезпечив корисний зразок пайплайну GEC, хоча не вирішує задачу нормалізації діалектів.
- Vuyko Mistral – дослідницький проєкт перекладу між регіональними варіантами української мови за допомогою донавченої Mistral-7B. Близький за задачею, але охоплює інші діалекти без підтримки суржику.
- Spivavtor – відкритий датасет для монологічних задач (перефразування, спрощення). Використаний як джерело літературних речень для синтетичної генерації діалектних пар.

За результатами аналізу у проєкті обрано гібридний підхід: umt5-base як baseline і MamayLM з QLoRA як основна система. Синтетичні дані генеруються через LLM (OpenRouter API) за правилами і словниками для кожного діалекту.

РОЗДІЛ 3. ОБГРУНТУВАННЯ СФЕРИ ЗАСТОСУВАННЯ ТА КОНЦЕПТУАЛЬНИХ ПОНЯТЬ

3.1. Метод «Критичних запитань»

Метод «Критичних запитань» передбачає послідовну відповідь на ключові запитання щодо проєкту, що дозволяє визначити його доцільність, межі та зацікавлені сторони.

Питання 1. Яку проблему вирішує проєкт?

Проєкт вирішує проблему **відсутності автоматизованого інструменту для нормалізації діалектних та суржикових форм до літературної української мови** з використанням сучасних нейромережових підходів. Наявні засоби корекції орієнтовані на стандартні орфографічні й граматичні помилки, а не на семантичну нормалізацію діалектних конструкцій.

Питання 2. Яку потребу задовольняє проєкт?

Проєкт задовольняє потреби трьох груп: (1) кінцеві користувачі (студенти, мігранти, носії діалектів) потребують доступного інструменту нормалізації коротких текстів; (2) NLP-розробники потребують модуля нормалізації як компоненту пайплайнів; (3) дослідники потребують відтворюваного baseline-рішення для задачі діалектної нормалізації.

Питання 3. Яка сфера застосування?

Сфера застосування: нормалізація коротких текстів (повідомлення, коментарі, чати) з гуцульського, бойківського, закарпатського діалектів та суржику до літературної форми. Система надає веб-інтерфейс для вибору типу вхідного тексту та може використовуватись як окремий інструмент або компонент NLP-системи.

Питання 4. Хто є зацікавленими сторонами?

Носії діалектів і суржикомовці, NLP-дослідники, розробники програмного забезпечення, науковий керівник, кафедра. Повний перелік наведено у Розділі 4.

Питання 5. Що поза межами проєкту?

Поза межами проєкту: переклад з інших мов (російської, польської тощо); нормалізація довгих документів; розпізнавання мовлення (ASR); комерційне мас-

штабування; покриття всіх діалектів України.

Питання 6. Трикутник конкурентних обмежень

Час: один навчальний семестр (лютий-червень 2026). **Ресурси:** обмежений GPU (QLoRA знижує вимоги до пам'яті); дані синтетично розширені через Mistral Small 24B. **Якість:** BLEU, chrF++, TER; umt5-base BLEU = 74.68 на гуцульському, 89.42 на суржику. Пріоритет: якість > терміни > ресурси.

3.2. Метод SMART

Метод SMART перевіряє мету проєкту за п'ятьма критеріями.

S – Specific (Конкретність). Мета сформульована конкретно: розробити систему нормалізації для 4 різновидів (гуцульський, бойківський, закарпатський діалекти та суржик) з веб-інтерфейсом, на основі seq2seq baseline і MamayLM з QLoRA. Визначені вхід, вихід, підхід та очікуваний результат.

M – Measurable (Вимірюваність). Результати вимірюються: BLEU (umt5-base досяг 74.68 на гуцульському та 89.42 на суржику); chrF++ (символьна F-міра, краща для морфологічно багатих мов); TER (кількість редагувань). Контрольні набори сформовані з вручну верифікованих пар (50/діалект).

A – Assignable (Виконавець). Студент групи III-42 Коваль Денис Петрович суміщає ролі менеджера, розробника та аналітика. Науковий керівник Сивоконь Олексій Олегович забезпечує методичний нагляд і рецензування. Виконавець має компетенції у Python, PyTorch та NLP.

R – Realistic (Реалістичність). Обидві моделі навчено і оцінено: umt5-base досяг BLEU = 74.68 на гуцульському; MamayLM QLoRA – BLEU = 51.81 на бойківському. Синтетична генерація через Mistral Small 24B забезпечила 125 000 навчальних пар. QLoRA дозволяє донавчати 4B-модель на GPU з ≥ 12 GB VRAM. Результати підтвердили реалістичність підходу.

T – Time-related (Часові рамки). Семестровий проєкт із чітким розкладом: аналіз літератури (3 тиж.) → підготовка даних (6 тиж.) → донавчання (4 тиж.) → оцінювання (2 тиж.) → документування (4 тиж.). Загальний критичний шлях – 19 тижнів.

3.3. Концептуальні поняття проєкту

Визначення проєкту. Проєкт – тимчасове зусилля зі створення унікального програмного продукту: нейромережевої системи, що перетворює тексти, на-

писані українськими діалектами та суржилом, на літературну форму. Реалізується у межах бакалаврської кваліфікаційної роботи за спеціальністю 122 «Комп'ютерні науки» у НУ «Львівська Політехніка».

Команда проєкту:

- **Виконавець / Менеджер:** Коваль Денис Петрович, ШІ-42. Планування, реалізація, контроль якості, документування.
- **Науковий керівник (Спонсор):** Сивоконь Олексій Олегович, асистент кафедри СШІ. Методичне спрямування, рецензування, погодження вимог.

Ромб конкурентних обмежень:

- **Кошти:** нульовий фінансовий бюджет; використовуються відкриті моделі та API.
- **Час:** один семестр, фіксована дата захисту БКР.
- **Якість:** BLEU, chrF++, TER, COMET на ручних контрольних наборах.
- **Результат:** працююча система з веб-інтерфейсом, відкритий репозиторій, таблиця метрик.

3.4. Складність проєкту з точки зору управління

Відповідно до матриці типів проєктів, проєкт класифіковано як **еволюційний із середнім рівнем виклику**.

Еволюційні вимоги. Задача нормалізації діалектів є недостатньо формалізованою. Точну якість для кожного діалекту неможливо передбачити на початку проєкту. Вимоги уточнюються по ходу роботи: після baseline-етапу стало зрозуміло, що мультидіалектний корпус потребує ретельнішого стратифікованого балансування.

Рівень виклику – середній. Більшість ключових компетенцій (Python, PyTorch, HuggingFace, NLP) наявні у виконавця. Водночас донавчання великих мовних моделей і специфіка низькоресурсних діалектних корпусів виходять за межі стандартного університетського курсу.

Критичність – менеджментний рівень: проєкт є ключовим для досягнення академічної мети (захист БКР), але не є критичним для виживання організації. Водночас результати мають практичну цінність для NLP-спільноти та потенційних інтеграторів.

РОЗДІЛ 4. ЗАЦІКАВЛЕНІ СТОРОНИ ТА ФОРМУВАННЯ ВИМОГ

4.1. Повний перелік зацікавлених сторін

Стейкхолдером є будь-хто, хто впливає на проєкт або на кого впливає проєкт – позитивно чи негативно. Нижче наведено повний перелік зацікавлених сторін із оцінкою потужності (Power) та зацікавленості (Interest).

Таблиця 1 — Зацікавлені сторони проєкту

ID	Стейкхолдер	Роль у проєкті	Power	Inter.	За / Проти
S1	Коваль Денис Петрович	Виконавець, менеджер	Висока	Висока	За
S2	Сивоконь Олексій Олегович	Науковий керівник	Висока	Висока	За
S3	Кафедра СШ, НУ «ЛП»	Інституційний замовник	Висока	Середня	За
S4	Команда MamaуLM (INSAIT)	Розробники базової моделі	Низька	Середня	За
S5	Носії діалектів (гуцульського, бойківського, закарпатського)	Кінцеві користувачі	Низька	Висока	За
S6	Внутрішні мігранти (суржикомовці)	Кінцеві користувачі	Низька	Висока	За
S7	Ukrainian NLP-спільнота	Академічна аудиторія	Середня	Висока	За
S8	EdTech-платформи (Prometheus, MOH)	Потенційні інтегратори	Середня	Середня	Нейтрально
S9	Мовні активісти / ТМШ	Промоутери норми	Низька	Висока	За

ID	Стейкхолдер	Роль у проєкті	Power	Inter.	За / Проти
S10	NLP-розробники у tech-компаніях	Споживачі API/компонента	Середня	Середня	За

4.2. Сітка оцінки зацікавлених сторін (Power/Interest)

Сітка розміщує стейкхолдерів у чотирьох квадрантах за осями «Потужність» і «Зацікавленість» та визначає стратегію взаємодії.

	Interest: Низька	Interest: Висока
Power: Висока	Квадрант II - Задовольняти S3 Кафедра СШ / НУ «ЛП»	Квадрант I - Ключові гравці S1 Коваль Денис S2 Сивоконь О.О.
Power: Низька	Квадрант III - Моніторинг S4 Команда MatayLM	Квадрант IV - Інформувати S5 Носії діалектів S6 Мігранти/переселенці S7 Ukrainian NLP-спільнота S9 Мовні активісти / ТМШ

Стейкхолдери S8 та S10 (середній рівень за обома осями) залучаються ситуативно.

4.3. Вимоги стейкхолдерів та фази виконання

Таблиця 2 — Вимоги стейкхолдерів та фази виконання

ID	Стейкхолдер	Вимоги та очікування	Фаза
S1	Виконавець	Чітка постановка задачі, доступ до ресурсів, відтворені результати	Всі

ID	Стейкхолдер	Вимоги та очікування	Фаза
S2	Науковий керівник	Дотримання академічних стандартів, новизна, відповідність темі БКР	Ініц., Контр., Закр.
S3	Кафедра СШ	Вчасна здача роботи, відповідність структурі БКР	Ініц., Закр.
S4	Команда MatayLM	Коректне цитування моделі, зворотній зв'язок	Вик., Закр.
S5	Носії діалектів	Коректна нормалізація без спотворення змісту	Вик., Контр.
S6	Мігранти / переселенці	Простий веб-інтерфейс, підтримка суржику	Вик., Контр.
S7	Ukrainian NLP-спільнота	Відкритий код і датасети, відтворювані метрики	Вик., Закр.
S8	EdTech-платформи	Можливість інтеграції через API, документація	Закр.
S9	Мовні активісти	Нормалізація до літературної норми (не «русифікація»)	Вик., Контр.
S10	NLP-розробники	Документований API, відкрита модель на HuggingFace	Закр.

4.4. Матриця розподілу відповідальності (RAM)

Умовні позначення: **A** – відповідальний (Accountable); **P** – учасник (Participant); **O** – необхідна думка (Opinion required); порожньо – не залучений.

Таблиця 3 — Матриця RAM

Завдання / Етап	S1	S2	S3	S4	S5	S6	S7	S8	S9	S10
Визначення теми та мети	A	P	O							
Огляд літератури та джерел	A	O					P			
Аналіз наборів даних	A	O		O			O			

Завдання / Етап	S1	S2	S3	S4	S5	S6	S7	S8	S9	S10
Підготовка корпусу (гуцульський)	A	O			O					
Синтетичне розширення даних	A	O		O	O	O			O	
Навчання baseline seq2seq	A	O								
Форм. мульти-діалект. корпусу	A	O			O	O	O		O	
Дон. MamayLM (QLoRA)	A	O		P						
Оцінювання якості	A	P			O	O	O		O	
Розробка NiceGUI-інтерфейсу	A	O				P		O		O
Написання тексту БКР	A	P	O							
Публікація коду та моделі	A	O		O			P	O		O
Захист БКР	A	P	A							

РОЗДІЛ 5. ПЛАНУВАННЯ ТА КОНТРОЛЬНІ СПИСКИ ПРОЄКТУ

5.1. Контрольні списки фаз PMBOK

Проект проходить п'ять фаз управління відповідно до методології PMBOK [1]. Для кожної фази сформовано технічний контрольний список (checklist) із очікуваними результатами.

Таблиця 4 — Фаза 1: Ініціювання

Checklist-елемент	Результат
Визначення проблеми	Опис проблеми та актуальності
Визначення сфери застосування	Документ сфери застосування
Формулювання мети за SMART	Конкретна, вимірювана мета
Визначення зацікавлених сторін	Перелік 10 стейкхолдерів
Узгодження теми з науковим керівником	Затверджена тема БКР
Попередній огляд доступних ресурсів	Перелік ключових джерел

Таблиця 5 — Фаза 2: Планування

Checklist-елемент	Результат
Огляд літератури (NMT, GEC, діалектна нормалізація)	Аналітичний огляд джерел
Аналіз наборів даних	Опис джерел даних та їх ролей
Вибір архітектур (umt5-base, MatayLM з QLoRA)	Обґрунтований вибір моделей
Визначення метрик якості	Набір метрик з цільовими значеннями
Визначення технологічного стеку	Перелік інструментів
Формування розкладу етапів	План-графік робіт
Ідентифікація ризиків	Реєстр ризиків

Checklist-елемент	Результат
Визначення вимог до ресурсів	Специфікація (CPU для baseline, GPU ≥ 12 GB для LLM)

Таблиця 6 — Фаза 3: Виконання

Checklist-елемент	Результат
Збір та підготовка даних (гуцульський)	Паралельний корпус + словник
Навчання baseline seq2seq (umt5-base)	Модель, BLEU ≈ 51
Аналіз помилок baseline	Звіт про типові помилки
Синтетична генерація пар для 3 діалектів + суржику	Мультидіалектний корпус
Донавчання MatayLM з QLoRA	Донавчена модель
Оцінювання якості на контрольних наборах	Таблиця метрик
Розробка NiceGUI-інтерфейсу	Демо-інтерфейс

Таблиця 7 — Фаза 4: Контроль

Checklist-елемент	Результат
Відстеження відповідності розкладу	Звіт про дотримання термінів
Моніторинг метрик під час навчання (TensorBoard)	Графіки loss і BLEU по епохах
Перевірка якості синтетичних даних	Лог відфільтрованих прикладів
Контроль розбиття train/val/test	Підтвердження коректності
Відстеження змін у вимогах	Журнал змін
Регулярні консультації з науковим керівником	Протоколи обговорень

Таблиця 8 — Фаза 5: Закриття

Checklist-елемент	Результат
Оформлення тексту БКР	Готовий документ
Фіксація фінальних метрик по всіх варіантах	Таблиця результатів
Публікація коду та моделі на GitHub / HuggingFace	Відкритий репозиторій
Підготовка презентації до захисту	Слайди
Фіксація досвіду (lessons learned)	Розділ висновків у БКР
Захист бакалаврської роботи	Оцінка

5.2. Структура розбиття робіт (WBS)

0. Система автоматичної нормалізації суржику та діалектних форм

1. Управління проєктом

- 1.1. Координація та звітність
- 1.2. Управління ризиками

2. Дослідження та аналіз

- 2.1. Огляд академічних джерел та NLP-корпусів
- 2.2. Аналіз наявних підходів до нормалізації

3. Підготовка даних

- 3.1. Збір діалектних зразків та суржик-текстів
- 3.2. Розробка правил та словників нормалізації
- 3.3. Синтетична генерація через LLM та анотація

4. Розробка моделей

- 4.1. Seq2seq baseline модель (umt5-base)
- 4.2. Інструкційне донавчання MamaLM (QLoRA)

5. Оцінка та інтеграція

- 5.1. Автоматична оцінка (BLEU, chrF++, TER, COMET)
- 5.2. Ручна оцінка вибірки (50 речень)
- 5.3. Розробка NiceGUI-інтерфейсу

6. Документація та захист

- 6.1. Бакалаврська кваліфікаційна робота
- 6.2. Технічна документація (README, CHANGELOG)

6.3. Захист проєкту


5.3. Мережева діаграма та розрахунок критичного шляху

Мережева діаграма побудована методом критичного шляху (CPM). Перелік операцій наведено в Таблиці 9.

Таблиця 9 — Перелік операцій проєкту

ID	Операція	Трив., тижні	Залежить від	Відповідальний
A	Аналіз літератури та предметної галузі	3	—	Коваль Д.П.
B	Підготовка та анотація датасету	6	A	Коваль Д.П.
C	Seq2seq базова модель	3	B	Коваль Д.П.
D	Донавчання MamayLM	4	B	Коваль Д.П.
E	Оцінка та інтеграція	2	C, D	Коваль Д.П., Сивоконь О.О.
F	Написання дипломної роботи	4	E	Коваль Д.П., Сивоконь О.О.

Рисунок 1 — Мережева діаграма проєкту (метод CPM)



Умовні позначення: червона рамка - критичні операції (TF=0); сіра рамка - некритичні (TF>0).

Таблиця 10 — Розрахунок раннього та пізнього початку і закінчення

ID	Трив.	ES	EF	LS	LF	TF	Крит.?	FF
A	3	0	3	0	3	0	Так	0
B	6	3	9	3	9	0	Так	0
C	3	9	12	10	13	1	Ні	1
D	4	9	13	9	13	0	Так	0
E	2	13	15	13	15	0	Так	0
F	4	15	19	15	19	0	Так	0

де: **ES** - ранній початок; **EF** - раннє закінчення; **LS** - пізній початок; **LF** - пізнє закінчення; **TF** - загальний резерв часу; **FF** - вільний резерв часу.

Загальна тривалість проєкту: **19 тижнів**. Критичний шлях: **A → B → D → E → F**.

5.4. Матриця комунікацій проєкту


Таблиця 11 — Матриця комунікацій

Аудиторія	Повідомлення	Тип	Частота	Комуніка-тор	Відпов.
Науковий керівник (S2)	Звіти про прогрес та технічні питання	Зустріч / email	Щотижне-во	Коваль Д.П.	Звіт-ність
Кафедра СШ (S3)	Проміжні результати	Презентація	Щомісяця	Коваль Д.П.	Відпо-від-ність
NLP-спільнота (S7)	Публікація моделей та датасетів	GitHub / звіт	За потреби	Коваль Д.П.	Відкри-тість
Носії діалектів (S5)	Збір зразків та зворотній зв'язок	Анкета	1 раз	Коваль Д.П.	Якість даних
Команда MatayLM (S4)	Технічні консультації	Email / API	За потреби	Коваль Д.П.	Інтегра-ція

Аудиторія	Повідомлення	Тип	Частота	Комуніка-тор	Відпов.
EdTech-платформи (S8)	Демонстрація системи	Вебінар	1 раз	Коваль Д.П., Сивоконь О.О.	Популяр.

5.5. Діаграма Ганта

Рисунок 2 — Діаграма Ганта проєкту (тижні 1-19)



Умовні позначення: ■ - критичні операції ($A \rightarrow B \rightarrow D \rightarrow E \rightarrow F$); ■ - некритичні ($TF > 0$).

РОЗДІЛ 6. АНАЛІЗ РИЗИКІВ ПРОЄКТУ

6.1. Ідентифікація ризиків

Управління ризиками є одним із найбільш критичних факторів успіху проєкту. Для ідентифікації ризиків проєкту застосовано такі методи: огляд аналогічних NLP-проєктів та академічних публікацій; консультація з науковим керівником щодо технічних обмежень; аналіз блок-схеми пайплайну генерації даних і тренування моделі; проведення «негативного мозкового штурму» для кожного з п'яти етапів проєкту; SWOT-аналіз специфіки роботи з малоресурсними діалектними корпусами.

За результатами ідентифікації визначено 12 ризиків, що охоплюють технічні, ресурсні, організаційні та якісні виміри проєкту.

6.2. Реєстр ризиків

Кожен ризик оцінено за двома параметрами: ймовірність виникнення (P) та вплив на проєкт (I), кожен за шкалою 1-3 (1 - низький, 2 - середній, 3 - високий). Значущість (Score) = $P \times I$.

Таблиця 12 — Реєстр ризиків проєкту

ІД	Ризик	P	I	Score	К	Стратегія
R01	Нестача паралельних діалектних даних для тренування	3	3	9	Ч	Пом'якшення
R02	Низька якість синтетичних даних LLM (галюцинації, помилки)	3	2	6	Ч	Пом'якшення
R03	Перенавчання (overfitting) через малий обсяг реальних даних	2	3	6	Ч	Пом'якшення
R04	Недостатні GPU-ресурси для fine-tuning MamayLM	2	2	4	Ж	Пом'якшення

ID	Ризик	P	I	Score	K	Стратегія
R05	Зміна умов доступу до API (OpenRouter, rate limits)	2	2	4	Ж	Уникнення
R06	Помилки у вихідних словниках та корпусах	2	2	4	Ж	Пом'якшення
R07	Невідповідність BLEU реальній якості нормалізації	3	1	3	Ж	Прийняття
R08	Відсутність носіїв діалекту для людської оцінки	3	1	3	Ж	Пом'якшення
R09	Зміна вимог керівника або кафедри на пізніх стадіях	1	3	3	Ж	Пом'якшення
R10	Технічні збої GPU-сервера під час тривалого навчання	2	1	2	З	Прийняття
R11	Складність інтеграції seq2seq і MatayLM в єдиний пайплайн	1	2	2	З	Пом'якшення
R12	Обмеження авторських прав на джерельні тексти корпусу	1	2	2	З	Уникнення

6.3. Матриця управління ризиками

Матриця розміщує кожен ризик у двовимірному просторі за осями ймовірності та впливу. Колір визначає пріоритет реагування: ЧЕРВОНИЙ - вирішити негайно; ЖОВТИЙ - розробити план дій; ЗЕЛЕНИЙ - моніторинг.

Ймовірність (P)	Вплив на проєкт (I)		
	1 - низький	2 - середній	3 - високий
3 - високий	Score 3 R07, R08	Score 6 R02	Score 9 R01
2 - середній	Score 2 R10	Score 4 R04, R05, R06	Score 6 R03
1 - низький	Score 1 —	Score 2 R11, R12	Score 3 R09

6.4. Плани реагування на ризики

R01 – Нестача паралельних діалектних даних (Score 9). Головна загроза проєкту. Плани пом'якшення: (а) автоматична генерація синтетичних пар за допомогою LLM на основі правил та словників (реалізовано для гуцульського, BLEU ≈ 51); (б) парсинг відкритих джерел – закарпатський словник (7 469 статей); (в) аугментація через back-translation. Резервний план: обмежити дослідження до двох варіантів (гуцульський + суржик) при критичній нестачі даних.

R02 – Низька якість синтетичних даних (Score 6). Плани пом'якшення: (а) автофільтрація за BLEU-схожістю, довжиною та наявністю діалектних маркерів; (б) ручна перевірка вибірки 2-5% на кожній ітерації; (в) тестування кількох промптів та моделей.

R03 – Перенавчання моделі (Score 6). Плани пом'якшення: (а) QLoRA 4-bit для регуляризації; (б) моніторинг validation loss; (в) early stopping; (г) аугментація та cross-validation. Резервний план: зменшення кількості епох, збільшення dropout.

R04 – Брак GPU-ресурсів (Score 4). QLoRA знижує потребу до 12-16 ГБ VRAM. Резервний план: оренда GPU через Vast.ai або Google Colab Pro.

R05 – Зміна умов API (Score 4). Стратегія уникнення: паралельне тестування локальних моделей (Mistral-7B через llama.cpp); локальне збереження всіх згенерованих даних.

R06 – Помилки у словниках (Score 4). Ручна верифікація 10% записів; автоматична перевірка через SpaCy та Ukrainian NLP.

R07-R09 (Жовті, Score 3). Прийняття з додатковими заходами: chrF + ручна оцінка 50 речень (R07); залучення студентів-філологів або учасників ТМШ (R08); щотижневі зустрічі з науковим керівником (R09).

R10-R12 (Зелені, Score 2). Регулярний моніторинг: збереження checkpoints кожні 500 кроків (R10); модульна архітектура пайплайну (R11); використання тільки CC-BY корпусів (R12).

6.5. Зведений план управління ризиками

Таблиця 13 — Зведений план управління ризиками

ID	Ризик (скор.)	P	I	Score	Дія	Відповід.	Термін
R01	Нестача діалект. даних	3	3	9	LLM-генерація + парсинг	Коваль Д.П.	Лют. 2026
R02	Низька якість LLM-даних	3	2	6	Авто-фільтрація + перевірка	Коваль Д.П.	Постійно
R03	Перенавчання моделі	2	3	6	QLoRA + early stopping	Коваль Д.П.	До трен.
R04	Брак GPU-ресурсів	2	2	4	Vast.ai / Colab Pro	Коваль Д.П.	За потр.
R05	Зміна умов API	2	2	4	Локальні моделі	Коваль Д.П.	Бер. 2026
R06	Помилки у словниках	2	2	4	Верифікація 10%	Коваль Д.П.	Лют. 2026
R07	BLEU $\neq$ реальна якість	3	1	3	chrF + human eval	Коваль Д.П.	Кв. 2026
R08	Відсутність носіїв мови	3	1	3	Залучення філологів	Коваль Д.П.	Кв. 2026
R09	Зміна вимог замовника	1	3	3	Щотижневі зустрічі	Коваль Д.П., Сивоконь О.О.	Постійно
R10	Збої GPU-сервера	2	1	2	Checkpoints 500 кроків	Коваль Д.П.	Постійно

ID	Ризик (скор.)	P	I	Score	Дія	Відповід.	Термін
R11	Складність інтеграції	1	2	2	Модульна архітектура	Коваль Д.П.	Тр. 2026
R12	Авторські права	1	2	2	Тільки СС-ВУ корпуси	Коваль Д.П.	Лют. 2026

РОЗДІЛ 7. ПОСЛІДОВНІСТЬ ВИКОНАННЯ РОБІТ

7.1. Технічний стек та інструменти

Реалізація проєкту базується на таких технологіях та інструментах:

- **Мова програмування:** Python 3.11+.
- **Фреймворки глибокого навчання:** PyTorch 2.6, HuggingFace Transformers [7].
- **Parameter-efficient fine-tuning:** PEFT (LoRA / QLoRA) [4, 5], TRL (SFTTrainer), Unsloth (прискорене навчання для Gemma-3).
- **Управління даними:** HuggingFace Datasets, CSV формат, стратифіковані розбиття.
- **Генерація синтетичних даних:** Mistral Small 24B через OpenRouter API; для суржиків додатково gutorphy2 (правило-базована транслітерація).
- **Оцінювання:** SacreBLEU, chrF++, TER; зовнішні LLM (GPT-4o, Gemini 2.0 Flash, Mistral Large) через OpenRouter API.
- **Розпізнавання мовлення:** SpeechBrain (m-ctc-t-large) для транскрипції аудіо.
- **Моніторинг:** TensorBoard, TensorBoardX.
- **Веб-інтерфейс:** NiceGUI 1.x (застосунок «Лексикон»).
- **Автоматизація:** GNU Make (Makefile із визначеними цілями).
- **Контроль версій:** Git, GitHub.

7.2. Підготовка даних

Підготовка даних є критичним (найтривалішим) етапом проєкту (операція B, 6 тижнів).

Ручні дані. Для гуцульського діалекту зібрано понад 10 000 пар вручну анотованих паралельних прикладів (діалект ↔ літературна норма). Ці дані використовуються виключно у validation і test розбиттях для об'єктивного оцінювання, а також беруть участь у навчанні.

Синтетична генерація. Основний обсяг навчальних даних отримано через синтетичну генерацію (30 000 пар на діалект). Модель *Mistral Small 24B* (через OpenRouter API або локально з 4-bit квантизацією) генерує паралельні пари на основі набору лінгвістичних правил і словника для кожного діалекту.

Для суржику додатково застосовується інструмент *rutorphy2* – правило-базова транслітерація кириличного тексту, що відтворює типові суржикові фонетичні та граматичні явища.

Підготовка мультидіалектного корпусу. Скрипт `prepare_multidialect_data.py` завантажує корпуси для всіх чотирьох варіантів, додає префікси-інструкції («Переклади з гуцульської:», «Переклади з бойківської:» тощо), формує стратифіковані розбиття: **train** – 125 000 пар, **val** – 13 000 пар, **test** – по 50 вручну верифікованих прикладів на діалект.

7.3. Навчання моделей

Baseline: umt5-base (seq2seq). Модель *google/umt5-base* навчається на мультидіалектному паралельному корпусі за допомогою скрипту `train_encoder_decoder.py`. Гіперпараметри: 40 епох, batch size 4, gradient accumulation 4, weight decay 0.1, label smoothing 0.1, AdamW 8-bit (BF16), lr = $5e-5$, максимальна довжина послідовності 256 токенів. Навчання виконується на одному GPU без квантизації.

Fine-tuning: MamayLM (decoder-only, QLoRA). Модель *INSAIT-Institute/MamayLM-Gemma-3-4B-IT-v1.0* донавчається за допомогою скрипту `train_decoder_only.py`. Застосовується 4-bit NF4 квантизація (bitsandbytes), QLoRA-адаптери (rank 4, $\alpha = 4$), SFTTrainer з форматуванням у chat template. Гіперпараметри: 3 епохи, batch size 1, gradient accumulation 2, lr = $2e-4$, max_seq_length = 512. Навчання виконується на GPU через TRL та бібліотеку Unsloth для прискорення.

Прогрес навчання відстежується через TensorBoard: криві loss (training і validation) та метрики BLEU по епохах записуються до директорії results/.

7.4. Оцінювання та веб-інтерфейс

Автоматичне оцінювання. Після навчання скрипти `evaluate_decoder_only.py` та `evaluate_encoder_decoder.py` генерують гіпотези на тестових наборах і обчислюють BLEU, chrF++, TER та COMET по кожному діалекту і суржику окремо.

Зовнішні моделі. Для порівняння оцінюються також GPT-4o, Gemini та Mistral-Small через eval-dialect CLI без донавчання (zero-shot / few-shot).

Веб-інтерфейс «Лексикон». Файл `app.py` реалізує демо-застосунок «Лексикон» на NiceGUI. Завантажується основна модель (umt5-base або MamayLM

QLoRA). Користувач обирає тип вхідного тексту (Гуцульський / Бойківський / Закарпатський / Суржик), вводить текст або завантажує аудіо – система повертає нормалізований варіант. Транскрипція аудіо виконується моделлю SpeechBrain (M-CTC-T-large) безпосередньо у браузері.

7.5. Закриття проєкту та представлення замовникам

Закриття проєкту передбачає: (1) завершення написання тексту БКР; (2) публікацію фінальних моделей на HuggingFace Hub; (3) публікацію датасету та коду у GitHub-репозиторії з ліцензіями Apache 2.0 і CC-BY 4.0; (4) підготовку захисної презентації (Idea Pitch, 3-5 хв); (5) захист бакалаврської роботи на засіданні ДЕК.

РОЗДІЛ 8. ПРЕДСТАВЛЕННЯ ТА СИСТЕМАТИЗАЦІЯ РЕЗУЛЬТАТІВ

8.1. Результати навчання моделей

Нижче наведено зведену таблицю фактично досягнутих метрик якості для всіх підтримуваних варіантів вхідного тексту. Порівнюються три підходи: fine-tuned umt5-base (seq2seq), MamayLM з QLoRA (decoder-only) та GPT-4o Mini у режимі zero-shot (без донавчання). Нижче TER – краще; вище BLEU і chrF++ – краще.

Таблиця 14 — Метрики якості нормалізації (тестовий набір, 50 прикладів/діалект)

Діалект	Модель	BLEU↑	chrF++↑	TER↓
Гуцульський	umt5-base	74.68	86.90	12.53
	MamayLM QLoRA	64.84	74.02	37.60
	GPT-4o (zero-shot)	64.89	—	—
Бойківський	umt5-base	29.12	54.78	49.37
	MamayLM QLoRA	51.81	66.82	35.26
Закарпатський	umt5-base	6.20	27.45	82.21
	MamayLM QLoRA	3.82	20.93	89.69
	GPT-4o (zero-shot)	65.39	—	—
Суржик	umt5-base	89.42	93.58	5.98
	MamayLM QLoRA	78.48	91.22	11.96
	GPT-4o (zero-shot)	88.97	—	—

Примітка: жирним виділено найкращий результат по кожному діалекту. «—» означає, що показник не обчислювався для даної моделі. GPT-4o та Gemini оцінювались лише за BLEU через обмеження платного API.

8.2. Загальні висновки за результатами моделювання

Результати експериментів (Таблиця 14) демонструють суттєву різницю у складності нормалізації між діалектами. **Суржик** виявився найлегшим для обох моделей: `umt5-base` досяг BLEU = 89.42, що зіставно з рівнем GPT-4o (88.97) без будь-якого донавчання. **Гуцульський діалект** також показав сильні результати у `seq2seq` підходу (BLEU = 74.68, TER = 12.53), тоді як `MamayLM` після донавчання поступається на 10 BLEU-балів – ймовірно, через особливості `chat-template` формату. **Бойківський діалект** виявив зворотну картину: `MamayLM QLoRA` перевершив `umt5-base` на 22.7 BLEU (51.81 проти 29.12), що вказує на більшу здатність `decoder-only` архітектури до узагальнення для менш ресурсних варіантів. **Закарпатський діалект** залишається найскладнішим для `fine-tuned` моделей (BLEU < 7), але GPT-4o нульовим пострілом досягнув BLEU = 65.39, що свідчить про нестачу ресурсів у тренувальному корпусі та вказує напрямок для майбутніх досліджень.

Ключовими факторами якості є: (1) стратифіковане балансування корпусу за діалектами; (2) синтетична генерація через `Mistral Small 24B` за правило-базованими промптами; (3) використання лише вручну верифікованих даних у `validation` і `test` розбиттях. Застосунок «Лексикон» забезпечує `end-to-end` демонстрацію від голосового введення до нормалізованого тексту.

ВИСНОВКИ

У ході виконання розрахунково-графічної роботи сформовано повну технічну та комунікаційну документацію для ІТ-проєкту «Система для автоматичної нормалізації суржику та діалектних форм української мови». Нижче підведено підсумки за всіма 13 пунктами змістового контенту.

1. **Вступ.** Обґрунтовано актуальність задачі нормалізації діалектів і суржику в контексті сучасного стану українського суспільства та розвитку NLP-технологій.
2. **Сфера застосування та об'єм робіт.** За методами «Критичних запитань» і SMART визначено: проблему, потреби, сферу, зацікавлені сторони, межі проєкту та трикутник обмежень (час / ресурси / якість).
3. **Процес управління та концептуальні поняття.** Проєкт визначено як тимчасове зусилля зі створення унікального програмного продукту. Описано команду (виконавець + науковий керівник) і ромб конкурентних обмежень (кошти, час, якість, результат).
4. **Складність проєкту.** Проєкт класифіковано як еволюційний із середнім рівнем виклику та менеджментною критичністю.
5. **Вимоги до проєкту (RAM).** Сформовано матрицю розподілу відповідальності для 13 ключових завдань і 10 стейкхолдерів.
6. **Стейкхолдери.** Ідентифіковано 10 зацікавлених сторін – від виконавця і наукового керівника до носіїв діалектів, NLP-спільноти та EdTech-платформ. Побудовано сітку Power/Interest.
7. **Вимоги стейкхолдерів та планування.** Сформовано таблицю вимог, прив'язану до фаз. Для кожної з п'яти фаз PMBOK розроблено контрольний список.
8. **Контрольний список та WBS.** Побудовано структуру розбиття робіт із 6 пакетів і 13 завдань. Реалізовано 16-крокову перевірку планування.
9. **Аналіз ризиків.** Ідентифіковано 12 ризиків, оцінено ймовірність та вплив, побудовано матрицю і розроблено конкретні плани реагування.
10. **Комунікаційна матриця.** Визначено аудиторії, типи повідомлень, частоту та відповідальних для 6 каналів комунікації.

11. **Закриття проєкту.** Визначено артефакти закриття: публікація БКР, відкритий репозиторій, модель на HuggingFace, захист.
12. **Представлення проєкту.** Підготовлено Idea Pitch (3-5 хв) за структурою: проблема, рішення, результати, висновки.
13. **Підсумки.** Навчання завершено для обох моделей на всіх чотирьох діалектах. umt5-base досяг BLEU = 89.42 на суржику та 74.68 на гуцульському. MatayLM QLoRA перевершив baseline на бойківському (BLEU 51.81 проти 29.12). Закарпатський діалект залишається викликом для донавчених моделей, але GPT-4o (zero-shot) демонструє BLEU = 65.39, що вказує на перспективи збільшення корпусу. Застосунок «Лексикон» розгорнуто та готовий до демонстрації.

СПИСОК ВИКОРИСТАНИХ ДЖЕРЕЛ

Література

- [1] Project Management Institute. *A Guide to the Project Management Body of Knowledge (PMBOK Guide)*. 7th ed. — PMI, 2021. — 370 p.
- [2] Vaswani A., Shazeer N., Parmar N. et al. Attention is All You Need // *Advances in Neural Information Processing Systems 30 (NeurIPS 2017)*. — Curran Associates, 2017. — P. 5998–6008.
- [3] Raffel C., Shazeer N., Roberts A. et al. Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer // *Journal of Machine Learning Research*. — 2020. — Vol. 21(140). — P. 1–67.
- [4] Hu E.J., Shen Y., Wallis P. et al. LoRA: Low-Rank Adaptation of Large Language Models // *Proceedings of the International Conference on Learning Representations (ICLR 2022)*. — OpenReview, 2022.
- [5] Dettmers T., Pagnoni A., Holtzman A., Zettlemoyer L. QLoRA: Efficient Finetuning of Quantized LLMs // *Advances in Neural Information Processing Systems 36 (NeurIPS 2023)*. — Curran Associates, 2023.
- [6] Syvokon O., Nahorna O. UA-GEC: Grammatical Error Correction and Fluency Corpus for the Ukrainian Language // *Proceedings of the Second Ukrainian Natural Language Processing Workshop (UNLP 2023)*. — Association for Computational Linguistics, 2023. — P. 143–149.
- [7] Wolf T., Debut L., Sanh V. et al. Transformers: State-of-the-Art Natural Language Processing // *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP 2020): System Demonstrations*. — Association for Computational Linguistics, 2020. — P. 38–45.