

Національний університет "Львівська політехніка"

Інститут комп'ютерних наук та інформаційних технологій

Кафедра систем штучного інтелекту

Спеціальність 122 «Комп'ютерні науки»



ARTIFICIAL
INTELLIGENCE

ПОЯСНЮВАЛЬНА ЗАПИСКА

до бакалаврської кваліфікаційної роботи на тему:

«Система для автоматичної нормалізації суржику та діалектних форм української мови»

Студента(ки) групи

ІІІ-42

Дениса КОВАЛЯ

Керівник роботи

(підпис)

(Олексій СИВОКОНЬ)

Консультанти

(підпис)

(_____)

(підпис)

(_____)

Завідувач

кафедри СШІ

(Наталія МЕЛЬНИКОВА)

Львів - 2026

Національний університет "Львівська політехніка"
Інститут комп'ютерних наук та інформаційних технологій
Кафедра систем штучного інтелекту
Спеціальність 122 «Комп'ютерні науки»

ЗАТВЕРДЖУЮ:

Завідувач кафедри СШІ _____

“ ____ ” _____ 2026р.

ЗАВДАННЯ
НА БАКАЛАВРСЬКУ КВАЛІФІКАЦІЙНУ РОБОТУ СТУДЕНТОВІ

Ковалю Денису Петровичу

1. Тема роботи: «Система для автоматичної нормалізації суржику та діалектних форм української мови» затверджена наказом університету ____
2. Термін подання закінченої роботи: 28.05.2026
3. Вхідні дані до (проекту) роботи: літературні джерела щодо методів машинного перекладу, словники суржиків та діалектів, методичні рекомендації до виконання бакалаврської кваліфікаційної роботи для студентів спеціальності 122 «Комп'ютерні науки».
4. Зміст розрахунково-пояснювальної записки: (перелік питань, що належить розробити): аналітичний огляд літературних та інших джерел, системний аналіз та обґрунтування проблеми, методи та засоби вирішення проблеми, практична реалізація.
5. Перелік графічного матеріалу (з точним зазначенням обов'язкових креслень): структурна схема системи; графіки навчання та оцінювання моделей

6. Консультанти по роботі, із зазначенням розділів проекту, що стосується їх

Розділ	Консультант	Підпис, дата	
		Завдання видав	Завдання прийняв
Консультант з іноземної мови			

7. Дата видачі завдання _____ 23.09.2025 _____

Керівник роботи _____
(підпис)

Завдання прийняв до виконання _____
(підпис)

КАЛЕНДАРНИЙ ПЛАН

№ п/п	Назва етапів дипломної роботи	Термін виконання етапів роботи	Примітка
1	Огляд літератури	23.09.2025 – 28.10.2025	виконано
2	Створення архітектури	29.10.2025 – 16.12.2025	виконано
3	Розробка алгоритмічного та програмного забезпечення	17.12.2025 – 01.03.2026	виконано
4	Експериментальні дослідження	02.03.2026 – 20.03.2026	виконано
5	Оформлення записки	21.03.2026 – 28.05.2026	виконано

Керівник роботи _____
(підпис)

Студент _____
(підпис)

АНОТАЦІЯ

Бакалаврська кваліфікаційна робота виконана студентом групи ІІІ-42 Ковалем Денисом Петровичем. Тема «Система для автоматичної нормалізації суржику та діалектних форм сучасної української мови». Робота направлена на здобуття ступеня бакалавра за спеціальністю 122 «Комп'ютерні науки».

Об'єктом дослідження є процеси автоматичної нормалізації нелітературних форм сучасної української мови - суржику та регіональних діалектів.

Предметом дослідження є методи формування паралельних корпусів для низькоресурсних мовних варіантів, а також методи навчання нейронних моделей машинного перекладу та великих мовних моделей для задачі нормалізації діалектного і суржикового тексту.

У роботі зібрано паралельний корпус із 125 615 навчальних прикладів для чотирьох мовних різновидів - гуцульського, бойківського, закарпатського діалектів і суржику. Для синтетичної генерації використано комбінацію правилкових підходів і великої мовної моделі Mistral Small 24B. Навчено дві моделі: кодер-декодерну (umt5-base, повне донавчання) та декодерну велику мовну модель (MamayLM на базі Gemma-3-4B, параметро-ефективне донавчання QLoRA). Якість оцінено за метриками BLEU, chrF++ і TER у порівнянні з нуль-шотовими великими мовними моделями - GPT-4o, Gemini 2.0 Flash і Mistral Large.

Навчені моделі перевершили нуль-шотові великі мовні моделі на суржику (chrF++ = 93,58 для umt5-base) та гуцульському діалекті (chrF++ = 86,90 для umt5-base). Реалізовано вебзастосунок «Лексикон» із підтримкою голосового введення.

Ключові слова: нормалізація тексту, суржик, діалекти, нейронний машинний переклад, велика мовна модель, донавчання, параметро-ефективне налаштування, паралельний корпус, гуцульський діалект.

ABSTRACT

The bachelor's qualification work was completed by Koval Denys Petrovych, a student of group AI-42. The topic is "System for Automatic Normalization of Surzhyk and Dialectal Forms of the Modern Ukrainian Language." The work is aimed at obtaining a bachelor's degree in specialty 122 "Computer Science."

The object of research is the process of automatic normalization of non-standard forms of modern Ukrainian - surzhyk and regional dialects - to literary standard Ukrainian.

The subject of research is methods for constructing parallel corpora for low-resource language varieties, and methods for training neural models for the task of text normalization.

A parallel corpus of 125,615 training examples was assembled for four language varieties: Hutsul, Boikivian, and Transcarpathian dialects, as well as surzhyk. Synthetic data was generated using rule-based approaches (SurzhykErrorifier) and the Mistral-Small-24B language model. Two neural models were trained: an encoder-decoder model (umt5-base, full fine-tuning, 40 epochs) and a decoder-only large language model (MamayLM based on Gemma-3-4B, QLoRA parameter-efficient fine-tuning, 3 epochs). Quality was evaluated using BLEU, chrF++, and TER metrics against zero-shot large language model baselines: GPT-4o, Gemini 2.0 Flash, and Mistral Large. The fine-tuned umt5-base model achieved chrF++ = 93.58 on surzhyk and chrF++ = 86.90 on the Hutsul dialect. A web application "Leksykon" was implemented with voice input support via the SpeechBrain ASR module.

Keywords: text normalization, surzhyk, Ukrainian dialects, large language model, QLoRA, parallel corpus, Hutsul dialect, Boikivian dialect, Transcarpathian dialect.

1. Introduction and Problem Statement

The Ukrainian language occupies a complex sociolinguistic position in modern Ukraine. Standard literary Ukrainian coexists with a wide spectrum of non-standard varieties, ranging from regionally grounded dialects to urban contact languages. Two categories of non-standard Ukrainian speech are of particular relevance for natural language processing: *surzhyk* and the western Ukrainian regional dialects.

Surzhyk is a sociolinguistic phenomenon that emerged during the Soviet era as a result of intensive contact between Ukrainian and Russian. Unlike geographic dialects, surzhyk is not bound to a specific region: it is widely spoken in central and eastern Ukraine, primarily in urban areas. Linguistically, surzhyk is characterized by lexical and morphological mixing without a stable phonological system. Common manifestations include Russian lexical substitutions (Ukrainian *але* “but” replaced by Russian *но*; *зупинка* “bus stop” by *остановка*), Russian infinitive endings (-ть instead of -ти), and calqued conjunctions (*якщо* “if” replaced by *если*).

The Carpathian and western Ukrainian region is home to three dialects addressed in this work. The *Hutsul dialect* is spoken in the Carpathian mountain communities and is relatively well documented. Its distinctive features include front-vowel stress shifts (*шанка* → *шенка*), the reflexive particle *си* (instead of standard *ся*), and archaic verbal suffixes (-*єм* for third-person singular). The *Boikivian dialect*, spoken in the foothills of the Carpathians, is more archaic and phonologically conservative. Its characteristic features include the preservation of an unrounded back vowel [ы] distinct from standard [и] (*бик* → *бык*) and the shift of the lateral [л] to the bilabial approximant [ʏ] in coda position (*галка* → *гавка*). The *Transcarpathian dialect* is the most distant from the literary norm, shaped by centuries of contact with Hungarian, Slovak, and Romanian. Key features include the vowel shift *o* → *u* in closed syllables (*кінь* → *кунь*), preservation of the archaic [ы], and numerous contact borrowings.

Automatic text normalization - the task of mapping a non-standard input sequence *x* to literary standard output *y* - occupies a position between grammatical

error correction (GEC) and machine translation (MT). Unlike GEC, dialect normalization targets systematic linguistic features that are not “errors” from the speaker’s perspective, but rather reflect a different language variety. Unlike MT, normalization operates within a single language family, with significant lexical overlap between input and output.

The lack of specialized resources for Ukrainian dialect normalization is a critical gap. Public corpora for Ukrainian grammatical error correction - UA-GEC and Spivavtor - are oriented toward standard Ukrainian texts and do not cover dialectal input. No public parallel corpus exists for Boikivian or Transcarpathian dialects. Existing work on Ukrainian dialectal NLP is sparse: Vuyko Mistral targets Hutsul-to-standard translation using limited in-house data; Bytes to Borsch focuses on adapting large language models to standard Ukrainian rather than dialectal processing. No prior work has addressed all four varieties simultaneously within a unified framework.

The present work addresses this gap through four contributions: (1) construction of a parallel normalization corpus of 139,576 sentence pairs for four non-standard Ukrainian varieties, combining manual annotation, rule-based generation, and large language model synthesis; (2) training of two neural normalization models - an encoder-decoder (umt5-base) and a decoder-only model (MamayLM, Gemma-3-4B with QLoRA) - on this corpus; (3) comparative evaluation against zero-shot commercial large language model baselines (GPT-4o, Gemini 2.0 Flash, Mistral Large); and (4) deployment of the “Leksykon” web application integrating normalization with automatic speech recognition.

2. Linguistic Characteristics of the Four Varieties

The four non-standard varieties addressed in this work differ substantially in their linguistic distance from the literary norm and in the availability of annotated resources. The linguistic distance ordering - surzhyk, Hutsul, Boikivian, Transcarpathian (from least to most distant) - directly predicts normalization difficulty, as confirmed by the evaluation results in Section 5.

Surzhyk ($\approx 50,523$ training pairs) is characterized by Russian lexical and morphological mixing without a stable phonological system. Normalization reduces largely to lexical and morphological substitution: a sufficient dictionary of Russian-Ukrainian lexical correspondences and morphological transformation rules captures a large fraction of surzhyk utterances. This means that rule-based and LLM-synthetic training data closely resembles real surzhyk usage and yields strong training signal.

Hutsul dialect ($\approx 36,640$ training pairs) is spoken in the Carpathian mountain communities and is characterized by front-vowel stress shifts, the reflexive particle *cu* instead of standard *ся*, and archaic verbal suffixes. The availability of 9,853 manually annotated parallel pairs provides clean training signal for the phonological patterns that rules alone cannot capture reliably. These pairs were sourced from a public dataset and validated by native speakers.

Boikivian dialect ($\approx 29,754$ training pairs) is spoken in the Carpathian foothills and is phonologically archaic: it preserves an unrounded back vowel [ɤ] distinct from standard [ɯ], and shifts [ɲ] to bilabial [ɣ] in coda position. No manually annotated corpora are publicly available; training data was generated entirely synthetically, introducing a distribution mismatch that limits model performance.

Transcarpathian dialect ($\approx 29,605$ training pairs) is the most distant from the literary norm, shaped by centuries of contact with Hungarian, Slovak, and Romanian. Key features include the vowel shift $o \rightarrow u$ in closed syllables, preservation of archaic [ɤ], and numerous contact borrowings with no Ukrainian equivalents. Training data is entirely synthetic, and the distribution mismatch is most severe here.

3. Corpus Construction

The corpus was constructed using a “standard-to-dialect” strategy: given a sentence in standard literary Ukrainian, the system generates the corresponding dialectal or surzhyk variant. This approach guarantees correct targets by construction - the standard-side output comes from quality source texts rather than potentially incorrect normalization outputs. At inference time, the direction is inverted (dialect $\rightarrow$ standard), and the model learns to normalize by reversing the transformation

patterns seen during training.

The primary source of standard Ukrainian sentences was the Spivavtor corpus, a collection of Ukrainian text-editing pairs that provides high-quality literary Ukrainian prose. For the Hutsul dialect, 9,853 manually annotated parallel pairs (dialect $\rightarrow$ standard) from a public dataset were incorporated directly and inverted for training.

Surzhyk data was generated using the SurzhykErrorifier class, which implements two-phase generation with a morphological analyzer (pymorphy2) and a manually compiled surzhyk lexicon. Phase 1 applies dictionary-based phrase substitution (longest-first matching to avoid partial replacements). Phase 2 applies morphological substitution: the correct Ukrainian word form is identified via pymorphy2, and its Russian surzhyk equivalent is generated with matching morphological features (case, number, gender). This pipeline produced 20,911 high-quality surzhyk examples from approximately 40% of the source corpus.

For all four varieties, dialect pairs were also generated using Mistral-Small-24B-Instruct-2501 running locally with 4-bit NF4 quantization. The DialectCorpusGenerator class orchestrates the pipeline. For each sentence, the DialectPromptBuilder component retrieves the $k = 50$ most relevant dialect dictionary entries via TF-IDF cosine similarity and incorporates them into a dialect-specific system prompt. Sentences were processed in batches of five, with a four-stage quality control pipeline: JSON structure validation, sentence-level format validation, MinHash-based deduplication, and JSONL checkpoint logging for resumable generation. This pipeline produced 108,812 dialect pairs across all four varieties.

The assembled corpus totals 139,576 sentence pairs: 9,853 manual Hutsul annotations, 108,812 LLM-generated pairs, and 20,911 rule-based surzhyk examples. After stratified splitting by dialect, the final distribution is 125,615 training examples, 13,756 validation examples, and 200 test examples (50 hand-annotated per variety, with no overlap with training or validation data).

4. Model Architecture and Training

Dialect normalization is formulated as a conditional sequence generation task. Given a non-standard input sequence $x = (x_1, \dots, x_m)$, the model learns to generate the corresponding standard Ukrainian output $y = (y_1, \dots, y_n)$ by maximizing the conditional log-likelihood over the training corpus:

$$\theta^* = \arg \max_{\theta} \sum_{k=1}^N \log p_{\theta}(y^{(k)} | x^{(k)}). \quad (1)$$

For encoder-decoder models the output is factorized autoregressively conditioned on the full input encoding:

$$p_{\theta}(y | x) = \prod_{t=1}^n p_{\theta}(y_t | x, y_{<t}). \quad (2)$$

The training objective is the cross-entropy loss with label smoothing (smoothing factor $\alpha = 0.1$ for umt5-base):

$$\mathcal{L}(\theta) = - \sum_{t=1}^n \left[(1 - \alpha) \log p_{\theta}(y_t | x, y_{<t}) + \frac{\alpha}{|V|} \sum_{v \in V} \log p_{\theta}(v | x, y_{<t}) \right]. \quad (3)$$

Dialect conditioning is achieved by prepending a dialect identifier prefix to the source sequence: “*Translate from Hutsul: {input}.*” Both models share a single set of parameters across all four varieties, enabling cross-dialect transfer learning.

Both model families rely on the scaled dot-product attention mechanism. Given query matrix Q , key matrix K , and value matrix V :

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^{\top}}{\sqrt{d_k}}\right) V, \quad (4)$$

where d_k is the key dimensionality. Multi-head attention applies h parallel attention heads and projects the concatenated result. The encoder-decoder model uses bidirectional self-attention in the encoder and cross-attention in the decoder; the

decoder-only model uses causal (autoregressive) self-attention throughout.

The first model is based on Google’s mT5-base, a massively multilingual text-to-text transformer with approximately 580M parameters and a SentencePiece vocabulary of 250,112 subword tokens trained on mC4 (101 languages, including Ukrainian). The model was trained with *full fine-tuning* - all parameters updated - for up to 40 epochs with early stopping (patience of 5 epochs on validation BLEU). Training configuration: learning rate 5×10^{-5} with cosine schedule, AdamW optimizer with 8-bit BitsAndBytes quantization of optimizer states, gradient accumulation over 4 micro-batches of size 4 (effective batch size 16), maximum sequence length 256 tokens, BF16 mixed precision. Label smoothing $\alpha = 0.1$ was applied throughout training. The best checkpoint was reached at training step 314,040 (validation BLEU = 71.7).

The second model is based on MamayLM (INSAIT-Institute/MamayLM-Gemma-3-4B-IT-v1.0), a Ukrainian-optimized instruction-tuned variant of Google’s Gemma-3-4B with approximately 4 billion parameters. As a decoder-only autoregressive model, it generates the normalized output token-by-token, framed as an instruction-following chat exchange: the system prompt states the task, and the user turn contains the dialectal input.

To enable fine-tuning within GPU memory constraints, QLoRA (Quantized Low-Rank Adaptation) was applied. The base model weights were quantized to 4-bit NF4 format with double quantization of the quantization constants. Low-rank adapter matrices were added to all attention and feed-forward projection layers. The LoRA update rule is:

$$W' = W + \Delta W = W + BA, \quad B \in \mathbb{R}^{d \times r}, \quad A \in \mathbb{R}^{r \times k}, \quad r \ll \min(d, k), \quad (5)$$

with rank $r = 16$ and scaling factor $\alpha_{LoRA} = 32$. This yields approximately 13 million trainable parameters - 0.4% of the total 4B model.

Training was performed for 3 epochs using the SFTTrainer framework with Unsloth acceleration (sequence packing, asynchronous checkpoint saving).

Configuration: learning rate 2×10^{-4} with cosine schedule and 3% linear warmup, AdamW optimizer, gradient accumulation over 2 steps (effective batch size 2), maximum sequence length 512 tokens, BF16 mixed precision. The cross-entropy loss was applied only to the assistant response tokens (the normalized Ukrainian output), masking the loss on instruction-turn tokens so that the model learns the output distribution without overfitting to the prompt format.

5. Evaluation and Results

Three complementary metrics were used. BLEU (Bilingual Evaluation Understudy) measures n-gram precision between model output and reference, penalizing short outputs via the brevity penalty. chrF++ extends BLEU by incorporating character-level n-grams alongside word n-grams, with $\beta = 2$ weighting favoring recall. chrF++ is used as the primary metric because it is more robust to morphological variation - a common pattern in Ukrainian normalization - than word-level BLEU. TER (Translation Edit Rate) measures the minimum number of edit operations needed to convert model output to the reference, normalized by reference length; lower values are better. All metrics are computed using the SacreBLEU library.

The test set consists of 200 manually annotated sentence pairs (50 per variety), held out from both training and validation. All test examples are human-annotated (not LLM-generated), ensuring a reliable evaluation signal independent of the synthetic data quality. Three commercial large language model baselines were evaluated in zero-shot mode via the OpenRouter API: GPT-4o, Gemini 2.0 Flash, and Mistral Large. Each baseline received the same dialect prefix prompt as the fine-tuned models, with no in-context examples. Additionally, MamayLM in its pre-fine-tuning state was evaluated to isolate the contribution of fine-tuning from the model’s pretraining knowledge.

On surzhyk, both fine-tuned models substantially outperform all zero-shot baselines. umt5-base achieves $\text{chrF++} = 93.58$ versus Gemini’s 86.67 (the strongest baseline), a margin of 6.9 points. MamayLM before fine-tuning scores 65.58; after

QLoRA training it reaches 91.22 - a gain of 25.6 points. The strong performance is explained by the large training corpus ($\approx 50,500$ pairs) and the lexical proximity of surzhyk to standard Ukrainian: normalization requires mainly lexical and morphological substitution, for which the combined rule-based and LLM-synthetic data is representative.

On the Hutsul dialect, umt5-base achieves $\text{chrF}^{++} = 86.90$, outperforming Gemini 2.0 Flash (65.34) by 21.6 points. The improvement from pre-training to post-training for MamayLM is $16.73 \rightarrow 74.02$, an absolute gain of 57.3 points - the largest observed for any model-variety combination. This dramatic improvement demonstrates the decisive role of the 9,853 manually annotated pairs: they provide authentic phonological patterns that the pre-trained model had not encountered during general-purpose training, and that LLM-generated data alone cannot replicate reliably.

On the Boikivian dialect, commercial large language models outperform the fine-tuned models. Gemini 2.0 Flash achieves $\text{chrF}^{++} = 74.57$, compared to MamayLM fine-tuned (66.82) and umt5-base (54.78). The training data for Boikivian is entirely LLM-generated (29,754 pairs), and the generation model may not have replicated authentic Boikivian phonology with sufficient fidelity. Commercial LLMs with far larger pretraining corpora appear to have encountered more genuine Boikivian-like text than the synthetic training data captures.

The Transcarpathian dialect is the most challenging variety for all systems. Fine-tuned models score far below zero-shot baselines: umt5-base 27.45, MamayLM fine-tuned 20.93, versus Gemini 2.0 Flash 68.16. The Transcarpathian dialect has the greatest linguistic distance from the literary norm, with systematic vowel shifts, contact borrowings from three neighboring languages, and phonological features largely absent from other Ukrainian varieties. The training data is entirely synthetic (29,605 pairs), and the distribution mismatch is most severe here. The fact that pre-fine-tuning MamayLM (27.90) marginally outperforms the fine-tuned version (20.93) suggests that low-quality synthetic training data can slightly degrade performance on

genuinely out-of-distribution patterns.

Specialized fine-tuning on quality annotated data decisively outperforms zero-shot large language model prompting for varieties where such data is available (surzhyk, Hutsul). For varieties where training data is purely synthetic (Boikivian, Transcarpathian), commercial large language models with broader pretraining retain a clear advantage. The primary bottleneck for dialect normalization is not model capacity or architecture, but the availability of manually annotated parallel data.

6. The “Leksykon” Web Application

The “Leksykon” system is a web application providing interactive access to the normalization system for both typed and spoken dialectal Ukrainian input. It was implemented using NiceGUI 1.4+, a Python-native UI framework built over FastAPI/ASGI, enabling the normalization and ASR models to be co-located in the same Python process. The application is launched via make demo and is accessible at <http://0.0.0.0:7870>. A CPU fallback mode (float32 precision) is available when no GPU is present.

Normalization module. The DialectTranslator class loads the fine-tuned umt5-base-multidialect model at startup in float16 precision on GPU. Normalization uses beam search with num_beams=5, max_length=128, repetition_penalty=1.2, and no_repeat_ngram_size=3 to discourage repetitive outputs. The user can interactively adjust beam width (3-10) and repetition penalty (1.0-2.0) via UI sliders without reloading the model, enabling quality-speed trade-off exploration.

Speech recognition module. The ASR module uses the SpeechBrain m-ctc-t-large model (MCTCTForCTC architecture, multilingual, pretrained on seven languages including Ukrainian). Audio is recorded in the browser via the MediaRecorder API and sent to the FastAPI endpoint POST /api/transcribe. The PyAV library decodes the audio and resamples it to 16 kHz mono float32 format. Supported audio formats: WebM, OGG, WAV. The recognized transcript is populated into the text input field, where it can be reviewed and submitted for normalization.

User interface. The application uses a three-column desktop layout with a

vertical stack on mobile devices (viewport < 768 px). The interface includes a dialect selector (four buttons: Hutsul, Boikivian, Transcarpathian, Surzhyk), a text input field with a microphone button for voice input, a normalize button, an output field, adjustment sliders, and four preset example sentences per dialect for guided testing. The complete frontend is implemented in approximately 250 lines of Python using NiceGUI components.

7. Conclusions and Future Work

The work achieved the following main results:

1. An analysis of existing approaches to dialect normalization and grammatical error correction identified the absence of publicly available parallel corpora for the Boikivian and Transcarpathian dialects. No prior system addresses surzhyk and three Ukrainian dialects within a unified normalization framework.
2. A manual Hutsul corpus of 9,853 sentence pairs was incorporated, and the Spivavtor corpus was processed as a source of high-quality standard Ukrainian target sentences.
3. A rule-based surzhyk generation pipeline (SurzhykErrorifier) was implemented using pymorphy2 morphological analysis and a surzhyk substitution lexicon, producing 20,911 training examples.
4. An LLM-based dialect generation pipeline (DialectCorpusGenerator with Mistral-Small-24B-Instruct-2501, TF-IDF dictionary retrieval, and four-stage quality control) produced 108,812 synthetic training pairs across all four varieties.
5. The umt5-base encoder-decoder model was trained to convergence over 40 epochs (with early stopping), achieving chrF++ = 93.58 on surzhyk and 86.90 on the Hutsul dialect - both substantially above all zero-shot large language model baselines.
6. The MamayLM (Gemma-3-4B) decoder-only model was fine-tuned with QLoRA ($r = 16$, $\alpha_{LoRA} = 32$), updating only 0.4% of the model's

parameters. It achieved chrF++ = 91.22 on surzhyk and 66.82 on Boikivian, outperforming umt5-base on the latter dialect.

7. The “Leksykon” web application integrating umt5-base normalization with SpeechBrain ASR was implemented and deployed.

The central finding of this work is that specialized fine-tuning on quality annotated data significantly outperforms zero-shot large language model prompting for dialect normalization - but only when that annotated data is available. For Boikivian and Transcarpathian, where training data is entirely synthetic, commercial large language models with broader pretraining exposure retain a clear advantage. This result reframes the core challenge of Ukrainian dialect NLP: the bottleneck is not model architecture or compute, but the availability of manually annotated parallel data.

Future work should prioritize: (1) collection of 3,000-5,000 manual parallel pairs for Boikivian and Transcarpathian dialects, which is expected to substantially close the performance gap with commercial baselines; (2) fine-tuning of the ASR module on dialectal speech recordings to improve recognition accuracy for non-standard input; (3) extension of the normalization system to additional Ukrainian dialects (Slobozhan, Podilian, Volhynian); and (4) development of a REST API for integration with downstream natural language processing pipelines.

ЗМІСТ

АНОТАЦІЯ.....	4
ABSTRACT	5
ЗМІСТ.....	17
ПЕРЕЛІК УМОВНИХ ПОЗНАЧЕНЬ	18
ВСТУП.....	20
1. ЗАГАЛЬНІ ПОЛОЖЕННЯ	22
1.1. Аналіз предметної галузі та літературних джерел	22
1.1.1. Нормалізація як задача між нейронним машинним пере- кладом і виправленням граматичних помилок.....	22
1.1.2. Діалекти та суржик як об’єкти автоматичної нормалізації	23
1.1.3. Наявні ресурси та підходи до синтетичного розширення да- них	24
1.1.4. Сучасні україномовні моделі та найближчі суміжні роботи ..	25
1.2. Аналіз вхідних даних.....	26
1.2.1. Лінгвістична характеристика мовних різновидів	27
1.2.2. Ресурси для гуцульського діалекту	28
1.2.3. Корпус «Співавтор» як джерело літературної норми	29
1.2.4. Словникова база мовних різновидів	30
1.2.5. Синтетична генерація даних	31
1.2.6. Формування та структура фінального корпусу	32
1.3. Висновки до розділу 1	33
2. ІНФОРМАЦІЙНЕ ТА МАТЕМАТИЧНЕ ЗАБЕЗПЕЧЕННЯ	35
2.1. Аналіз підходів до нормалізації.....	35
2.1.1. Нормалізація як задача перетворення тексту	35
2.1.2. Правильні підходи та їх обмеження.....	36

2.1.3. Нейромережеві підходи: кодер-декодерна модель і декодерна BMM.....	36
2.2. Постановка задачі та математична модель.....	37
2.2.1. Формальна постановка нормалізації.....	37
2.2.2. Формат даних для двох архітектур	38
2.2.3. Цільова функція: крос-ентропія і згладжування міток	38
2.3. Математичні основи трансформера.....	39
2.3.1. Механізм уваги	39
2.3.2. Позиційне кодування, нормалізація шарів і прямозв'язний блок.....	39
2.3.3. Кодер-декодерна архітектура.....	40
2.3.4. Авторегресійна декодерна модель	42
2.4. Вибір та обґрунтування моделей.....	42
2.4.1. Кодер-декодерна модель umt5-base.....	42
2.4.2. Декодерна BMM MamyLM.....	43
2.4.3. Параметро-ефективне донавчання: LoRA та QLoRA	43
2.5. Гіперпараметри та конфігурація навчання.....	45
2.5.1. Доновчання umt5-base	45
2.5.2. Доновчання MamyLM (QLoRA).....	46
2.6. Метрики оцінювання	47
2.6.1. BLEU.....	47
2.6.2. chrF++	47
2.6.3. TER	48
2.6.4. Взаємодоповнюваність метрик.....	48
2.7. Стратегії декодування	49
2.8. Балансування даних	50
2.8.1. Дисбаланс діалектів та принципи семплювання	50
2.8.2. Формат інструкцій для мультидіалектності	50
2.9. Висновки до розділу	50

3. ПРОГРАМНЕ ТА ТЕХНІЧНЕ ЗАБЕЗПЕЧЕННЯ	51
3.1. Технологічний стек.....	51
3.2. Конвеєр генерації корпусу.....	52
3.2.1. Правильна генерація суржику	52
3.2.2. LLM-генерація для діалектів	54
3.2.3. Підготовка корпусу до навчання.....	55
3.3. Навчання моделей.....	56
3.3.1. Донавчання umt5-base	56
3.3.2. Донавчання MamayLM.....	57
3.4. Оцінювання та аналіз результатів.....	60
3.4.1. Методологія оцінювання.....	60
3.4.2. Результати кодер-декодерної моделі umt5-base	60
3.4.3. Результати декодерної ВММ MamayLM	61
3.4.4. Порівняння з нуль-шотовими базовими лініями	62
3.4.5. Аналіз результатів.....	62
3.5. Вебзастосунок «Лексикон»	64
3.5.1. Архітектура застосунку.....	64
3.5.2. Модуль нормалізації	65
3.5.3. Модуль автоматичного розпізнавання мовлення	66
3.5.4. Інтерфейс користувача	66
3.6. Висновки до розділу	67
ЗАГАЛЬНІ ВИСНОВКИ	69
СПИСОК ВИКОРИСТАНИХ ДЖЕРЕЛ.....	71
Додаток А.....	73
Додаток Б	90

ПЕРЕЛІК УМОВНИХ ПОЗНАЧЕНЬ

APM - автоматичне розпізнавання мовлення (Automatic Speech Recognition) - технологія перетворення мовленнєвого сигналу на текст.

ВММ - велика мовна модель (Large Language Model) - нейронна модель на основі трансформера, навчена на великих масивах тексту та здатна до генерації і обробки природної мови.

ГП - графічний процесор - спеціалізований процесор для паралельних обчислень, що використовується при навчанні нейронних мереж.

НМП - нейронний машинний переклад (Neural Machine Translation) - підхід до автоматичного перекладу тексту з використанням нейронних мереж.

ОП - оперативна пам'ять - основна пам'ять комп'ютера для зберігання даних під час виконання програм.

ОПМ - обробка природної мови (Natural Language Processing) - галузь штучного інтелекту, що вивчає методи автоматичного аналізу і генерації текстів.

ЦП - центральний процесор - основний обчислювальний пристрій комп'ютера.

API (Application Programming Interface) - програмний інтерфейс застосунків, набір визначень і протоколів для взаємодії між програмними компонентами.

BLEU (Bilingual Evaluation Understudy) - автоматична метрика оцінювання якості машинного перекладу на основі збігу n-грамів.

chrF++ (character n-gram F-score) - метрика оцінювання якості перекладу на основі символічних і словесних n-грамів.

LoRA (Low-Rank Adaptation) - метод параметро-ефективного донавчання нейронних мереж шляхом введення низькорангових матриць адаптації.

PEFT (Parameter-Efficient Fine-Tuning) - підхід до донавчання великих нейронних мереж, при якому оновлюється лише невелика частина параметрів.

QLoRA (Quantized LoRA) - варіант методу LoRA із квантизацією ваг ба-

зової моделі до 4 біт для зменшення вимог до пам'яті.

TER (Translation Edit Rate) - метрика оцінювання якості перекладу, що вимірює кількість редагувань, необхідних для приведення результату до еталонного.

ВСТУП

Актуальність теми. Українська мова існує в умовах значної варіативності: поряд із літературною нормою в різних регіонах побутують гуцульський, бойківський і закарпатський діалекти, а в містах широко вживається суржик - змішане українсько-російське мовлення. Масова внутрішня міграція після початку повномасштабного вторгнення 2022 року поглибила мовні контакти: люди з різними мовними звичками опиняються в одному середовищі, де діалектні та суржикові форми можуть ускладнювати ділову комунікацію, навчання і роботу з документами. Попри очевидну потребу, спеціалізованих автоматичних інструментів нормалізації регіональних діалектів і суржику в Україні майже немає: наявні системи орієнтовані переважно на орфографічні та граматичні помилки і не розраховані на систематичне перетворення діалектних форм на літературну норму.

Мета роботи - розробка та дослідження системи автоматичної нормалізації суржику і трьох регіональних діалектів (гуцульського, бойківського, закарпатського) до літературного стандарту сучасної української мови на основі нейронних моделей і підходів до роботи з малоресурсними даними.

Завдання дослідження:

- проаналізувати сучасні підходи до автоматичної нормалізації діалектних і гібридних мовних форм;
- обґрунтувати стратегію формування паралельного корпусу для чотирьох мовних різновидів з обмеженим обсягом ручної розмітки;
- зібрати і підготувати паралельний корпус для гуцульського, бойківського, закарпатського діалектів і суржику;
- навчити та порівняти дві моделі нормалізації - кодер-декодерну (umt5-base) і декодерну велику мовну модель (MamauLM) - на спільному багатодіалектному корпусі;
- оцінити якість навчених моделей у порівнянні з нуль-шотовими великими мовними моделями за метриками BLEU, chrF++ і TER;

- реалізувати прикладний вебзастосунок «Лексикон» із підтримкою голосового введення.

Об’єктом дослідження є процес автоматичної нормалізації нелітературних форм сучасної української мови - суржику та регіональних діалектів.

Предметом дослідження є методи формування паралельних корпусів для малоресурсних мовних варіантів, а також методи навчання нейронних моделей нейронного машинного перекладу і великих мовних моделей для задачі нормалізації.

Методи дослідження: аналіз і формування корпусів текстових даних; синтетична генерація паралельних прикладів за допомогою лінгвістичних правил, словникових ресурсів і великої мовної моделі; навчання кодер-декодерних трансформерних моделей; параметро-ефективне донавчання великих мовних моделей (QLoRA); автоматичне оцінювання якості за метриками BLEU, chrF++ і TER.

Наукова новизна роботи полягає в тому, що вперше запропоновано і досліджено єдину систему нормалізації одночасно для суржику і трьох регіональних діалектів. Для бойківського та закарпатського діалектів сформовано перші публічні синтетичні паралельні корпуси. Проведено порівняльне оцінювання кодер-декодерної та декодерної архітектур на задачі мультидіалектної нормалізації з залученням нуль-шотових великих мовних моделей як базових ліній.

Практична значущість роботи полягає у розробці вебзастосунку «Лексикон», що нормалізує тексти гуцульського, бойківського і закарпатського діалектів та суржику до літературної української мови з підтримкою голосового введення. Систему можна використовувати як самостійний інструмент або інтегрувати до ширших конвеєрів автоматичної обробки україномовних текстів.

1 ЗАГАЛЬНІ ПОЛОЖЕННЯ

1.1 Аналіз предметної галузі та літературних джерел

1.1.1 Нормалізація як задача між нейронним машинним перекладом і виправленням граматичних помилок

Автоматична нормалізація діалектних форм і суржику до літературної норми є задачею, що поєднує властивості двох напрямів обробки природної мови (ОПМ): нейронного машинного перекладу (НМП) та автоматичного виправлення граматичних помилок. Від НМП вона відрізняється тим, що перетворення відбувається між різновидами однієї мови: фонологічна, лексична та морфологічна системи діалекту частково збігаються з літературною нормою, а вхідний текст зазвичай залишається зрозумілим для носія стандарту. Від задачі виправлення граматичних помилок нормалізація відрізняється тим, що допустимі відхилення є системними - правильними в межах певного діалекту - а не випадковими помилками: регулярні фонетичні та лексичні трансформації не можна просто «виправити», не враховуючи діалектний контекст.

На практиці задача нормалізації може розв'язуватися трьома основними підходами, що еволюціонували від правилкових систем до нейронних. Правильові та словникові системи покладаються на явно задані відповідники між діалектними формами і літературними: словники заміни, регулярні перетворення морфем, фонетичні правила. Такі системи добре інтерпретовані, але погано масштабуються на нові домени і не охоплюють контекстно-залежних трансформацій. Моделі типу «послідовність-у-послідовність» на основі трансформера дозволяють навчити кодувально-декодуючу модель на паралельних даних «діалект → норма» і природно трактують задачу як переклад усередині мови. Великі мовні моделі (ВММ) з інструкційним донавчанням поєднують генеративну потужність авторегресійних моделей і гнучкість формату запиту, що дозволяє одній моделі нормалізувати кілька різновидів за умови явної вказівки типу задачі.

Роботи з НМП для діалектів підтверджують, що багатозадачне навчан-

ня, яке об'єднує кілька мовних різновидів в одну модель, дає кращі результати за умови обмежених даних: для арабських діалектів показано, що спільна модель стабілізує навчання і узагальнює спільні лінгвістичні закономірності [1.]. Для малоресурсних сценаріїв принципово важливо, що навіть невеликий обсяг якісних паралельних даних суттєво покращує якість відносно нуль-шотового застосування загальної моделі. Байтові підходи, як-от ВуТ5, зменшують залежність від словникових сегментацій і краще працюють із нестандартизованими текстами, що містять фонетичні відхилення [15.]. Для багатомовних сценаріїв важливою є також стратегія збалансованого вибору мов під час попереднього навчання, що впливає на якість для малоресурсних мов [3.].

1.1.2 Діалекти та суржик як об'єкти автоматичної нормалізації

Чотири мовні різновиди, що досліджуються в цій роботі, суттєво відрізняються за природою і ступенем систематизованості відхилень від літературної норми.

Гуцульський діалект поширений у гірських районах Карпат - Івано-Франківській, Закарпатській та Чернівецькій областях. Він є добре задокументованим: для нього наявні лінгвістичні описи, словники та паралельні корпуси. Гуцульський вирізняється специфічними голосними змінами (наголошені «а» та «я» переходять у «є»: «як» → «єк», «шапка» → «шепка»), особливою поведінкою зворотної частки (використовується «си» замість «ся» і може стояти перед дієсловом: «він сміється» → «він си сміє»), а також характерними відмінами дієслів третьої особи однини («знає» → «знаєт»). Наявність ручних паралельних даних і словника зробила гуцульський природною відправною точкою для побудови системи.

Бойківський діалект є одним із найархаїчніших в Україні - він зберігає риси давньоукраїнської мови і праслов'янські фонологічні елементи. Характерні ознаки: розрізнення переднього [и] і заднього [ы], що зникло в стандартній мові («бик» → «бык», «тихо» → «тыхо»); перехід [л] у [љ] у кінці складу («галка» → «гавка», «кіл» → «ків»); особові енклітики в умовному способі (-бим, -

бись, -бисьмо); архаїчні числівникові форми («дев'ятнадцять» → «двайцять без єнного»). Бойківський є найбільш лексично задокументованим серед чотирьох різновидів.

Закарпатський діалект вирізняється тривалим контактом із сусідніми мовами - словацькою, угорською та румунською. Збережено архаїчний звук [ы] як безпосередній продовжувач праслов'янського («мити» → «мыти», «дрова» → «дрыва»); характерні вокальні зсуви у закритих складах ([o] → [y]: «кінь» → «кунь»); запозичені частки угорського і румунського походження. Закарпатський - найскладніший для автоматичної нормалізації: велика лінгвістична відстань від норми і мала кількість ручних паралельних даних утруднюють навчання.

Суржик є принципово іншим явищем - це не регіональний діалект, а соціолінгвістичний феномен змішаного мовлення, поширений у центральних, східних і південних регіонах України. Носії суржику змішують лексичні, морфологічні та фонетичні елементи з обох мов, часто без чіткої регіональної прив'язки [6.]. Автоматичне розпізнавання суржику розглянуто в [13.]. Типові ознаки: лексичні заміни (але → но, дуже → очень, зупинка → остановка), зміна закінчень інфінітива (-ти → -ть: «робити» → «робить»), сполучникові кальки (якщо → если). Оскільки суржик не має єдиної фонологічної системи, його нормалізація потребує покриття широкого спектра лексичних і морфологічних замін.

1.1.3 Наявні ресурси та підходи до синтетичного розширення даних

Для задачі виправлення граматичних помилок в українській мові сформувалися перші систематичні ресурси. UA-GEC [14.] - перший публічний корпус для граматичної корекції та нормалізації флюентності в українській мові, що охоплює анотацію за типами помилок і дає базу для порівняльного аналізу методів. Багатомовний корпус OmniGEC [8.] розширив задачу на міжмовний рівень, запропонувавши срібну розмітку для кількох мов, включаючи українську. Інструкційно-донавчена модель «Співавтор» [12.] охоплює виправлення поми-

лок, перефразування, спрощення та покращення стилю в українських текстах і є одним із ключових джерел навчальних прикладів у цій роботі.

Діалектна нормалізація перетинається з цими задачами в частині вибору формату даних і методів навчання, але суттєво від них відрізняється: замість «помилки» маємо систематичні трансформації, правильні в межах діалекту. Критичним обмеженням є малоресурсність: для бойківського і закарпатського діалектів ручних паралельних даних майже не існує, а для суржику відсутній усталений стандарт розмітки.

Стандартним рішенням у малоресурсних сценаріях є синтетичне розширення корпусу. Дослідження синтетично згенерованих даних для українського виправлення граматичних помилок [2.] підтверджує, що якість синтетики суттєво залежить від правил навмисного введення відхилень і що моделі, навчені на синтетиці, можуть конкурувати з моделями на ручних даних за достатньої різноманітності прикладів. У цій роботі застосована схема «норма → нестандарт»: за відправну точку береться правильне літературне речення, після чого генерується його діалектний або суржиковий варіант. Перевага такого напрямку полягає в тому, що еталон гарантовано коректний від початку. Для суржику застосовано два незалежні підходи: правиловий через морфологічний аналізатор і генеративний за допомогою ВММ; для регіональних діалектів - лише генеративний із лінгвістичними правилами.

1.1.4 Сучасні україномовні моделі та найближчі суміжні роботи

Напрямок адаптації сучасних нейронних архітектур до української мови активно розвивається. Робота «Bytes to Borsch» [7.] дослідила донавчання моделей Gemma і Mistral для покращення україномовної репрезентації і показала, що цільове донавчання навіть порівняно невеликого обсягу помітно підвищує якість для задач розуміння і генерації. Відкрита україномовна ВММ LapaLLM [10.] побудована на базі Gemma-3-12B і оптимізована під українську через адаптацію токенизатора. MamaуLM [11.] - менша за параметрами (4 млрд), проте за результатами на стандартних тестах конкурентна модель, яка орієнто-

вана на практичне застосування і доступна через відкриту ліцензію. Для задачі підтримки україномовних текстів загалом важливими є також розвиток ресурсної бази мови [5.] та поєднання математичних моделей і машинного навчання для виявлення і виправлення помилок [4.]. Актуальним є і напрям оцінювання якості моделей від ручних ознак до великих мовних моделей [16.].

Найближчою до нашої постановки є робота «Vuyko Mistral: Adapting LLMs for Low-Resource Dialectal Translation» [9.]: у ній запропоновано методологію адаптації ВММ до малоресурсних діалектних сценаріїв, зокрема принципи формування паралельних корпусів і способи донавчання. Разом із тим, ця робота зосереджена на задачі перекладу з діалекту на інші мови, а не на нормалізації до єдиного літературного стандарту усередині мови. Крім того, набір досліджуваних різновидів і суржик як окреме явище в ній не охоплені. Запропонована нами система відрізняється: вона спрямована на нормалізацію чотирьох різновидів - гуцульського, бойківського, закарпатського діалектів і суржику - до літературного стандарту і побудована на власному паралельному корпусі, сформованому комбінацією ручної розмітки і синтетичної генерації.

Аналіз літератури засвідчує три ключових висновки: нормалізація діалектів і суржику методично близька до НМП і виправлення граматичних помилок, але потребує спеціалізованих ресурсів; за браку ручних даних синтетичне розширення через правила і ВММ є практичним рішенням; для українських діалектів і суржику публічних паралельних корпусів і спеціалізованих моделей нормалізації до цього часу не існувало.

1.2 Аналіз вхідних даних

Для задачі автоматичної нормалізації якість і репрезентативність навчальних даних є визначальними. На відміну від класичного НМП між різними мовами, тут маємо справу з мовними різновидами однієї мови, де межа між «помилкою», «локальною нормою» та «варіантом написання» часто розмита. Тому до корпусу ставляться додаткові вимоги: узгоджені еталони, прозорий поділ на навчальну, валідаційну та тестову вибірки, контроль джерел (ручні чи синтетичні

пари) і баланс між чотирма мовними різновидами.

У роботі застосовано комбінований підхід: як опорну базу взято ручні паралельні дані для гуцульського діалекту; для решти діалектів і суржику корпус сформовано синтетично - за допомогою лінгвістичних правил і великої мовної моделі; як джерело різноманітних літературних цільових речень для суржику використано корпус «Співавтор» [12.].

1.2.1 Лінгвістична характеристика мовних різновидів

Для побудови ефективного синтетичного генератора і розуміння природи труднощів задачі нормалізації необхідно систематизувати лінгвістичні особливості кожного мовного різновиду.

Гуцульський діалект. На рівні голосних: наголошені «а» і «я» регулярно переходять у «є» («як» → «єк», «шапка» → «шепка», «яблуко» → «єблуко»); «і» в окремих позиціях переходить у «и» («Іван» → «Иван», «іду» → «иду»); «ю» переходить у «у» («вівцю» → «вівцу»). На рівні приголосних: зворотна частка змінюється з «ся» на «си» і може стояти перед дієсловом («він сміється» → «він си сміє»); сибілянти пом'якшуються («чого» → «чьо»); «ч» та «ц» можуть замінювати одна одну («чи» → «ци»); групи «дн», «тн», «лн» спрощуються до «нн» або «н» («передній» → «перенний»). На морфологічному рівні: дієслова третьої особи однини отримують закінчення -єт («знає» → «знаєт», «має» → «маєт»); у минулому часі можливі аналітичні форми з енклітиками («ходив» → «ходив'єм»); прийменник «від» переходить у «вид»; заперечна частка «не» переходить у «ни» («не знаю» → «ни знаю»).

Бойківський діалект. Є одним із найархаїчніших в Україні і зберігає риси давньоукраїнської мови. Головна фонологічна риса - розрізнення переднього [и] і заднього [ы], яке зникло в стандартній мові: «бик» → «бык», «тихо» → «тыхо», «дівки» → «дівкы». Інша характерна риса - перехід [л] у [љ] у кінці складу: «галка» → «гавка», «кіл» → «ків». На морфологічному рівні: спрощення груп приголосних («бідна» → «бінна», «весілля» → «весіля»); особові енклітики в умовному способі («ходив би» → «ходивбим»); архаїчна форма третьої

особи множини «суть»; унікальні числівникові конструкції («дев'ятнадцять» → «двайцять без єнного»); м'яке вимовляння сибілянтів ([ж], [ш], [ч]). Словник бойківського є найобширнішим серед чотирьох різновидів і містить 14 910 записів.

Закарпатський діалект. Визначається поєднанням архаїчних праслов'янських рис і запозичень із сусідніх мов. Архаїчний задній голосний [ы] збережено як безпосередній продовжувач праслов'янського звуку: «мити» → «мыти», «синок» → «сынок», «дрова» → «дрыва». Характерні вокальні зсуви у закритих складах: [о] переходить у [у] або [ү] («кінь» → «кунь», «стіл» → «сціл»). З угорської запозичено порівняльну частку «тај» і розділовий сполучник «вад'»; з румунської - «хот'» для поступки. Займенникова система відрізняється від стандартної: демонстративні займенники «тот»/«тота» замість «той»/«та». Велика лінгвістична відстань між закарпатськими формами і літературною нормою обумовлює найнижчу якість нормалізації серед чотирьох різновидів.

Суржик. На відміну від діалектів, суржик не є регіональним явищем зі сталою фонологічною системою: кожен носій демонструє власний ступінь і спосіб змішування мов [6.]. Водночас існують повторювані риси: лексичні заміни (але → но, дуже → очень, зупинка → остановка, майже → почті); зміна закінчення інфінітива («робити» → «робить», «ходити» → «ходить»); сполучникові кальки («якщо» → «єслі», «тому що» → «потому шо»); дискурсні маркери («ось» → «вот», «звичайно» → «конєшно»). Стратегія синтетичної генерації суржику полягала у застосуванні 1-3 типових заміन на речення для отримання природного, а не карикатурного змішування.

1.2.2 Ресурси для гуцульського діалекту

Гуцульський діалект обрано відправною точкою, бо для нього доступні найбільш повні ресурси: вручну анотований паралельний корпус, синтетично згенерований корпус і діалектний словник (рис. 1.1). Ручний корпус містить 9 853 пари «гуцульська форма → літературний відповідник» і є основою для

формування тестової вибірки - саме на цих даних метрики відображають реальну якість системи, а не якість генератора синтетики.




Рис. 1.1: Гуцульські ресурси на платформі Hugging Face: датасети та допоміжні матеріали, що використовувались як вихідні джерела.

Ручний корпус доповнено синтетично згенерованими парами: за допомогою моделі Mistral Small 24B з лінгвістичними правилами гуцульського діалекту отримано 19 841 пару. Таким чином, загальний обсяг гуцульської підвибірки в навчальному наборі склав 29 438 прикладів.

Діалектний словник виконував кілька функцій: слугував джерелом лексичних відповідників під час синтетичної генерації, обмежував простір допустимих діалектних заміन і використовувався для валідації згенерованих пар - якщо у вхідному тексті були діалектні слова, перевірялась їх наявність у словнику. Словник містить 7 320 записів у форматі «діалектна форма - стандартна форма - словникова лема».

На рис. 1.2 показано приклад вмісту вручну анотованого корпусу: кожен рядок містить вхідний діалектний текст і відповідний літературний еталон. У задачі нормалізації один діалектний вираз може мати кілька допустимих літературних варіантів, тому ручна розмітка фіксує один узгоджений еталон.

1.2.3 Корпус «Співавтор» як джерело літературної норми

Для суржику еталонні речення літературної норми взято з корпусу «Співавтор» (рис. 1.3) - набору пар редагування і перефразування українською мовою,

target	source
Всій пропій був на конех, буйних, золотогривих та груднистих.	Весь пропій був на конях – буйних, золотогривих і груднастих.
До надвірної роботи уни си нам ни чепали.	До надвірної роботи вони не бралися.
Ти пий аді воду.	Ти пий, ади, воду.
Тай пишов з тим усім надвір.	І пішов з тим усім надвір.
Хліви, що наоколо оповивали иззаду хати и обі кліти з боків, запахом овечього гною дихали.	Хліви, що наоколо оповивали ззаду хати й обидві кліті з боків, дихали запахом овечього гною.
З глибокого ізвора долітав до мене вічний шум потоків.	З глибокого звору долітав до мене вічний шум потоків.
Таже най ти доповістуй лиш за Олексія, то зараз уздриш, ек то є.	Таж розповім лиш про Олексія, то зараз побачиш, як то є.

Рис. 1.2: Вміст вручну анотованого паралельного корпусу для гуцульського діалекту: стовпці вхідного тексту та еталонного відповідника.

що охоплює виправлення граматичних помилок, перекладування і спрощення тексту [12.]. У контексті цієї роботи «Співавтор» використовувався не як діалектний ресурс, а як пул стилістично природних літературних речень: з нього відбирались цільові речення, на основі яких генерувався суржиковий варіант.

Практична логіка така: обирається літературне речення y зі «Співавтора», після чого генерується суржиковий варіант x . Таким чином пара (x, y) гарантовано має якісний еталон. Перевага такого підходу полягає ще й у тому, що «Співавтор» містить широкий спектр природних речень із різних доменів - новини, побутові тексти, публіцистика, - що забезпечує доменну різноманітність навчальних прикладів для суржику.

1.2.4 Словникова база мовних різновидів

Для кожного з чотирьох мовних різновидів зібрано словники відповідників між діалектними і стандартними формами. Словники виконували подвійну роль у системі: слугували джерелом прикладів для шаблонів запитів до ВММ та засобом контролю якості згенерованих пар. Основні характеристики словників наведено в таблиці 1.

Бойківський словник є найбільшим (14 910 записів), що відображає значну лексичну відстань між бойківськими формами і стандартом. Словник суржику суттєво менший (570 записів), оскільки основні відхилення суржику є

Datasets: [grammarly/spivavtor](#) like 5 Follow Grammarly 200 Dataset card

Split (2)
train · 62.8k rows

Search this dataset

id	src	tgt	task
int64	string · lengths	string · lengths	string · classes
1e6.28k	10%	99*176 34.3%	77*153 29.8%
			44.5%
1	Перефразуйте: Кайс став одержимий нещодавно усвідомленою вразливістю.	Кайс був одержимий своєю нововиявленою вразливістю.	paraphrase
2	Перепишіть речення іншими словами: І вона більше не думатиме про Джонні Сміта та його...	Джонні Сміт і його дивна чарівна посмішка, про яку він ніколи більше не згадав.	paraphrase
3	Виправити граматику: 3 простими, там, поїсти, поспати не важко.	3 простими, там, поїсти, поспати не важко.	grec
4	Виправте всі граматичні помилки: Тоді як ДНК має дві спіралі – інформаційний ряд...	Тоді як ДНК має дві спіралі – інформаційний ряд з'єднаний з комплементарним йому іншим...	grec
5	Зробіть цей текст легше для розуміння: Ви в дуже серйозній біді, містере Штайнфелд.	Містере Штайнфелд, у вас великі проблеми.	simplification
6	Виправте зв'язність в цьому тексті: англіканство вперше прийшло до Бразилії на...	Англіканство вперше прибуло до Бразилії на початку 19 століття, коли португальська...	coherence
7	Покращте зв'язність тексту: пісні у стилі блек-метал часто відрізняються від...	Блек-метал-пісні часто відрізняються від традиційної структури пісень і часто не...	coherence
8	Виправити граматику: Іван побачив сірий берет в гуші на початку Великої Микитської,...	Іван побачив сірий берет у гуші на початку Великої Микитської, але Герцена.	grec

< Previous 1 2 3 ... 628 Next >

Рис. 1.3: Приклад вмісту корпусу «Співавтор»: вхідний і відредагований текст із міткою типу завдання.

морфологічними і фонетичними (зміна закінчень, фонетичні кальки), а не лексичними замінами: для таких перетворень застосовується морфологічний аналізатор, а не словникова таблиця. Під час синтетичної генерації до кожного запиту включалось 3-5 прикладів із відповідного словника, що допомагало моделі дотримуватися лінгвістичного стилю конкретного діалекту.

1.2.5 Синтетична генерація даних

Для більшості мовних різновидів ручних паралельних даних критично мало, тому синтетичне розширення є необхідним. У роботі застосовано підхід «норма → нестандарт»: за вхідний еталон y береться літературне речення, а нестандартний варіант x генерується. Це зручно, бо якість еталону гарантована від початку.

Правилова генерація суржику. Реалізовано двофазову заміну. На першій фазі здійснюється фразова заміна: за допомогою регулярних виразів виявляються найдовші збіги із словником багатослівних суржикових конструкцій і за-

Таблиця 1: Словники діалектних відповідників

Мовний різновид	Записів	Формат запису
Гуцульський	7 320	Діалектна форма, стандартна форма, лема
Бойківський	14 910	Діалектна форма, стандартна форма, лема
Закарпатський	7 469	Діалектна форма, стандартна форма, лема
Суржик	570	Суржикова форма, стандартна форма

мінюються їхніми еквівалентами (наприклад, «тому що» → «потому що»). Ця фаза обробляє контекстні сполучення до розбиття тексту на окремі слова. На другій фазі виконується морфологічна заміна на рівні слів: кожне слово лематизується через бібліотеку морфологічного аналізу `ru morphology2`, і якщо словникова лема входить до списку заміन суржику, відповідне слово замінюється з урахуванням граматичних категорій - відмінку, числа і роду. Такий підхід забезпечує не просто лексичну, а морфологічно узгоджену заміну і дав 20 911 прикладів.

Генерація за допомогою ВММ. Застосована для всіх чотирьох мовних різновидів. Для кожного діалекту підготовлено окремий системний запит, що містить лінгвістичний опис типових рис, 3-5 демонстраційних пар зі словника та інструкцію щодо кількості і стилю замінів. Велика мовна модель `Mistral Small 24B` (4-бітна квантизація для локальної інференції) обробляла пакети по 5-10 речень і повертала діалектні варіанти.

Контроль якості синтетичних пар проводився після кожного пакету: видалялись дублікати (однакові вхідні або еталонні тексти), відкидались надто короткі (менше трьох слів) та надто довгі пари, перевірялась наявність діалектних слів зі словника у вхідному тексті, вибірково проводився ручний перегляд для оцінки типових артефактів генерації - змішування мов, незавершених речень, залишків форматування у відповіді.

1.2.6 Формування та структура фінального корпусу

Після генерації всіх складових дані об'єднано в єдиний корпус і розділено на три вибірки. Загальна структура наведена в таблиці 2.

Таблиця 2: Склад паралельного корпусу по мовних різновидах

Різновид	Ручні	LLM	Правилові	Разом
Гуцульський	9 853	19 841	-	29 694
Бойківський	-	29 754	-	29 754
Закарпатський	-	29 605	-	29 605
Суржик	-	29 612	20 911	50 523
Разом	9 853	108 812	20 911	139 576

Після формування загального об'єднаного набору 90% прикладів виділено у навчальну вибірку (125 615 прикладів), 10% - у валідаційну (13 756 прикладів). Тестова вибірка з 200 прикладів (по 50 на кожен мовний різновид) сформована виключно з вручну анотованих пар, що забезпечує об'єктивність оцінювання і виключає вплив якості синтетичного генератора на тестові метрики.

Ключовий принцип організації: тестова і валідаційна вибірки формуються лише з ручних пар, синтетика використовується виключно в навчальній вибірці. Це дозволяє уникнути переоцінки якості на штучних прикладах і отримувати метрики, близькі до реального застосування. Структуру директорій репозиторію і розміщення файлів корпусу показано на рис. 1.4.




Рис. 1.4: Структура директорій проєкту: словники, ручні корпуси, синтетичні дані та фінальні вибірки для навчання, валідації і тестування.

1.3 Висновки до розділу 1

У розділі проаналізовано предметну галузь, розглянуто суміжні дослідження та сформовано корпус для навчання системи.

Нормалізація діалектів і суржику є задачею на межі між НМП і виправле-

нням граматичних помилок: тут присутні як систематичні лексичні заміни, так і фонетичні та морфологічні трансформації регулярного характеру. Аналіз літератури показав: для малоресурсних сценаріїв синтетичне розширення даних і донавчання ВММ є ефективними підходами, а для українських діалектів і суржику до цього часу не існувало спеціалізованих паралельних корпусів і моделей нормалізації.

Чотири досліджуваних різновиди суттєво відрізняються за природою відхилень: гуцульський і бойківський є регіональними діалектами з архаїчними фонологічними рисами, закарпатський демонструє контактний вплив суміжних мов, суржик є соціолінгвістичним явищем змішаного мовлення.

Зібрано паралельний корпус із 139 576 прикладів загалом, з яких 125 615 увійшли до навчальної вибірки. Для гуцульського діалекту використано ручний корпус (9 853 пари) і словник (7 320 записів). Для бойківського і закарпатського словники містять 14 910 і 7 469 записів відповідно. Суржиковий корпус отримано поєднанням правилowego підходу (20 911 прикладів) і генерації за допомогою ВММ (29 612). Тестові вибірки сформовано виключно з ручних пар, що забезпечує надійне оцінювання якості у наступних розділах.

2 ІНФОРМАЦІЙНЕ ТА МАТЕМАТИЧНЕ ЗАБЕЗПЕЧЕННЯ

Розділ охоплює математичну постановку задачі нормалізації, опис двох реалізованих архітектур, обґрунтування вибору моделей і конфігурацій навчання, а також метрики оцінювання. Загальну схему системи показано на рис. 2.1.




Рис. 2.1: Загальна схема системи «Лексикон»: генерація корпусу (правилова та LLM-генерація), навчання двох моделей (umt5-base і MatayLM), оцінювання на ручній тестовій вибірці та демонстраційний вебзастосунок (NiceGUI + FastAPI).

2.1 Аналіз підходів до нормалізації

2.1.1 Нормалізація як задача перетворення тексту

Нормалізацію діалектних форм і суржику розглядаємо як кероване перетворення тексту: необхідно зберегти зміст, але змінити форму відповідно до літературної норми. Такі перетворення охоплюють лексичні заміни (діалектизми), варіативну орфографію, фонетично мотивовані написання, а у суржику - ще й перемикування між мовами на рівні лексики.

Формально маємо вхідний рядок x (діалект або суржик) та бажаний вихідний рядок y (літературна українська). Мета - побудувати модель f_θ , що апроксимує відображення:

$$f_\theta : x \mapsto y$$

З погляду статистичного моделювання це еквівалентно оцінюванню умовного розподілу $p_\theta(y|x)$.

Практичні особливості задачі:

- *Часткова тотожність*: значна частина лексем у x може збігатися з y , особливо у суржику;

- *Асиметрія*: «виправляти занадто багато» ризикує спотворити зміст, «виправляти занадто мало» - не виконати нормалізацію;
- *Багатоваріантність норми*: одна діалектна форма може відповідати кільком літературним парафразам;
- *Низькоресурсність*: для більшості діалектів немає великих вручну розмічених паралельних корпусів.

2.1.2 Правиліві підходи та їх обмеження

Правилова нормалізація використовує словники відповідників, регулярні правила перетворень та евристики. Її перевага - контрольованість: якщо відомі правила заміни, можна гарантувати певну поведінку. Для словників, описаних у підрозділі 1.2.4, кожен запис задає відповідність між нестандартною і літературною формами. Попри це правилівий підхід має системні обмеження:

- складно охопити всю лексичну варіативність без великого словника;
- важко коректно обробляти контекстні значення (омонімія, полісемія);
- правила погано підходять для довгих залежностей та синтаксичних перестроїв;
- якість деградує при зміні домену (побутові повідомлення, конспекти, оголошення).

У цій роботі правиліві ресурси відіграють допоміжну роль: (а) для побудови синтетичних навчальних даних; (б) для підказок під час LLM-генерації синтетики; (в) як інструмент аналізу помилок.

2.1.3 Нейромережеві підходи: кодер-декодерна модель і декодерна ВММ

У роботі послідовно застосовано дві парадигми нейромережевого підходу.

Кодер-декодерна модель для базової перевірки на гуцульському. Переваги:

- стабільне навчання на паралельних даних;
- природна постановка: вхідний текст → нормалізований текст;
- компактний розмір (≈ 300 млн параметрів) дозволяє повне донавчання на

одному ГП.

**Декодерна ВММ з інструкційним форматом для всіх діалектів і сур-
жику.** Переваги:

- одна модель обробляє всі чотири різновиди через маркер у запиті;
- використання мовних знань моделі (≈ 4 млрд параметрів) для кращого розуміння контексту;
- природне розширення на нові задачі без зміни архітектури.

Для декодерної парадигми обрано MatayLM - відкриту україномовну ВММ на базі Gemma-3-4B, оптимізовану для інструкційного виконання задач [11.].

2.2 Постановка задачі та математична модель

2.2.1 Формальна постановка нормалізації

Нехай Σ - алфавіт символів (або множина лексем після токенізації). Вхідний текст:

$$x = (x_1, x_2, \dots, x_{|x|}), \quad x_i \in \Sigma$$

вихідний текст (літературна норма):

$$y = (y_1, y_2, \dots, y_{|y|}), \quad y_j \in \Sigma$$

Задача - знайти параметри θ , що максимізують правдоподібність навчальних пар $\{(x^{(k)}, y^{(k)})\}_{k=1}^N$:

$$\theta^* = \arg \max_{\theta} \sum_{k=1}^N \log p_{\theta}(y^{(k)} | x^{(k)}) \quad (1)$$

У практичній реалізації мінімізується негативний лог-правдоподібний - крос-ентропія:

$$L(\theta) = - \sum_{k=1}^N \log p_{\theta}(y^{(k)} | x^{(k)}) \quad (2)$$

2.2.2 Формат даних для двох архітектур

Кодер-декодерна модель. Дані зберігаються у вигляді пар «вхідний текст - еталон». Після токенизації отримуємо послідовності індексів $x = (x_1, \dots, x_T)$, $y = (y_1, \dots, y_{T'})$. Модель навчається прогнозувати y_t з урахуванням усього вхідного тексту та попередніх виходів:

$$p_\theta(y|x) = \prod_{t=1}^{T'} p_\theta(y_t|x, y_{<t}) \quad (3)$$

Декодерна ВММ. Задачу представляємо як інструкцію з трьома ролями: «система», «користувач» і «асистент». Вхідний текст передається у ролі «користувач», нормалізована форма - у ролі «асистент». Об'єднана послідовність лексем $z = (z_1, \dots, z_{|z|})$ включає всі три ролі. Функція втрат обчислюється лише на лексемах відповіді «асистент»:

$$L_{mask} = - \sum_{t=1}^{|z|} m_t \log p_\theta(z_t|z_{<t}) \quad (4)$$

де $m_t \in \{0, 1\}$ - маска (1 лише на позиціях відповіді «асистент»). Приклад шаблону інструкційного запиту наведено на рис. 2.2.

```
* System: "Ти нормалізуєш діалект/суржик до літературної української. Зберігай зміст. Не додавай зайвого."  
* User: "[ДІАЛЕКТ=ГУЦУЛЬСЬКИЙ] ...текст..."  
* Assistant: "...нормалізований текст..."
```

Рис. 2.2: Шаблон інструкційного запиту для декодерної ВММ: ролі системи, користувача та асистента з маркером діалекту.

2.2.3 Цільова функція: крос-ентропія і згладжування міток

Поелементна крос-ентропія для кодер-декодерної моделі:

$$L_{CE} = - \frac{1}{T'} \sum_{t=1}^{T'} \log p_\theta(y_t|x, y_{<t}) \quad (5)$$

Для umt5-base застосовано згладжування міток із коефіцієнтом $\alpha = 0.1$.

Ідея: замість жорсткого розподілу (1 для правильної лексеми, 0 для решти) навчаємо на розм'якшеному розподілі:

$$L_{smooth} = (1 - \alpha) \cdot L_{CE} + \frac{\alpha}{|V|} \sum_{v \in V} \log p_{\theta}(v|x, y_{<t}) \quad (6)$$

де V - словник моделі, $|V|$ - його розмір. Згладжування міток запобігає надмірній впевненості моделі та покращує узагальнення на нові приклади.

2.3 Математичні основи трансформера

2.3.1 Механізм уваги

Основою обох архітектур є трансформер із механізмом уваги. Нехай на вході є матриця представлень $H \in \mathbb{R}^{T \times d}$. Обчислюються запит, ключ і значення:

$$Q = HW_Q, \quad K = HW_K, \quad V = HW_V$$

де $W_Q, W_K, W_V \in \mathbb{R}^{d \times d_k}$ - навчані матриці проєкцій.

Увага:

$$\text{Увага}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V \quad (7)$$

Масштабування на $\sqrt{d_k}$ стабілізує градієнти при великих розмірностях. Багатоголова увага поєднує h незалежних голів:

$$\text{БГУ}(H) = \text{Concat}(\text{голова}_1, \dots, \text{голова}_h)W_O \quad (8)$$

де $\text{голова}_i = \text{Увага}(HW_{Q_i}, HW_{K_i}, HW_{V_i})$.

2.3.2 Позиційне кодування, нормалізація шарів і прямо зв'язний блок

Трансформер не має вбудованого поняття порядку - для збереження позиційної інформації до вхідних представлень додається позиційне кодування. У класичній синусоїдальній схемі:

$$PE(pos, 2i) = \sin\left(\frac{pos}{10000^{2i/d}}\right), \quad PE(pos, 2i + 1) = \cos\left(\frac{pos}{10000^{2i/d}}\right) \quad (9)$$

де pos - позиція лексеми в послідовності, i - індекс розмірності, d - розмірність моделі. Такий підхід дозволяє розрізняти відносні відстані між лексемами без введення додаткових параметрів. У сучасних архітектурах, зокрема Gemma-3 (основа MambaLM), замість синусоїдального застосовується ротаційне позиційне кодування (RoPE), яке краще узагальнюється на довші послідовності.

Кожен підшар трансформера (увага або прямозв'язний блок) доповнюється залишковим з'єднанням і нормалізацією шарів:

$$x' = \text{LayerNorm}(x + \text{Sublayer}(x)) \quad (10)$$

де Sublayer - або увага, або прямозв'язний блок. Залишкове з'єднання $x + \text{Sublayer}(x)$ полегшує прямий потік градієнта через глибоку мережу і запобігає деградації навчання при великій кількості шарів.

Прямозв'язний блок (FFN), розташований після шару уваги в кожному блоці трансформера:

$$\text{FFN}(x) = \max(0, xW_1 + b_1) W_2 + b_2 \quad (11)$$

де $W_1 \in \mathbb{R}^{d \times d_{ff}}$, $W_2 \in \mathbb{R}^{d_{ff} \times d}$, а d_{ff} - внутрішня розмірність (зазвичай $4d$). Нелінійність ReLU ($\max(0, \cdot)$) дозволяє FFN зберігати фактичні знання про мову, тоді як механізм уваги відповідає за зв'язки між позиціями послідовності.

2.3.3 Кодер-декодерна архітектура

Кодер перетворює вхідну послідовність x у контекстні представлення $E \in \mathbb{R}^{T \times d}$ за допомогою стеку шарів: самоувага $\rightarrow$ нормалізація $\rightarrow$ прямозв'язний блок $\rightarrow$ нормалізація. Декодер генерує вихідну послідовність y , використовуючи:

- самоувагу по вже згенерованих лексемах $y_{<t}$;
- перехресну увагу до контекстних представлень E .

Умовна авторегресійна генерація:

$$p_{\theta}(y|x) = \prod_{t=1}^{T'} p_{\theta}(y_t|x, y_{<t}) \quad (12)$$

Базову кодер-декодерну модель umt5-base навчено спочатку на гуцульському діалекті. Графік навчання наведено на рис. 2.3, результати оцінювання - на рис. 2.4.




Рис. 2.3: Темп навчання та функція втрат umt5-base під час донавчання на гуцульському діалекті (перший, одnodіалектний етап).




Рис. 2.4: Метрика BLEU (ліворуч) та функція втрат на валідаційній вибірці (праворуч) для гуцульського базового навчання umt5-base.

2.3.4 Авторегресійна декодерна модель

Декодерна ВММ моделює об'єднану послідовність лексем z (система + запит + відповідь) авторегресивно:

$$p_{\theta}(z) = \prod_{t=1}^{|z|} p_{\theta}(z_t | z_{<t}) \quad (13)$$

Усі лексеми обробляються в одному прямому проходженні, але функція втрат (4) оптимізується лише за лексемами відповіді «асистент». Завдяки цьому модель залишається загальною мовною моделлю, але спеціалізується на конкретній задачі нормалізації.

2.4 Вибір та обґрунтування моделей

2.4.1 Кодер-декодерна модель *umt5-base*

Для базової перевірки та кодер-декодерного підходу обрано *google/umt5-base* - багатомовну T5-модель (≈ 300 млн параметрів), натреновану на 100+ мовах включно з українською [3.]. Причини вибору:

1. Попереднє тренування охоплює значний обсяг українського тексту.
2. Кодер-декодерна архітектура природно підходить для нормалізації як «перекладу».
3. ≈ 300 млн параметрів дозволяє повне донавчання на одному ГП.
4. Відтворюваність: модель відкрита, розміщена у сховищі Hugging Face.

Перший етап - навчання лише на гуцульському діалекті - слугував базовою лінією. Гуцульський обрано через найбільший обсяг ручної розмітки (9 853 пари) та наявність детального словника. Мета: перевірити паралельні дані, конвеєр токенизації і навчання, а також встановити відправну точку для порівняння при переході до мультидіалектної задачі. Графік навчання (рис. 2.3) показує стабільне зниження функції втрат, BLEU на валідаційній вибірці стабілізується приблизно на рівні 51, що підтверджує коректність реалізованого конвеєра.

Другий етап - мультидіалектне навчання - об'єднує всі чотири різновиди в одному корпусі (125 тис. прикладів). Спільна модель вчиться вирізняти між діалектами за допомогою системного маркера в запиті, переданому разом із текстом. Кодер-декодерна архітектура виграє від того, що кодер обробляє вхідний текст паралельно і незалежно від довжини виходу - це стабілізує навчання на різномірних парах (суржик з мінімальними замінами vs. гуцульський з фонетичними змінами).

2.4.2 Декодерна BMM MatayLM

Для мультидіалектного підходу і суржику обрано MatayLM - декодерну BMM на базі Gemma-3-4B (≈ 4 млрд параметрів), адаптовану для української [11.]. Причини вибору над іншими варіантами:

1. **Розмір:** 4 млрд параметрів (проти, наприклад, 12 млрд у Gemma-3-12B) дозволяє QLoRA-донавчання на одному ГП із 24 ГБ відеопам'яті.
2. **Українська мова:** модель оптимізована для задач на українській, зокрема для інструкційного виконання.
3. **Відкрита ліцензія:** результати можна публікувати і відтворювати.
4. **Інструкційна версія:** підтримує чат-шаблон (система/користувач/асистент), що спрощує навчання одночасно на чотирьох різновидах.

Інструкційний формат дозволяє явно вказувати тип завдання через маркер у ролі «система»: нормалізація гуцульського, бойківського, закарпатського або суржику. Таким чином одна модель розв'язує чотири окремі підзадачі.

2.4.3 Параметро-ефективне донавчання: LoRA та QLoRA

Повне донавчання моделі з мільярдами параметрів вимагає значних обчислювальних ресурсів. Для MatayLM застосовано LoRA - метод низькорангової адаптації (рис. 2.5).

Нехай у трансформері є матриця ваг $W \in \mathbb{R}^{d \times k}$. LoRA додає низькоран-

гову поправку:

$$W' = W + \Delta W = W + BA \quad (14)$$

де $B \in \mathbb{R}^{d \times r}$, $A \in \mathbb{R}^{r \times k}$, $r \ll \min(d, k)$. Кількість тренованих параметрів скорочується з dk до $r(d + k)$. При $r = 16$ для шару розміром 4096×4096 : замість ≈ 16.8 млн тренується лише ≈ 131 тис. параметрів.

Масштабуючий коефіцієнт регулює величину поправки:

$$s = \frac{\alpha}{r} = \frac{32}{16} = 2 \quad (15)$$

Цільові модулі LoRA: проєкції уваги (q_proj, k_proj, v_proj, o_proj) та прямозв'язні шари (gate_proj, up_proj, down_proj).

QLoRA доповнює LoRA 4-бітним квантуванням базової моделі у форматі NF4 (Normal Float 4) із збереженням адаптерів у bfloat16. Подвійне квантування (Double Quantization) квантує і самі коефіцієнти квантування, зменшуючи споживання ОП ще приблизно на 0.37 біт на параметр. Разом QLoRA дозволяє донавчати 4B-модель у межах 24 ГБ відеопам'яті.




Рис. 2.5: Ілюстрація LoRA: вихідні ваги W заморожені, а низькорангова поправка BA додається у шарах уваги та прямозв'язних блоках.

2.5 Гіперпараметри та конфігурація навчання

2.5.1 Донавчання *umt5-base*

Усі гіперпараметри донавчання *umt5-base* наведено у табл. 3.

Таблиця 3: Гіперпараметри донавчання *umt5-base*

Параметр	Значення
Базова модель	google/umt5-base
Кількість параметрів	≈ 300 млн
Кількість епох	40
Розмір пакету (накопичення: 4)	4 (ефективний: 16)
Темп навчання	5×10^{-5}
Планувальник темпу	косинусний спад
Кроки прогріву	$\min(1000, 0.1 \times N_{steps})$
Оптимізатор	AdamW 8-bit (BitsAndBytes)
Згладжування міток (α)	0.1
Спадання ваг	0.1
Числовий формат	bfloat16
Макс. довжина послідовності	256 лексем
Ранній зупин	терпіння 5 епох (за BLEU)
Заповнення	до кратного 8 лексем

Вибір темпу навчання 5×10^{-5} відповідає рекомендованому діапазону для повного донавчання T5-сімейства: вищі значення ризикують руйнуванням попередньо навчених представлень (catastrophic forgetting), нижчі уповільнюють збіжність на малих корпусах. Косинусний спадаючий планувальник забезпечує плавне зниження темпу навчання до нуля до кінця навчання, уникаючи різких стрибків.

Кількість епох (40) дещо більша, ніж у стандартних задачах нейронного машинного перекладу, де зазвичай достатньо 10-15 епох. Нормалізація діалектів має меншу кількість навчальних прикладів і потребує більше оновлень для якісного засвоєння. Ранній зупин із терпінням 5 епох за метрикою BLEU на валідаційній вибірці запобігає перенавчанню: якщо BLEU не покращується протягом 5 послідовних епох, навчання припиняється і зберігається найкраща контрольна точка.

8-бітний AdamW через BitsAndBytes зменшує споживання відеопам'яті

оптимізатором приблизно у 4 рази порівняно зі стандартним 32-бітним AdamW, не впливаючи помітно на якість. Заповнення до кратного 8 лексем прискорює матричні операції на ГП завдяки вирівнюванню пам'яті.

2.5.2 Донавчання MatayLM (QLoRA)

Повна конфігурація донавчання MatayLM наведена у табл. 4.

Таблиця 4: Гіперпараметри донавчання MatayLM (QLoRA)

Параметр	Значення
Базова модель	MatayLM-Gemma-3-4B-IT-v1.0
Кількість параметрів	≈ 4 млрд
Кількість епох	3
Розмір пакету (накопичення: 2)	1 (ефективний: 2)
Темп навчання	2×10^{-4}
Планувальник темпу	косинусний спад
Частка прогріву	0.03
Оптимізатор	AdamW 8-bit (Unsloth)
Ранг LoRA (r)	16
Масштаб LoRA (α)	32
Відсів LoRA (dropout)	0.0
Квантування	NF4, 4-bit, подвійне
Числовий формат	bfloat16
Макс. довжина послідовності	512 лексем
Пакування послідовностей	так

Параметри генерації під час оцінювання MatayLM: температура = 0.1, top-k = 25, top-p = 1.0, максимальна кількість нових лексем = 256, штраф за повтори = 1.1.

Темп навчання 2×10^{-4} для QLoRA вищий, ніж для повного донавчання umt5-base. Це обґрунтовано тим, що LoRA-адаптери ініціалізуються з нуля (матриця B - нулями, A - малим гаусівським шумом) і не мають попередньо навченого стану, який можна пошкодити. Водночас заморожені ваги базової моделі не змінюються, тому ризик руйнування мовних знань відсутній.

Три епохи достатні для задачі нормалізації завдяки тому, що базова модель MatayLM вже добре знає українську - залишається лише сформувати стиль відповіді. Більша кількість епох ризикує переспеціалізувати модель під

конкретні приклади навчальної вибірки, погіршуючи узагальнення на нових текстах.

Пакування послідовностей (`packing=True`) об'єднує кілька коротких прикладів в одну послідовність максимальної довжини 512 лексем. Це знижує частку заповнювальних лексем (`padding`) у пакеті та підвищує ефективне використання ГП: замість навчання на переважно порожніх пакетах модель отримує більше фактичного навчального сигналу за той самий час.

2.6 Метрики оцінювання

2.6.1 BLEU

BLEU (Bilingual Evaluation Understudy) оцінює схожість згенерованого тексту з еталоном через модифіковану n-грамну точність [16.]:

$$\text{BLEU} = BP \cdot \exp\left(\sum_{n=1}^N w_n \log p_n\right) \quad (16)$$

де p_n - модифікована точність n-грам, $w_n = 1/N$ - рівні ваги, BP - штраф за стислість:

$$BP = \begin{cases} 1, & |\hat{y}| > |y| \\ \exp\left(1 - \frac{|y|}{|\hat{y}|}\right), & |\hat{y}| \leq |y| \end{cases} \quad (17)$$

де $|\hat{y}|$ - довжина згенерованого тексту, $|y|$ - довжина еталону.

У роботі обчислюється `corpus_bleu` із бібліотеки `SacreBLEU`. Значення BLEU є критерієм збереження найкращої контрольної точки під час навчання `umt5-base`.

2.6.2 chrF++

`chrF++` розширює метрику `chrF`, додаючи до символьних n-грам словесні (параметр `word_order = 2`). Базова F-міра:

$$\text{chrF} = \frac{(1 + \beta^2) \cdot \text{chrP} \cdot \text{chrR}}{\beta^2 \cdot \text{chrP} + \text{chrR}} \quad (18)$$

де chrP - символна точність, chrR - символна повнота, $\beta = 2$ (більший акцент на повноту, ніж на точність).

Переваги chrF++ для задачі нормалізації:

- нечутлива до токенизації - оцінює безпосередньо символи;
- краще відображає морфологічну схожість для мов із розгалуженою флексійною системою;
- стабільніша за BLEU на коротких виходах, де n-грамні підрахунки нестійкі.

У роботі chrF++ є основною порівняльною метрикою. Обчислюється як `corpus_chrf(word_order = 2)` у SacreBLEU.

2.6.3 TER

TER (Translation Edit Rate) вимірює кількість редагувань, необхідних для перетворення згенерованого тексту на еталон:

$$TER = \frac{\text{кількість редагувань}}{|\text{еталон}|} \quad (19)$$

Типи редагувань: вставка, видалення, заміна та зсув фрагмента. На відміну від BLEU і chrF++, менше значення TER означає кращу якість. Обчислюється як `corpus_ter` у SacreBLEU.

2.6.4 Взаємодоповнюваність метрик

Три метрики охоплюють різні аспекти якості і доповнюють одна одну:

- BLEU акцентує на точності n-грамних збігів слів - добре відображає, чи вибирає модель правильну лексику;
- chrF++ оцінює морфологічну близькість через символні n-грами - важливо для українського, де одне слово може мати кілька відмінкових форм;
- TER показує мінімальний обсяг правок для отримання еталону - інтуїтивно зрозуміла метрика для оцінки «скільки ще треба виправити».

Для задачі нормалізації до близькоспорідненої літературної норми типові очікувані діапазони: chrF++ > 90 для суржику (мінімальні лексичні відмінності)

та суттєво нижчі значення для діалектів із більшою фонетичною і морфологічною відстанню від норми, таких як закарпатський. Низький TER при невисокому BLEU може сигналізувати про правильні слова у неправильному порядку або часткові збіги.

2.7 Стратегії декодування

Задача декодування - знайти найбільш імовірну вихідну послідовність:

$$\hat{y} = \arg \max_y \log p_{\theta}(y|x) \quad (20)$$

Жадібний пошук: на кожному кроці вибирається лексема з найвищою ймовірністю:

$$\hat{y}_t = \arg \max_{y_t} p_{\theta}(y_t|x, \hat{y}_{<t}) \quad (21)$$

Найшвидший варіант, але може «зациклюватись» або пропустити глобально кращу послідовність.

Пошук з променем (beam search, B - розмір променя): підтримує B найкращих часткових гіпотез одночасно. Для umt5-base під час оцінювання $B = 4$. Краща якість за рахунок перебору, ціна - лінійне збільшення обчислень.

Семплювання з температурою (для MatayLM): лексема вибирається із розподілу, загостреного температурою τ :

$$p'_{\theta}(y_t|x, \hat{y}_{<t}) \propto \exp\left(\frac{\log p_{\theta}(y_t|x, \hat{y}_{<t})}{\tau}\right) \quad (22)$$

При $\tau = 0.1$ розподіл загострюється і наближається до жадібного пошуку, зберігаючи невелику варіативність. Додатково застосовується top-k фільтрування ($k = 25$): решту лексем відкидають.

Відмінність стратегій: umt5-base генерує детермінований вихід (пошук з променем), MatayLM - з незначним різноманіттям через семплювання.

2.8 Балансування даних

2.8.1 Дисбаланс діалектів та принципи семплювання

Мультидіалектний корпус нерівномірний: суржик охоплює ≈ 50 тис. прикладів, тоді як гуцульський вручну - менше 10 тис. При навчанні на об'єднаному корпусі оптимізація зміщується у бік найбільшого підкорпусу. Для вирівнювання вводяться ваги семплювання:

$$P(\text{діалект} = i) \propto n_i^\gamma \quad (23)$$

де n_i - кількість прикладів діалекту i , а $\gamma \in [0, 1]$ контролює ступінь вирівнювання ($\gamma = 0$ - рівномірний, $\gamma = 1$ - пропорційний до обсягу).

2.8.2 Формат інструкцій для мультидіалектності

Для декодерної BMM використовується єдиний формат із маркером діалекту в системній ролі:

- нормалізація гуцульського (маркер «HUTSUL»);
- нормалізація бойківського (маркер «BOIKO»);
- нормалізація закарпатського (маркер «TRANSCARPATHIAN»);
- нормалізація суржику (маркер «SURZHUK»).

Таким чином система розв'язує умовну задачу $p_\theta(y|x, t)$, де t - тип нормалізації, закодований у вхідному запиті.

2.9 Висновки до розділу

У розділі наведено математичну постановку задачі нормалізації як умовної генерації $p_\theta(y|x)$. Кодер-декодерна модель umt5-base [3.] пройшла повне донавчання за 40 епох із кроком навчання 5×10^{-5} , згладжуванням міток $\alpha = 0.1$ (формула 6) та раннім зупином. Декодерна BMM MatayLM [11.] навчена через QLoRA ($r = 16$, $\alpha = 32$, 4-bit NF4) за 3 епохи з кроком 2×10^{-4} . Описано математичні основи: механізм уваги трансформера (формула 7), цільові функції (формули 5–6), стратегії декодування (жадібний пошук та пошук з променем) і метрики BLEU [16.], chrF++ та TER (формули 16–19).

3 ПРОГРАМНЕ ТА ТЕХНІЧНЕ ЗАБЕЗПЕЧЕННЯ

3.1 Технологічний стек

Систему реалізовано на Python 3.11 з фіксованими версіями залежностей у файлі `pyproject.toml`. Керування залежностями виконується через інструмент `uv`, а всі основні операції автоматизовано через `Makefile`: встановлення середовища (`install`), підготовка даних (`prepare-data`), генерація корпусів (`generate-*`), навчання моделей (`train-*`), оцінювання (`evaluate-*`), запуск застосунку (`demo`) та компіляція документації (`pdf`).

Перевага такого підходу - відтворюваність: будь-який дослідник може клонувати репозиторій і відтворити всі результати однією командою `make all`, не виконуючи ручних кроків. Зокрема, `make prepare-data` завантажує вихідні речення, запускає правилу та LLM-генерацію і формує фінальний навчальний корпус повністю автоматично. Цей підхід до автоматизації знижує ризик помилок відтворення, притаманних ручним інструкціям.

Основні бібліотеки, задіяні у системі, наведено в таблиці 5.

Бібліотека `Unsloth` є ключовою для прискорення QLoRA-навчання. Вона перезаписує критичні операції (функція уваги, обчислення `softmax` у `cross-entropy`) нативними ядрами `CUDA` через `Triton-JIT`-компіляцію, що дає зниження споживання відеопам'яті на 30-40% порівняно зі стандартною реалізацією `Transformers`. Додатково `Unsloth` підтримує асинхронне збереження контрольних точок у фоновому потоці, не призупиняючи навчання. Бібліотека `rumorphy2` забезпечує морфологічний аналіз для правилкової генерації суржику: без неї підтримка відмінкових форм заміників була б неможливою без великої вручну складеної таблиці.

Крім програмних залежностей, важливу роль відіграє технічне забезпечення. Різні етапи роботи системи ставлять різні вимоги до обчислювальних ресурсів (табл. 6).

Фактично у роботі використано сервер з `NVIDIA A100 (80 GB VRAM)`,

Таблиця 5: Основні бібліотеки системи

Бібліотека	Версія	Призначення
PyTorch	2.6.0	Основний фреймворк для навчання нейронних мереж
Transformers	$\geq 4.57.1$	Трансформерні архітектури, токенизатори, конвеєри
PEFT	$\geq 0.15.0$	LoRA/QLoRA параметро-ефективне донавчання
TRL	0.18.2	SFTTrainer для навчання з інструкціями
Unsloth	2026.1.4	Прискорення QLoRA (2-3 рази): зли-та увага, оптимізований autograd
BitsAndBytes	$\geq 0.45.0$	4- та 8-бітне квантування вагових матриць
Accelerate	$\geq 1.12.0$	Розподілені обчислення та змішана точність
SacreBLEU	$\geq 2.5.1$	Обчислення BLEU, chrF++ та TER
Datasets	3.4.1	Завантаження та обробка наборів даних
NiceGUI	$\geq 1.4.0$	Вебзастосунок (Python-native UI над FastAPI)
PyAV (av)	$\geq 14.0.0$	Декодування аудіо WebM/OGG/WAV до 16 кГц
py morphology2	актуальна	Морфологічний аналіз і відмінювання слів
Typeer	$\geq 0.9.0$	Інтерфейси командного рядка скриптів

128 ГБ оперативної пам'яті та NVMe-диском обсягом 1 ТБ. Такі ресурси дозволили виконати всі етапи без обмежень за пам'яттю та сховищем. Найбільш ресурсомістким є етап генерації синтетики: модель Mistral-Small-24B потребує понад 16 ГБ VRAM навіть у 4-бітному режимі, а генерація 30 000 прикладів на діалект займає від 12 до 24 годин на NVIDIA A100.

3.2 Конвеєр генерації корпусу

3.2.1 Правилова генерація суржику

Для суржику реалізовано клас SurzhykErrorifier, що перетворює нормативні українські речення у суржик без залучення зовнішніх ВММ. Такий підхід

Таблиця 6: Вимоги до технічного забезпечення за етапами

Компонент	Генерація синтетики	Навчання umt5	QLoRA MamayLM	Застосунок
ЦП	8+ ядер	8+ ядер	8+ ядер	4+ ядра
ОП	32 ГБ	16 ГБ	32 ГБ	8 ГБ
ГП (VRAM)	24 ГБ	8 ГБ	24 ГБ	4 ГБ
Сховище	50 ГБ	10 ГБ	20 ГБ	5 ГБ

дозволив отримати додатково 20 911 прикладів за рахунок детермінованих правил, рівномірно покриваючи типові лексичні підстановки. Правильний підхід забезпечує стовідсоткову відтворюваність: однакове речення завжди дає однаковий суржиковий варіант.

Алгоритм складається з двох послідовних фаз.

Фаза 1: фразова заміна. Клас будує лексикон фраз: усі записи словника, що складаються з кількох слів, упорядковуються за спаданням довжини у лексемах. Для кожного вхідного речення алгоритм застосовує ці фрази як регулярні вирази (з урахуванням меж слів \b) від найдовшої до найкоротшої, підставляючи відповідний суржиковий варіант при першому збігу. Пріоритет найдовшого збігу запобігає частковим замінам: наприклад, фраза «на самому ділі» замінюється цілком, а не лише слово «самом». Усі заміщені позиції у реченні позначаються як вже оброблені і не передаються до фази 2.

Фаза 2: пословна морфологічна заміна. Для кожного слова, ще не заміненого у фазі 1, виконується лематизація через `ru morphology2`. Якщо лема знайдена у лемному індексі словника, береться суржиковий відповідник. Далі `ru morphology2` відмінює його у потрібну граматичну форму, збігаючи граммами оригінального слова (рід, число, відмінок, особа, час). Це гарантує граматичну узгодженість результату: якщо вхід містить слово у родовому відмінку множини, суржиковий заміник також опиняється у тій самій формі. Якщо потрібна граматична форма відсутня у парадигмі замінника (наприклад, незмінювані слова), система повертає початкову форму без помилки.

Речення відкидається, якщо жодної заміни не відбулося. Відношення ефе-

ктивності: з усього доступного корпусу нормативних речень правилловий підхід дав позитивний результат (хоча б одну заміну) приблизно для 40% речень, що й склало 20 911 прикладів суржику.

3.2.2 LLM-генерація для діалектів

Для генерації бойківського, закарпатського та гуцульського діалектів, а також додаткового суржику, реалізовано клас `DialectCorpusGenerator`. Він складається з двох взаємодіючих компонентів: `DialectPromptBuilder` та `LocalModelClient`.

DialectPromptBuilder відповідає за формування інструкційного запиту до моделі. Для кожного діалекту завантажується відповідний файл правил з теки `prompts/` (337-568 рядків). Щоб не включати до контексту весь словник (що може перевищувати ліміт лексем моделі), застосовується відбір найрелевантніших статей. Обчислюється TF-IDF косинусна схожість між вхідним реченням та кожним записом словника, і до запиту включаються лише $k = 50$ найближчих статей. Таким чином кожне речення отримує сфокусовану лексичну підказку, адаптовану до його конкретної семантики: речення про транспорт отримує транспортну лексику, а речення про побут - побутову. Шаблон запиту наведено на рис. 2.2 (підрозд. 2.2.2).

Відібрані словникові статті замінюють плейсхолдер `{dictionary}` у системному запиті. Запит користувача містить пакет з 5 вхідних речень, пронумерованих списком. Модель повертає відповідний список з 5 перекладів у форматі JSON-масиву рядків.

LocalModelClient виконує інференцію на локально розгорнутій моделі `Mistral-Small-24B-Instruct-2501` з 4-бітним квантуванням NF4 у режимі подвійного квантування. Локальний запуск обрано замість хмарного API з двох причин: по-перше, це усуває залежність від зовнішніх сервісів і ліміти запитів; по-друге, забезпечує повний контроль над параметрами генерації (`temperature=0.7`, `max_tokens=2048`). Пакетна обробка по 5 речень за запит дозволяє моделі розглядати речення у спільному контексті, що підвищує стилістичну узгодженість

перекладів у межах одного пакету. При обробці ізольованих речень модель може обрати різний стиль для схожих фраз; спільний контекст 5 речень знижує таку варіативність.

Клас `DialectCorpusGenerator` реалізує чотирирівневий контроль якості:

- **Подвійний розбір відповіді:** спершу спроба декодувати JSON-масив рядків; якщо не вдається - текстовий запасний варіант (розбиття за нумерованими рядками).
- **Валідація:** відсіюються пари, де вихід коротший за третину входу (ознака незавершеності відповіді), або де присутні залишки JSON-синтаксису, або де кількість виходів не збігається з кількістю входів.
- **Дедуплікація:** хеш нормалізованого рядка (нижній регістр, без зайвих пробілів) зберігається у множині; дублікати не додаються до корпусу незалежно від сеансу генерації.
- **JSONL-журнал:** кожен прийнятий запис зберігається з полем `source`, що містить ідентифікатор діалекту та номер пакету. Це дозволяє відстежити походження будь-якого прикладу у корпусі.

Ліміт генерації встановлено на рівні 30 000 прикладів на діалект. Фактично отримано: 19 841 для гуцульського (ліміт не досягнуто через менший вихідний корпус речень), по 29 754 для бойківського та 29 612 для суржику. Повторні запуски при збоях безпечні завдяки дедуплікації: вже згенеровані приклади просто пропускаються.

3.2.3 Підготовка корпусу до навчання

Фінальний корпус формується скриптом `prepare_multidialect_data.py`. Він об'єднує підкорпуси всіх діалектів, перемішує їх і ділить на навчальну і валідаційну вибірки у пропорції 90/10. Тестова вибірка формується цілком окремо: вона містить виключно ручні анотації (по 50 прикладів на діалект, 200 разом) і жодним чином не перетинається з навчальними даними. Такий поділ гарантує чисте оцінювання: модель не могла «бачити» тестові речення у жодній формі під час навчання.

Розподіл підсумкового корпусу наведено в таблиці 7.

Таблиця 7: Розподіл корпусу за різновидами

Різнovid	Ручні	LLM	Прав.	Навч.	Валід.	Тест
Гуцульський	9 853	19 841	-	26 725	2 969	50
Бойківський	-	29 754	-	26 778	2 976	50
Закарпатський	-	29 605	-	26 644	2 961	50
Суржик	-	29 612	20 911	45 471	5 052	50
Разом	9 853	108 812	20 911	125 615	13 756	200

Підкорпус суржику є найбільшим завдяки двом незалежним підходам до генерації: LLM-синтетика і правилова генерація не перетинаються за методом, тож їх об'єднання дає різноманітніший корпус. Підкорпус гуцульського діалекту вирізняється наявністю 9 853 ручних пар, що позитивно вплинуло на якість навчання. Підкорпуси бойківського та закарпатського діалектів сформовані виключно з LLM-синтетики через відсутність публічних паралельних корпусів для цих різновидів.

3.3 Навчання моделей

3.3.1 Донавчання *umt5-base*

Навчання кодер-декодерної моделі *umt5-base* [3.] реалізовано через клас *Seq2SeqTrainer* з бібліотеки *Transformers*. Процес складається з шести основних кроків.

Крок 1: завантаження та підготовка даних. CSV-файли з навчальною і валідаційною вибірками завантажуються в об'єкти *HuggingFace Dataset* з полями *source* (діалектний текст) та *target* (нормативна відповідь). Для мультидіалектної моделі поле *source* містить префікс, наприклад: «Переклади з гуцульської: *вхідний текст*». Префіксний підхід дозволяє єдиній моделі обслуговувати всі чотири різновиди без окремих ваг.

Крок 2: токенизація. Вхідні та цільові тексти кодуються через *AutoTokenizer* (*SentencePiece*, словник 250 112 лексем). Максимальна довжина входу і виходу обмежена 256 лексемами - цього достатньо для всіх речень у корпусі, оскільки середня довжина речення не перевищує 30 слів.

Крок 3: динамічне доповнення. Замість фіксованого доповнення до 256 лексем застосовується `DataCollatorForSeq2Seq` з параметром `pad_to_multiple_of=8`: кожен пакет доповнюється лише до кратної 8 довжини найдовшого речення у пакеті. Це мінімізує кількість паддінг-лексем і підвищує ефективність матричних операцій на CUDA, оскільки ядра тензорних обчислень оптимізовані для розмірів, кратних 8 або 16.

Крок 4: навчання. Використовується `Seq2SeqTrainer` з гіперпараметрами, описаними у підрозділі 2.5 (табл. 3). Функція втрат - перехресна ентропія зі згладжуванням міток $\alpha = 0.1$ (формула 6), що запобігає надмірній впевненості моделі у окремих лексемах і покращує узагальнення.

Крок 5: моніторинг і рання зупинка. Після кожної епохи обчислюється BLEU на валідаційній вибірці через функцію `compute_metrics`: декодуються передбачення (ігноруються спеціальні ID доповнення —100), обчислюється BLEU через `sacrebleu` з детоксифікацією. Якщо BLEU не покращується упродовж 5 епох поспіль, навчання зупиняється достроково. Зберігаються три останні контрольні точки; по завершенні автоматично завантажується найкраща за BLEU.

Крок 6: збереження. Фінальна модель і токенизатор зберігаються у каталог `models/umt5-base-multidialect/final_model`, звідки їх завантажує застосунок «Лексикон» у режимі реального часу.

Графіки мультидіалектного навчання (суржик + 3 діалекти) наведено на рис. 3.1 та 3.2. Пікове значення BLEU 71.7 досягнуто на кроці 314 040.

3.3.2 Донавчання MatayLM

Навчання декодерної BMM MatayLM [11.] (Gemma-3-4B) реалізовано через `SFTTrainer` з бібліотеки `TRL` з прискоренням `Unsloth`. Ключова особливість порівняно з кодер-декодерним підходом - необхідність явного форматування прикладів у чат-шаблон і маскування функції втрат.

Крок 1: завантаження та квантування. Базова модель завантажується у режимі 4-бітного квантування NF4 з подвійним квантуванням (`BitsAndBytesConfig`). Подвійне квантування означає, що коефіцієнти кванту-




Рис. 3.1: Функція втрат та темп навчання umt5-base під час мультідіалектного донавчання (суржик + 3 діалекти, 314 040 кроків).

вання самих ваг теж квантуються, що дає додаткову економію близько 0.4 біту на параметр. Якщо доступна бібліотека Unsloth - використовується її оптимізований завантажувач; інакше модель завантажується через стандартний Transformers разом з PEFT.

Крок 2: форматування у чат-шаблон. Кожен навчальний приклад форматується у два повідомлення: користувача («Переклади з {діалект}: {вхідний текст}») та асистента («{нормативний текст}»). Функція `apply_chat_template` перетворює ці пари у послідовність лексем відповідно до формату Gemma-3 (спеціальні маркери початку і кінця ходу). Префіксний метод обумовлення на діалект зберігається з umt5-підходу для сумісності.

Крок 3: пакування. SFTTrainer з параметром `packing=True` об'єднує короткі приклади у пакети до 512 лексем. Замість того щоб доповнювати кожен приклад до 512 лексем паддінгом (що давало б велику частку «порожніх» лексем), пакування заповнює кожен пакет реальним текстом майже повністю. Це суттєво підвищує завантаженість ГП і прискорює навчання: у практиці пакування дало приріст пропускної здатності близько 40% порівняно з непакованим режимом на тому самому обладнанні.

Крок 4: маскування функції втрат. Градієнт обчислюється лише за ле-




Рис. 3.2: Динаміка BLEU та функція втрат на валідаційній вибірці під час мультидіалектного донавчання *umt5-base*.

ксемами відповіді асистента. Лексеми системного запиту та запиту користувача замінюються на -100 (ігнорований індекс у стандартній функції перехресної ентропії PyTorch), тому модель навчається генерувати нормативну відповідь, а не відтворювати вхідний запит.

Крок 5: LoRA-адаптери. QLoRA-адаптери ($r = 16$, $\alpha = 32$, dropout=0.0) застосовуються до всіх проєкційних матриць уваги та FFN-шарів: `q_proj`, `k_proj`, `v_proj`, `o_proj`, `gate_proj`, `up_proj`, `down_proj`. Заморожені ваги базової моделі зберігаються у 4-бітному форматі і не займають оперативну пам'ять ГП в повній точності. Ефективна кількість навчальних параметрів - близько 13 мільйонів, що становить менш ніж 0.4% від загального обсягу моделі у 4 мільярди параметрів.

Крок 6: контрольні точки та завершення. Unsloth забезпечує асинхронне збереження контрольних точок у фоновому потоці без паузи у навчанні. Після завершення можливе злиття адаптерів у базову модель (`merge_and_unload`) для ефективного розгортання без накладних витрат PEFT під час інференції.

Частково захоплені криві навчання MatayLM наведено на рис. 3.3. TensorBoard активовано приблизно з кроку 25 000, тому початковий спад функції втрат на графіку відсутній.




Рис. 3.3: Функція втрат та темп навчання MamayLM (QLoRA) з кроку 25 000 до 53 500 (TensorBoard увімкнено з проміжного кроку навчання).

3.4 Оцінювання та аналіз результатів

3.4.1 Методологія оцінювання

Тестова вибірка містить 200 прикладів: по 50 на кожен з чотирьох різновидів. Усі приклади зібрані вручну і жодним чином не перетиналися з навчальними даними. Ручна анотація тестових прикладів є принципово важливою: якби тестова вибірка містила LLM-синтетику, результати відображали б якість того самого генератора, яким навчалися моделі, а не реальну лінгвістичну точність.

Нуль-шотовими базовими лініями слугують три комерційні BMM, доступні через OpenRouter API: GPT-4o [16.], Gemini 2.0 Flash та Mistral Large. Їх запитували з тим самим системним запитом («Переклади з {діалект} до літературної української мови»), але без жодних прикладів у контексті - нуль-шотовий режим. Це дозволяє оцінити, наскільки спеціалізоване донавчання перевершує загальні BMM, що не мали доступу до наших навчальних даних.

Для оцінювання кодер-декодерних моделей реалізовано скрипт `evaluate_encoder_decoder.py`, для декодерних BMM - `evaluate_decoder_only.py`. Обидва зберігають результати у `results.json` з розбивкою показників за кожним з чотирьох різновидів. Обчислюються три метрики, описані у підрозділі 2.6: BLEU (формула 16), chrF++ та TER (формула 19).

3.4.2 Результати кодер-декодерної моделі *umt5-base*

Зведені результати *umt5-base* по всіх різновидах наведено на рис. 3.4.

UMT5-base (finetuned, encoder-decoder)

Tasks	bleu	chrf++	ter
boiko_translation	29.12	54.78	49.37
hutsul_translation	74.68	86.90	12.53
surzhyk_translation	89.42	93.58	5.98
transcarpathian_translation	6.20	27.45	82.21

Рис. 3.4: Результати umt5-base на тестовій вибірці за різновидами (BLEU, chrF++, TER).

Найкращий результат - суржик (chrF++ = 93.58). Це пояснюється найбільшим навчальним підкорпусом (понад 50 000 пар двох типів генерації) та лексичною близькістю суржику до нормативної мови: більшість слів збігаються, відрізняються лише окремі лексеми. Гуцульський діалект демонструє chrF++ = 86.90, що зумовлено найбільшою кількістю ручних анотацій (9 853 пари). Бойківський результат нижчий (chrF++ = 54.78): цей діалект має складніші синтаксичні і фонетичні відмінності від норми, а кодер-декодерна архітектура може недостатньо вловлювати їх при суто лексичних підстановках. Закарпатський дає найслабший результат (chrF++ = 27.45): суттєва лінгвістична відстань від літературної норми і відсутність ручних прикладів у навчанні.

3.4.3 Результати декодерної BMM MamayLM

Результати MamayLM наведено на рис. 3.5.

MamayLM (finetuned, decoder-only)

Tasks	bleu	chrf++	ter
boiko_translation	51.81	66.82	35.26
hutsul_translation	64.84	74.02	12.53
surzhyk_translation	78.48	91.22	11.96
transcarpathian_translation	3.82	20.93	89.69

Рис. 3.5: Результати MamayLM на тестовій вибірці за різновидами (BLEU, chrF++, TER).

MamayLM демонструє сильний результат на суржику (chrF++ = 91.22) і на бойківському (chrF++ = 66.82), де вона перевершує umt5-base. На гуцульському

результат нижчий (74.02 проти 86.90 у umt5), що може пояснюватися меншою кількістю навчальних кроків (3 епохи проти 40) і природою декодерних ВММ: такі моделі краще виявляють семантичні паттерни, але гірше «запам'ятовують» точні лексичні відповідності, важливі для символічних метрик. Закарпатський залишається найскладнішим і для MamayLM (chrF++ = 20.93).

3.4.4 Порівняння з нуль-шотовими базовими лініями

Результати нуль-шотових базових ліній наведено на рисунках 3.6-3.9.

Tasks	Filter	n-shot	Metric	Value	Stderr	Stderr_CLT
boiko_translation	none	0	chrF_score	0.7395±	N/A	0.0199
hutsul_translation	none	0	chrF_score	0.6489±	N/A	0.0255
surzhyk_translation	none	0	chrF_score	0.8897±	N/A	0.0176
transcarpathian_translation	none	0	chrF_score	0.6539±	N/A	0.0218

Рис. 3.6: Результати нуль-шотового GPT-4o за різновидами.

Tasks	Filter	n-shot	Metric	Value	Stderr	Stderr_CLT
boiko_translation	none	0	chrF_score	0.7457±	N/A	0.0199
hutsul_translation	none	0	chrF_score	0.6534±	N/A	0.0245
surzhyk_translation	none	0	chrF_score	0.8667±	N/A	0.0193
transcarpathian_translation	none	0	chrF_score	0.6816±	N/A	0.0210

Рис. 3.7: Результати нуль-шотового Gemini 2.0 Flash за різновидами.

Tasks	Filter	n-shot	Metric	Value	Stderr	Stderr_CLT
boiko_translation	none	0	chrF_score	0.7091±	N/A	0.0225
hutsul_translation	none	0	chrF_score	0.6318±	N/A	0.0233
surzhyk_translation	none	0	chrF_score	0.8579±	N/A	0.0209
transcarpathian_translation	none	0	chrF_score	0.6365±	N/A	0.0250

Рис. 3.8: Результати нуль-шотового Mistral Large за різновидами.

Зведену таблицю chrF++ для всіх моделей і різновидів наведено в таблиці 8.

3.4.5 Аналіз результатів

Аналіз показників дозволяє зробити кілька спостережень.

Суржик. Обидві донавчені моделі перевершують усі нуль-шотові базові лінії, включно з найсильнішою з них - Gemini 2.0 Flash (93.58 і 91.22 проти 86.67). Основна причина - великий корпус (понад 50 000 пар) та лексична

MamayLM (baseline, before finetuning)

Tasks	bleu	chrF++	ter
boiko_translation	21.77	58.73	56.42
hutsul_translation	5.06	16.73	50.13
surzhyk_translation	49.07	65.58	35.89
transcarpathian_translation	10.43	27.90	82.21

Рис. 3.9: Нуль-шотові результати MamayLM (до донавчання) за різновидами.

Таблиця 8: Порівняння моделей за метрикою chrF++ на тестовій вибірці

Модель	Суржик	Гуцульський	Бойківський	Закарпатський
umt5-base (наш)	93.58	86.90	54.78	27.45
MamayLM (наш)	91.22	74.02	66.82	20.93
GPT-4o	88.97	64.89	-	65.39
Gemini 2.0 Flash	86.67	65.34	74.57	68.16
Mistral Large	85.79	63.18	70.91	63.65
MamayLM (до донавч.)	65.58	16.73	58.73	27.90

близькість суржика до норми: більшість слів ідентична, змінюється лише 20-30% лексики. Показово, що нуль-шотовий MamayLM до донавчання дав лише 65.58 - тобто донавчання підняло ту саму модель на 25.64 пункти. Це свідчить, що основний внесок дають саме спеціалізовані навчальні дані, а не загальна потужність архітектури.

Гуцульський. umt5-base (86.90) і MamayLM (74.02) суттєво перевищують усі нуль-шотові моделі, найближча з яких - Gemini (65.34). Вирішальним фактором став найбільший ручний підкорпус (9 853 пари): донавчені моделі вивчили специфічну фонетику і лексику гуцульського, яку комерційні BMM знають лише з передтренувального корпусу. MamayLM до донавчання показав лише 16.73 на гуцульському - це найбільший розрив між базовою і донавченою версією серед усіх різновидів, що підтверджує ефективність ручних анотацій.

Бойківський. Тут ситуація інша: найкращий результат у Gemini 2.0 Flash (74.57), далі Mistral Large (70.91), і лише потім MamayLM (66.82) і umt5-base

(54.78). Наші донавчені моделі не виходять на перше місце. Причина - корпус бойківського складається виключно з LLM-синтетики: якщо синтетика неточно відображає реальні властивості діалекту, модель навчається неправильним патернам. Комерційні ВММ, навчені на великих корпусах, у цьому випадку краще узагальнюють.

Закарпатський. Найбільший розрив між нашими моделями і комерційними базовими лініями: umt5 (27.45), MamaLM (20.93) проти Gemini (68.16), GPT-4o (65.39), Mistral (63.65). Як і для бойківського, корпус закарпатського сформований виключно з LLM-синтетики. Нуль-шотовий MamaLM (27.90) навіть злегка перевершує донавчений на синтетиці umt5 (27.45), що підтверджує: навчання на неякісній синтетиці може не давати жодного приросту або навіть шкодити.

Загальний висновок: спеціалізоване донавчання переконливо виправдане для різновидів із якісними навчальними даними (суржик, гуцульський). Для бойківського і закарпатського, де корпус складається виключно з LLM-синтетики, комерційні ВММ у нуль-шотовому режимі залишаються сильнішими. Ключовий фактор якості - не обсяг синтетики, а наявність ручних анотацій.

3.5 Вебзастосунок «Лексикон»

3.5.1 Архітектура застосунку

Застосунок «Лексикон» реалізовано на базі фреймворку NiceGUI версії 1.4 і вище. NiceGUI будує Python-native UI над FastAPI і Starlette: розробник описує інтерфейс через Python-об'єкти (ui.button, ui.textarea тощо), а фреймворк генерує відповідний HTML/JavaScript і обслуговує його через вбудований ASGI-сервер. Перевага такого підходу - відсутність необхідності писати JavaScript вручну: весь код інтерфейсу, моделі та обробки запитів знаходиться в одному Python-середовищі.

Застосунок запускається командою make demo (або безпосередньо uv run python app.py) і доступний за адресою <http://0.0.0.0:7870>. При старті завантажуються обидва модулі: нормалізатор і модуль АРМ. Якщо ГП недоступний,

нормалізатор автоматично перемикається на ЦП-режим (float32 замість float16), що дозволяє запустити застосунок навіть без відеокарти з певним зниженням швидкості.

Інтерфейс застосунку показано на рис. 3.10.




Рис. 3.10: Інтерфейс вебзастосунку «Лексикон»: вибір різновиду мови, поле введення тексту з кнопкою мікрофону та поле нормалізованого результату.

3.5.2 Модуль нормалізації

Клас DialectTranslator завантажує збережену мультидіалектну модель umt5-base з каталогу models/umt5-base-multidialect/final_model у режимі float16 на ГП. Обумовлення на конкретний діалект реалізується через префікс запиту:

- «surzhyk» → «Переклади з суржику: {текст}»;
- «hutsul» → «Переклади з гуцульської: {текст}»;
- «boiko» → «Переклади з бойківської: {текст}»;
- «transcarpathian» → «Переклади з закарпатської: {текст}».

Вхідний текст токенізується і передається на генерацію через model.generate() з такими параметрами: num_beams=5 (пошук з 5 променями), max_length=128, repetition_penalty=1.2, no_repeat_ngram_size=3.

Параметр `repetition_penalty=1.2` знижує ймовірність повторення слів у виводі, а `no_repeat_ngram_size=3` забороняє повтор будь-якого тримграму - разом це усуває артефакти зациклення, характерні для seq2seq-моделей на коротких або незнайомих входах.

Користувач може динамічно регулювати `num_beams` (від 3 до 10) та `repetition_penalty` (від 1.0 до 2.0) через повзунки в інтерфейсі без перезавантаження моделі. Зміна `num_beams` впливає на якість і швидкість: більше променів дає точніший результат, але збільшує час відповіді.

3.5.3 Модуль автоматичного розпізнавання мовлення

Модуль APM використовує модель `speechbrain/m-ctc-t-large` (MSTCTForCTC через Hugging Face Transformers) - багатомовну CTC-модель, попередньо навчену на 7 мовах без додаткового донавчання на діалектних даних. Модель обрана через підтримку кириличного алфавіту і відносно невеликий розмір (близько 450 МБ) для моделі такого класу.

Обробка аудіо реалізована через бібліотеку PyAV: браузер записує мовлення через MediaRecorder API і надсилає файл у форматі WebM або OGG на ендпоінт FastAPI POST `/api/transcribe`. На сервері PyAV декодує аудіопотік, конвертує у моно float32 і ресемплює до 16 кГц - стандартна частота дискретизації для більшості APM-моделей. Отриманий масив передається у модель, результат декодується через AutoProcessor і повертається у відповіді як JSON: `{"text": "..."}.`

Перевага використання PyAV замість зовнішнього ffmpeg: бібліотека встановлюється через pip і містить всі необхідні кодеки статично, що спрощує розгортання на нових машинах без системних залежностей.

3.5.4 Інтерфейс користувача

Інтерфейс організований у три колонки на десктопі: ліва - панель вибору діалекту з прикладами, центральна - поле введення тексту, права - поле результату. На мобільних пристроях (ширина менш ніж 768 пікселів) колонки перешкоджаються у вертикальний стек через CSS breakpoint.

Функціонал застосунку:

- чотири кнопки вибору діалекту з коротким описом і географічним регіоном;
- поле введення тексту з кнопкою мікрофону для голосового введення через АРМ - натискання починає запис, повторне натискання зупиняє і автоматично транскрибує мовлення у поле введення;
- кнопка «Нормалізувати» запускає обробку і виводить результат у правому полі;
- повзунки для тонкого налаштування параметрів генерації (num_beams, repetition_penalty);
- чотири приклади вхідних речень (по одному на кожен різновид) для швидкого тестування без введення тексту вручну.

Весь інтерфейс описано приблизно у 250 рядках Python-коду у файлі `app.py`, що є наслідком декларативного підходу NiceGUI.

3.6 Висновки до розділу

У розділі описано програмне та технічне забезпечення системи «Лексикон». Технологічний стек базується на Python 3.11 з бібліотеками PyTorch 2.6.0, Transformers, PEFT, TRL та Unsloth; навчання відбувалося на NVIDIA A100 (80 ГБ VRAM). Конвеєр генерації корпусу реалізує два підходи: правилний через клас `SurzhykErrorifier` (20 911 прикладів суржику з `rumorphy2` і словника) та LLM-генерація через клас `DialectCorpusGenerator` (108 812 прикладів через `Mistral-Small-24B-Instruct-2501`). Загалом корпус налічує 125 615 навчальних пар.

Навчання `umt5-base` виконано через `Seq2SeqTrainer` за 40 епох з раннім зупинком (терпіння 5 епох), навчання `MamayLM` - через `SFTTrainer` з QLoRA та пакуванням за 3 епохи. Оцінювання на 200 ручних прикладах показало, що донавчені моделі перевершують усі нуль-шотові базові лінії на суржику (`chrF++` = 93.58 для `umt5-base` проти 86.67 у `Gemini 2.0 Flash`) та гуцульському (86.90 проти 65.34). Для бойківського і закарпатського, де навчальний корпус склада-

ється виключно з LLM-синтетики, комерційні ВММ у нуль-шотовому режимі виявились кращими (Gemini: 74.57 і 68.16 відповідно), що вказує на критичну роль якісних ручних анотацій. Вебзастосунок реалізовано на NiceGUI і FastAPI з нормалізатором на основі umt5-base і АРМ-модулем speechbrain/m-ctc-t-large.

ЗАГАЛЬНІ ВИСНОВКИ

У роботі розроблено систему «Лексикон» для автоматичної нормалізації суржику та трьох регіональних діалектів сучасної української мови до літературної норми.

Основні результати роботи:

1. Проаналізовано сучасні підходи до нормалізації діалектів і суржику та найближчі роботи у цій галузі (UA-GEC, Spivavtor, Vuyko Mistral, Bytes to Borsch). Встановлено відсутність публічних паралельних корпусів для бойківського та закарпатського діалектів.
2. Зібрано та проаналізовано вхідні дані: ручний паралельний корпус гуцульського діалекту (9 853 пари), загальномовний корпус Spivavtor [12.] як джерело нормативних речень. Проаналізовано обмеженість наявних ресурсів і обґрунтовано підхід до синтетичного розширення.
3. Розроблено конвеєр правилкової генерації суржику (клас SurzhykErrorifier): двофазовий алгоритм на основі словника і морфологічного аналізатора rymorphy2 дав 20 911 навчальних прикладів.
4. Розроблено конвеєр LLM-генерації діалектних пар (клас DialectCorpusGenerator) з відбором словникових статей через TF-IDF косинусну схожість. Згенеровано 108 812 прикладів через Mistral-Small-24B-Instruct-2501. Підсумковий корпус: 125 615 навчальних / 13 756 валідаційних / 200 тестових пар.
5. Виконано повне донавчання кодер-декодерної моделі umt5-base [3.] (40 епох, $lr = 5 \times 10^{-5}$, згладжування міток $\alpha = 0.1$, рання зупинка). Результат на тестовій вибірці: chrF++ = 93.58 на суржику, 86.90 на гуцульському.
6. Виконано QLoRA-донавчання декодерної BMM MatayLM [11.] (Gemma-3-4B, $r = 16$, $\alpha = 32$, 3 епохи, прискорення Unsloth). Ре-

зультат: chrF++ = 91.22 на суржику, 66.82 на бойківському.

7. Реалізовано вебзастосунок «Лексикон» на NiceGUI і FastAPI з нормалізатором umt5-base (пошук з 5 променями) і модулем автоматичного розпізнавання мовлення speechbrain/m-ctc-t-large для голосового введення.

Основний науковий результат: спеціалізоване донавчання перевершує нуль-шотові комерційні ВММ (GPT-4o, Gemini 2.0 Flash, Mistral Large) для різновидів із якісними навчальними даними - суржику (chrF++ = 93.58 проти 86.67 у Gemini) та гуцульського (86.90 проти 65.34). Для бойківського і закарпатського, де навчальний корпус складається виключно з LLM-синтетики, перевага залишається за комерційними ВММ (Gemini: 74.57 і 68.16 відповідно). Це підтверджує ключову роль ручних анотацій: не обсяг синтетики, а її якість і наявність ручних еталонних пар визначають здатність моделі перевершити загальні ВММ.

Напрями подальшого розвитку: зібрати ручні паралельні корпуси для бойківського (мінімум 3-5 тис. пар) і закарпатського діалектів - це є головним вузлом місцем системи; донавчити модуль АРМ на діалектних аудіозаписах; розширити підтримку інших діалектів (слобожанський, подільський, волинський); розробити програмний інтерфейс для інтеграції «Лексикону» з іншими інструментами обробки природної мови.

СПИСОК ВИКОРИСТАНИХ ДЖЕРЕЛ

1. Baniata L. H., Park S., Park S.-B. A Neural Machine Translation Model for Arabic Dialects That Utilizes Multitask Learning (MTL) // *Computational Intelligence and Neuroscience*. 2018. С. 1-10. doi: 10.1155/2018/7534712.
2. Bondarenko M., Yushko A., Shportko A., Fedorych A. Comparative Study of Models Trained on Synthetic Data for Ukrainian Grammatical Error Correction // *Proceedings of the Third Ukrainian Natural Language Processing Workshop (UNLP)*. 2024.
3. Chung H. W. et al. UniMax: Fairer and more Effective Language Sampling for Large-Scale Multilingual Pretraining. Квітень 2023. arXiv:2304.09151. doi: 10.48550/arXiv.2304.09151.
4. Fedchuk R., Vysotska V. Mathematical Model of a Decision Support System for Identification and Correction of Errors in Ukrainian Texts Based on Machine Learning // *CEUR Workshop Proceedings*. 2021.
5. Haltiuk M. On the Path to Make Ukrainian a High-Resource Language // *Proceedings of the Second Ukrainian Natural Language Processing Workshop (UNLP)*. 2023.
6. Kent K. Language Contact: Morphosyntactic Analysis of Surzhyk Spoken in Central Ukraine // *Journal of Language Contact*. 2010.
7. Kiulian A. et al. From Bytes to Borsch: Fine-Tuning Gemma and Mistral for the Ukrainian Language Representation. Квітень 2024. arXiv:2404.09138. doi: 10.48550/arXiv.2404.09138.
8. Kovalchuk R., Romanyshyn M., Ivaniuk P. Introducing OmniGEC: A Silver Multilingual Dataset for Grammatical Error Correction // *Proceedings of the Second Ukrainian Natural Language Processing Workshop (UNLP)*. 2023.
9. Kyslyi R., Maksymiuk Y., Pysmennyi I. Vuyko Mistral: Adapting LLMs for Low-Resource Dialectal Translation. Червень 2025. arXiv:2506.07617. doi: 10.48550/arXiv.2506.07617.
10. Lapa LLM.

Доступно у: <https://huggingface.co/lapa-llm>

11. MamayLM.

Доступно у: <https://huggingface.co/blog/INSAIT-Institute/mamaylm>

12. Saini A., Chernodub A., Raheja V., Kulkarni V. Spivavtor: An Instruction Tuned Ukrainian Text Editing Model. Квітень 2024. arXiv:2404.18880. doi: 10.48550/arXiv.2404.18880.
13. Sira N., Di Nunzio G. M., Nosilia V. Towards an Automatic Recognition of Mixed Languages in R: The Case of Ukrainian-Russian Hybrid Language Surzhyk // *CLiC-it 2021*. 2021.
14. Syvokon O., Nahorna O., Kuchmiichuk P., Osidach N. UA-GEC: Grammatical Error Correction and Fluency Corpus for the Ukrainian Language // *Proceedings of the Second Ukrainian Natural Language Processing Workshop (UNLP)*. 2023. С. 96-102. doi: 10.18653/v1/2023.unlp-1.12.
15. Xue L. et al. ByT5: Towards a Token-Free Future with Pre-Trained Byte-to-Byte Models // *Transactions of the Association for Computational Linguistics*. 2022. arXiv:2105.13626. doi: 10.48550/arXiv.2105.13626.
16. Zhao H. et al. From Handcrafted Features to LLMs: A Brief Survey for Machine Translation Quality Estimation // *IJCNN 2024*. Чер 2024. С. 1-10. doi: 10.1109/IJCNN60899.2024.10650457.

Додаток А

Повний вихідний код системи, включно з кодом навчання моделей, генерації корпусу та вебзастосунку «Лексикон», доступний у відкритому репозиторії на GitHub: <https://github.com/DenkoProg/surdo-perevodchik>.

У додатку наведено системні промпти, які використовувалися для LLM-генерації суржикових та гуцульських діалектних пар через модель Mistral-Small-24B-Instruct-2501. Кожен промпт містить лінгвістичні правила, словник підстановок і приклади перекладів для відповідного різновиду мови.

А.1 Системний промпт для генерації суржику

You are an expert in Surzhyk — the mixed Russian-Ukrainian vernacular

- ↪ widespread in eastern and southern Ukraine. Your task is to convert standard
- ↪ literary Ukrainian sentences into authentic everyday Surzhyk.

Surzhyk is NOT a regional dialect — it is a sociolinguistic phenomenon of

- ↪ Russian-Ukrainian language mixing found in everyday informal speech.
- ↪ Unlike formal "chancellery calques," real spoken Surzhyk blends Russian
- ↪ vocabulary and grammar into Ukrainian at the word level. Your goal is to
- ↪ produce natural-sounding Surzhyk as it is actually spoken by ordinary people,
- ↪ not how bureaucratic documents are written.

Apply rules selectively and naturally. Not every sentence needs all rules applied —

- ↪ choose the substitutions that sound most authentic for the given context.

1. Lexical Substitutions — Common Everyday Words

Replace Ukrainian words with their Russian-calqued equivalents. These are the

- ↪ most characteristic features of everyday spoken Surzhyk.

1.1 Connectives and Discourse Markers

- "але" → "но" (рос. "но")
- "якщо" → "єсли" (рос. "если")
- "тому що" / "бо" → "потому що" (рос. "потому что")

- "хоча" → "хотя" (рос. "хоча")
- "взагалі" → "вообще" / "вообще" (рос. "вообще")
- "насправді" → "на самом ділі" (рос. "на самом деле")
- "звичайно" → "конечно" / "конечно" (рос. "конечно")
- "навіть" → "даже" (рос. "даже")
- "тільки" → "только" / "только" (рос. "только")
- "ще" → "ещё" (рос. "ещё")
- "потім" → "потом" (рос. "потом")
- "тоді" → "тогда" (рос. "тогда")
- "завжди" → "всегда" (рос. "всегда")
- "ніколи" → "никогда" (рос. "никогда")
- "зараз" → "щас" (рос. "сейчас")
- "дуже" → "очень" (рос. "очень")
- "зовсім" → "совсем" (рос. "совсем")
- "майже" → "почті" (рос. "почти")
- "скрізь" → "везде" / "всюди" (рос. "везде")
- "тут" → "тут" (stays same, but also "здесь")
- "там" → "там" (same in both)
- "ось" → "вот" (рос. "вот")
- "по-перше" → "во-первых" (рос. "во-первых")
- "наприклад" → "напрімер" (рос. "например")

1.2 Common Verbs

- "зрозуміти" / "зрозумів" → "понять" / "понимати" / "понімав" (рос. "понять")
- "казати" / "сказати" → "говорити" / "говорить" (рос. "говорить")
- "треба" → "нада" / "надо" (рос. "надо")
- "думати" → "думать" / "думаю" stays same (рос. "думать")
- "знаходитися" → "находитися" (рос. "находиться")
- "починати" → "начинати" (рос. "начинать")
- "кінчати" / "закінчувати" → "кончати" / "закінчать" (рос. "кончать")

- "відчувати" → "чувувати" / "відчувать" (рос. "чувствовать")
- "вважати" → "рахувати" / "считати" (рос. "считать")
- "подобатися" → "нравитися" (рос. "нравиться")
- "відповідати" → "отвічати" (рос. "отвечать")

1.3 Common Nouns and Adjectives

- "місто" → may stay, but "город" used in some regions (рос. "город")
- "зупинка" → "остановка" (рос. "остановка")
- "квартира" → "квартира" (slight Russian pronunciation)
- "час" → "время" / "час" (both used)
- "хвилина" → "мінута" / "минута" (рос. "минута")
- "наступний" → "слідуючий" (рос. "следующий")
- "минулий" → "прошлий" (рос. "прошлый")
- "різний" → "разний" (рос. "разный")
- "певний" → "конкретний" / "определений" (рос. "определённый")
- "справжній" → "настоящий" (рос. "настоящий")
- "важливий" → "важний" / "важливий" (рос. "важный")
- "трохи" → "трошки" / "чуть-чуть" / "трошки" (рос. "чуть-чуть")

2. Verb Infinitive Endings

In Russian, infinitives end in "-ть" or "-ти", but the dominant everyday form is

→ "-ть". In Surzhyk, Ukrainian "-ти" endings frequently shift to "-ть":

- "робити" → "робить" (рос. "делать")
- "ходити" → "ходить" (рос. "ходить")
- "говорити" → "говорить" (рос. "говорить")
- "жити" → "жить" (рос. "жить")
- "знати" → "знать" (рос. "знать")
- "думати" → "думать" (рос. "думать")
- "бачити" → "бачить" / "відіть" (рос. "видеть")
- "чути" → "чуть" (рос. "слышать")

- "хотіти" → "хотіть" (рос. "хотеть")
- "іти" → "іть" / "йти" (рос. "идти")
- "брати" → "брать" (рос. "брать")
- "давати" → "давать" (рос. "давать")

Apply this substitution to infinitives in context (after "треба/нада", "можна",
→ "хочу", "буду", etc.).

3. Preposition Interference (Conversational)

- "за законом" → "по закону" (рос. "по закону")
- "через це" → "із-за цього" / "іzza цього" (рос. "из-за этого")
- "щодо цього" → "насчот цього" (рос. "насчёт этого")
- "після цього" → "после цього" (рос. "после этого")
- "перед цим" → "пєред цим" (рос. "перед этим")
- "до кінця" → "до кінця" (same)
- "для того щоб" → "для того шоби" (рос. "для того чтобы")

4. Discourse Fillers and Particles

Add or substitute with Russian conversational fillers:

- "ну" — Russian filler, used in both but very common in Surzhyk
- "вот" — "ось" → "вот" (рос. "вот")
- "значить" — "тобто" → "значить" (рос. "значит")
- "короче" — "словом" → "короче" (рос. "короче")
- "в общем" — "загалом" → "в общем" (рос. "в общем")
- "ладно" — "добре" → "ладно" (рос. "ладно")
- "да" — "так" → "да" (рос. "да") — in agreement/response contexts

5. Formal Phrase Calques (for formal/bureaucratic contexts)

Use these only when the sentence is clearly formal or official in tone:

- "брати участь" → "приймати участь" (рос. "принимать участие")

- "складати іспит" → "здавати іспит" (рос. "сдавать экзамен")
- "ухвалити рішення" → "прийняти рішення" (рос. "принять решение")
- "вживати заходів" → "приймати міри" (рос. "принимать меры")
- "протягом" → "на протязі" (рос. "на протяжении")
- "наступний" → "слідуючий" (рос. "следующий")

6. Frequency and Naturalness Guidelines

- ****Apply 1–3 changes per sentence**** — Surzhyk is partial mixing, not full
 - ↳ Russian
- ****Everyday sentences****: focus on lexical substitutions (connectives, verbs,
 - ↳ common nouns) and infinitive endings
- ****Preserve Ukrainian word order**** — syntax remains Ukrainian; only
 - ↳ vocabulary changes
- ****Most authentic patterns first****: common word substitutions > infinitive
 - ↳ endings > discourse particles > preposition interference > formal calques
- ****Priority****: dictionary entries > translation examples > rules above

SURZHYK DICTIONARY

Consider the following standard Ukrainian → Surzhyk vocabulary for

↳ substitutions:

{dictionary}

TRANSLATION EXAMPLES

Standard Ukrainian: Але він не хотів цього робити.

Surzhyk: Но він не хотів цього робить.

Standard Ukrainian: Зараз він працює в музеї.

Surzhyk: Щас він працює в музеї.

Standard Ukrainian: Вона дуже втомилася після роботи.

Surzhyk: Вона очень втомилася після роботи.

Standard Ukrainian: Я думаю, що це правильне рішення.

Surzhyk: Я думаю, що це правильне рішення.

Standard Ukrainian: Якщо він прийде, скажи мені.

Surzhyk: Єслі він прийде, скажи мені.

Standard Ukrainian: Він узагалі не розумів, що відбувається.

Surzhyk: Він вообщє не понимав, що відбувається.

Standard Ukrainian: Треба подумати перед тим, як вирішувати.

Surzhyk: Нада подумать перед тим, як вирішувать.

Standard Ukrainian: Потім вона пішла додому і почала готувати вечерю.

Surzhyk: Потом вона пішла додому і начала готувать вечерю.

Standard Ukrainian: Навіть якщо це складно, треба намагатися.

Surzhyk: Дажє єслі це складно, нада намагатись.

Standard Ukrainian: Він завжди говорив те, що думав.

Surzhyk: Він всегда говорив те, шо думав.

Standard Ukrainian: Звичайно, це не найлегше завдання.

Surzhyk: Конєшно, це не найлегше завдання.

Standard Ukrainian: Тому що він не міг цього зрозуміти.

Surzhyk: Потому шо він не міг цього понять.

Standard Ukrainian: Вона взагалі не хотіла про це говорити.

Surzhyk: Вона вообщє не хотіла про це говорить.

Standard Ukrainian: Наступного тижня відбудеться важлива зустріч.

Surzhyk: Слідуючого тижня відбудеться важлива зустріч.

Standard Ukrainian: За законом кожен має право на захист.

Surzhyk: По закону кожен має право на захист.

IMPORTANT

- Preserve the original meaning of the sentence
- Apply Russian-Ukrainian mixing naturally — not every word must change
- Use 1–5 substitutions per sentence for realistic Surzhyk

- Keep Ukrainian grammar structure; only replace vocabulary/phrases/endings
- Return ONLY the Surzhyk version, without explanations
- Return each sentence on a new line
- For everyday informal sentences: use everyday Surzhyk patterns (connectives,
 - ↪ infinitive endings, common words)
- For formal sentences: additionally apply formal calques from section 5
- If a sentence has no obvious Surzhyk substitutions, use at least one common
 - ↪ lexical change (e.g., "але" → "но", "тому що" → "потому що", infinitive
 - ↪ "-ти" → "-ть")

A.2 Системний промпт для генерації гуцульського діалекту

You are an expert in the Hutsul dialect of the Ukrainian language. Your task is to

↪ convert standard Ukrainian sentences into authentic Hutsul dialect.

Below is a comprehensive set of grammatical rules to help you convert Ukrainian

↪ text into the Hutsul dialect.

They focus on phonetic changes, grammatical transformations, and syntactic

↪ patterns characteristic of the Hutsul dialect, with a particular emphasis on

↪ Word Order.

Note: Apply specific rules such as changing "и" to "і" or softening consonants by

↪ adding "ь" only when you are certain they are appropriate in the context.

1. Vowel Changes

1.1. "є" instead of "а" or "я" (when stressed)

"а" or "я" become "є" when stressed.

Examples:

- "як" → "єк"
- "ягода" → "єгода"
- "яблуко" → "єблуко"
- "яйце" → "єйце"
- "ярмарок" → "єрмарок"
- "теля" → "теле"
- "шапка" → "шепка"
- "капелюх" → "кепелюх"
- "м'ята" → "мнєта"
- "колядник" → "колідник"

"є" instead of "и" in some words:

- "їдеш" → "єдеш"
- "їшли" → "єшли"

1.2. "е" or sometimes "і" instead of "и" (when stressed)

"и" becomes "е" or less commonly "і" when stressed.

Examples:

- "абись" → "абес"
- "абисьти" → "абести"
- "жито" → "жето"
- "вим'я" → "вім'ї"

1.3. "и" instead of "і"

"і" becomes "и".

Examples:

- "Іван" → "Иван"
- "іду" → "иду"
- "із" → "из"
- "зійшла" → "зийшла"

1.4. "и" or "і" instead of "я"

"я" becomes "и" or "і".

Examples:

- "найся" → "найси"
- "як ся маєте" → "як сі маєте"
- "він знаходився" → "він находив сі"
- "я забився" → "я забивсі"

1.5. "у" instead of "ю"

"ю" becomes "у".

Examples:

- "сюди" → "суда"
- "вівцю" → "вівцу"
- "кішницю" → "кішницу"

1.6. "ві-" instead of "ви-" in prefixes

The prefix "ви-" becomes "ві-".

Examples:

- "витратити" → "вітратити"

- "виповісти" → "віповісти"

2. Consonant Changes

2.1. Softening of Dentals

The sounds "д", "т", "з", "с" are often softened significantly before "і".

Examples:

- "діло" → "діло" (pronounced softly, but not "гіло")

- "тісто" → "кісто" (The "т" before "і" often sounds like a soft "к")

2.2. "ть" instead of "к"

"к" becomes "ть" in certain words.

Example:

- "донька" → "доньтя"

2.3. "д" instead of "г"

"г" becomes "д".

Example:

- "легінь" → "ледінь"

2.4. "к" instead of "т" and "г" instead of "д" (Palatalization)

Before "і" or "є", "т" often sounds like a soft "к", and "д" sounds like a soft "г"

↪ (rarely, but possible).

Examples:

- "тісто" → "кісто"

- "тяжко" → "кєшко"

- "дід" → "гєд" (Only in very specific deep dialect cases, otherwise keep "дід")

2.5. Softened Sibilants (Sh, Ch sounds)

Softening of sibilant consonants by adding a soft sign "ь".

Examples:

- "чого" → "чьо"

- "нічого" → "нічьо"

- "челядь" → "чєлєдь"

- "шапка" → "шєпка"

- "чари" → "чєри"

2.6. "ц" instead of "ч" and vice versa

"ч" becomes "ц", and "ц" becomes "ч".

Examples:

- "чи" → "ци"

- "цибух" → "чибук"

2.7. Hard "с", "ц", "з" instead of softened ones

Softened consonants "сь", "зь", "ць" become hard "с", "з", "ц".

Examples:

- "щось" → "шос"

- "десь" → "дес"

- "на вулицю" → "на вулицу"

- "крізь" → "кріз"

2.8. "нн", "н" instead of "дн", "тн", "лн"

"дн", "тн", "лн" become "нн" or "н".

Examples:

- "передній" → "перенний"

- "мельник" → "менник" or "меник"

3. Use of Particles and Conjunctions

3.1. "і" to "тай" or "та й"

The conjunction "і" is replaced with "тай" or "та й".

Example:

- "Він і вона" → "Він тай вна"

3.2. "та" becomes "тай"

"та" changes to "тай".

Example:

- "Більше та краще" → "Бирше тай красше"

3.3. "й" to "тай"

"й" becomes "тай".

Example:

- "Він й вона" → "Він тай вна"

4. Negation

4.1. "не" to "ни"

"не" becomes "ни".

Example:

- "Не знаю" → "Ни знаю"

4.2. Double Negation

Double negation is used for emphasis.

Example:

- "Ніколи не бачив" → "Ніколи ни видів"

5. Pronouns and Possessives

5.1. "його" to "йиго"

"його" becomes "йиго".

Example:

- "Його книга" → "Йиго книга"

5.2. "мене" to "міні"

"мене" becomes "міні".

Example:

- "Він бачив мене" → "Він видів міні"

6. Reflexive Verbs

6.1. "ся" to "си"

"ся" becomes "си".

Example:

- "Сміється" → "Смієтси"

6.2. Placement of "си"

Unlike standard Ukrainian, "си" acts as a separate particle. It can stand AFTER the
→ verb, but very often stands BEFORE the verb.

Examples:

- "Він сміється" → "Він си сміє"

- "Як ся маєш?" → "Єк си маєш?"

7. Verb Endings and Conjugations

7.1. Third Person Singular Present Tense

Verbs ending in "-є" or "-е" change to "-єт".

Examples:

- "Має" → "Маєт"

- "Знає" → "Знаєт"

- "Ходить" → "Ходит"

7.2. Past Tense Verbs

Past tense verbs often remain the same, but pronunciation may differ.

Example:

- "Він сказав" → "Він сказав" (with dialectal pronunciation)

7.3. Shortened Auxiliary Verbs (Enclitics)

In past tense, specific endings are often added to indicate the person (I, You, We).

Examples:

- "Я ходив" → "Ходив'єм" or "Ходивим"

- "Ти зробив" → "Зробив'єс" or "Зробивис"

- "Ми пішли" → "Пішли'смо"

8. Prepositions

8.1. "від" to "вид"

"від" becomes "вид".

Example:

- "Від тебе" → "Вид тебе"

8.2. "у" to "в"

"у" becomes "в" before consonants.

Example:

- "У хаті" → "В хаті"

8.3. "до" becomes "д'" before vowels

"до" becomes "д'" when followed by a word starting with a vowel.

Example:

- "До Андрія" → "Д'Андрія"

9. Word Order and Syntax

Word order in the Hutsul dialect can differ significantly from standard Ukrainian.

- The dialect often rearranges sentence components to emphasize certain
- elements, convey nuances, or align with traditional speech patterns.

9.1. Time and Place Expressions at the Beginning

Rule: Time and place expressions are frequently placed at the beginning of the

- sentence to set the scene or emphasize when or where an action occurs.

Examples:

- Ukrainian: "В понеділок я піду до міста."

- Hutsul: "В понегівок я пиду до міста."

9.2. Emphasis Through Inversion

Rule: The Hutsul dialect uses inversion to emphasize certain parts of a sentence,

- such as placing the verb before the subject or moving objects to the front.

Examples:

- Ukrainian: "Він представив законопроект."

- Hutsul: "Представів він законопроект."

- Ukrainian: "Я тебе люблю."

- Hutsul: "Люблю я тебе."

9.3. Flexible Placement of Conjunctions

Rule: Conjunctions like "тай" can be used to link clauses or phrases, and their

- placement can vary to affect the rhythm and flow of the sentence.

Example:

- Ukrainian: "Вона співала і танцювала."

- Hutsul: "Вна співала, тай танцювала."

9.4. Subject Pronouns May Be Omitted

Rule: Subject pronouns are sometimes omitted if the verb form makes it clear who
→ is performing the action.

Example:

- Ukrainian: "Я йду додому."

- Hutsul: "Иду додому."

9.5. Use of Reduplication for Emphasis

Rule: Words may be repeated for emphasis or to intensify the meaning.

Example:

- Ukrainian: "Швидко-швидко біг."

- Hutsul: "Борше-борше біг."

9.6. Placement of Reflexive Particles

Rule: The reflexive particle "си" can influence word order, often following the verb
→ closely.

Example:

- Ukrainian: "Він сміється."

- Hutsul: "Він смієтси."

9.7. Questions Formed with Intonation and Particles

Rule: Questions may be formed by intonation and the use of particles like "ци,"
→ often placed at the beginning.

Example:

- Ukrainian: "Ти знаєш?"

- Hutsul: "Ци ти знаєш?"

9.8. Negative Constructions and Emphasis

Rule: Negation can be emphasized by placing "ни" before the verb and sometimes
→ repeating it.

Example:

- Ukrainian: "Він не прийшов."

- Hutsul: "Він ни прийшов."

9.9. Order of Adjectives and Nouns

Rule: Adjectives usually precede nouns, but for emphasis, the order can be
→ inverted.

Example:

- Standard Order: "Красна гілка" (Красна дівка)

- Inverted for Emphasis: "Гілка красна"

9.10. Use of Interjections and Fillers

Rule: Interjections like "ой," "ей," "ну" can be inserted to convey emotion or
→ emphasis, affecting the rhythm and word order.

Example:

- "Ой, єк то файно!"

10. Emphasis and Interjections

10.1. Use of "ой", "ай", "ей"

Interjections are used to express emotions and can be placed at various points in the
→ sentence.

Examples:

- "Ой, єк добре!"

- "Ай, шо то робити?"

- "Єй, міні тяжко!"

HUTSUL-UKRAINIAN DICTIONARY

Also consider the following Ukrainian-Hutsul dictionary for vocabulary

→ substitutions:

{dictionary}

TRANSLATION EXAMPLES

Ukrainian: І пішов з тим усім надвір.

Hutsul: Тай пишов з тим усім надвір.

Ukrainian: До надвірної роботи вони не бралися.

Hutsul: До надвірної роботи уни си нам ни чєпали.

Ukrainian: Таж розповім лиш про Олексія, то зараз побачиш, як то є.

Hutsul: Таже най ти доповістую лиш за Олексія, то зараз уздриш, ек то є.

Ukrainian: Можна класти в землю все — сіяти й садити.

Hutsul: Мож класти у земню усе — сієти й садити.

Ukrainian: Давно так не було, як тепер: ніхто не сердився восени за пашу.

Hutsul: Давно, то ни так було, ек тепер, ніхто ни сердивси восени за пашу.

Ukrainian: Та що діяти? — тяжко зітхнув Иванчік.

Hutsul: Та шо дієти?» — тежко зідхнув Иванчік.

Ukrainian: Їхні очі лакомо зустрілися, і вони, сміючись, любо собі цілувалися.

Hutsul: Їх очі лакомо си зострітили, тай вни, сміючіси любо одно д'одному,
↪ цулувалиси.

Ukrainian: Він тримав у лівій руці чепелик від граду.

Hutsul: Він держєв у лівій руці чепелик вид граду.

Ukrainian: Здавалося, що його нічого на світі ні радувало, ні веселило.

Hutsul: Здавалоси, шо йиго нічо на світі ні радувало, ні веселило.

Ukrainian: Він не злякався ведмедя.

Hutsul: Він ни вергси медведя.

IMPORTANT:

- Preserve the original meaning of the sentence
- Use characteristic Hutsul lexical and phonetic features
- Apply rules naturally, don't overdo it
- Return ONLY the translation, without explanations
- Return each translated sentence on a new line
- If multiple rules could apply to the same word, use this priority:
 1. dictionary entries,
 2. translation examples,
 3. general rules.

Додаток Б

У додатку наведено системні промпти для генерації бойківського та закарпатського діалектних пар. Структура промптів аналогічна до Додатку А.

Б.1 Системний промпт для генерації бойківського діалекту

You are an expert in the Boiko dialect of the Ukrainian language. Your task is to

→ convert standard Ukrainian sentences into authentic Boiko dialect.

CRITICAL: The Boiko dialect is a UKRAINIAN dialect spoken in the Carpathian

→ region of Ukraine. It is NOT Belarusian, NOT Russian, NOT Polish, NOT Old

→ Church Slavonic. Do NOT produce Belarusian text. The output must remain

→ Ukrainian with Boiko-specific phonetic and morphological features applied on

→ top.

Below is a comprehensive set of grammatical rules to help you convert Ukrainian

→ text into the Boiko dialect.

They focus on phonetic changes, grammatical transformations, and syntactic

→ patterns characteristic of the Boiko dialect.

Note: The Boiko dialect is one of the most archaic Ukrainian dialects, preserving

→ many features of Old Ukrainian and Proto-Slavic. Apply rules naturally and

→ contextually.

1. Vowel Changes

1.1. Distinction of [и] and [ы]

The Boiko dialect distinguishes between front [и] and back [ы].

Examples:

- "бик" → "бык"

- "тихо" → "тыхо"

- "бич" → "бич" (preserved front [и])

- "високо" → "высоко"

- "дівки" → "дівкы"

1.2. Preservation of [e] and [и] in Unstressed Syllables

Unlike standard Ukrainian, [e] and [и] remain distinct in unstressed positions.

Examples:

- "мене" → "мене" (not mixed with [и])
- "течки" → "течкы"

1.3. Narrowing of [e] → [и] Before Soft Consonants

Examples:

- "десь" → "дись"
- "пень" → "пинь"
- "отець" → "отиць"
- "днесь" → "днись"

1.4. Softening of Consonants Before [и] from Old [o], [e]

Examples:

- "дім" → "дым"
- "тік" → "тык"
- "сім" → "сым"
- "двір" → "дьвір"

1.5. Approach of Unstressed [o] to [y]

In peripheral subdialects, unstressed [o] approaches or becomes [y].

Examples:

- "робота" → "роубота" / "робута"
- "коза" → "куза"
- "корова" → "курова"

1.6. Labialization of [a] Before [й]

Examples:

- "дав" → "доў"
- "правда" → "проўда"
- "лавка" → "лоўка"

1.7. Narrowing of [a] After Soft Consonants

[a] becomes [и], less commonly [e] or [і] after soft consonants.

Examples:

- "теля" → "тели"
- "час" → "чес"
- "сміється" → "смієсі"

2. Consonant Changes

2.1. Soft Pronunciation of Sibilants

Sibilants [ж], [ш], [ч] are typically pronounced soft.

Examples:

- "жаба" → "жяба" (soft ж)
- "душа" → "душя" (soft ш)
- "куча" → "кучя" (hen coop)

2.2. [дж] → [дз'] (Voiced Palatal Affricate)

On the place of Proto-Slavic [дж], a special sound is pronounced.

Examples:

- "сажа" → "садзя"
- "межа" → "медзя"
- "їж" → "їдз"
- "чужий" → "чудзий"

2.3. [л] → [љ] at Syllable End

Examples:

- "кіл" → "ків"
- "галка" → "гавка"
- "пищалка" → "пищавка"
- "повний" → "повўний" / "повний"

2.4. Soft [p'] at Word End and Sometimes Mid-Word

Examples:

- "козар" → "козарь"
- "тепер" → "теперь"
- "верх" → "верьх"

2.5. Epenthetic [й] After Labials (Not Changing to [л])

Examples:

- "сплю" → "спйу"
- "тямлю" → "тямйу"
- "виробляють" → "виробйяют"
- BUT: "роблений" → "роблений" (preserved)

2.6. [н'к] → [йк] in Suffixes

Examples:

- "невістонька" → "невістойка"
- "новенький" → "новейкий"
- "полегоньки" → "полегойки"

2.7. No Consonant Lengthening in Nouns Like "життя"

Examples:

- "весілля" → "весіля"
- "насіння" → "насіня"
- "білизна, одяг" → "шматя"

2.8. [дн] → [нн]

Examples:

- "бідна" → "бінна"
- "полудень" → "полунне"
- "повинний" → "повидний" (hypercorrection in some areas)

2.9. Africatzation of Initial [з] in Some Words

Examples:

- "зелений" → "дзелений" / "дзелений"
- "зерня" → "дзерня" / "дзерня"
- "звір" → "дзвир" / "дзвир"

2.10. Africatzation of Soft [д'], [т'] After [з], [ц]

Examples:

- "газді" → "газдзі"

- "стіна" → "сціна"

- "кість" → "кісць"

2.11. Loss of [й] in Certain Words and Endings

Examples:

- "військо" → "восько"

- "стрий(ко)" → "стрико" (father's brother)

- "маю" → "мау"

- "знають" → "знаут"

- "рукою" → "рукоў"

- "землею" → "землев"

2.12. Second Pleophony (Mostly in Infinitives)

Examples:

- "негода; добра погода" → "веремя"

- "кинути" → "веречи"

- "зачерпнути" → "зачерети"

2.13. Alveolar [л] and Soft [д'], [т'] → [ɾ], [ɕ'] (Peripheral Areas)

Examples:

- "діло" → "гіло"

- "тісто" → "кісто"

- "плат" → "плат" (with alveolar л)

- "слива" → "слива" (with alveolar л)

3. Stress Patterns

3.1. Stress Differences from Standard Ukrainian

Examples:

- "беркут" → "берку́т" (stress on last syllable)

- "Бескид" → "Бески́д"

- "високо" → "високо́"

- "потік" → "по́тік"

- "пишу" → "пи́шу"

- "несеш" → "не́сеш"

3.2. Emphatic Stress Shift to First Syllable

Examples:

- "великий" → "ве́ликий" (emphatic)

- "зелений" → "зе́лений" (emphatic)

- "далеко" → "да́леко" (emphatic)

4. Noun Morphology

4.1. Feminine Nouns Ending in -ов

Examples:

- "бритва" → "бритов"

- "голова" → "голов"

- "церква" → "церков"

4.2. Collective Neuter Nouns

Examples:

- "хлопці" → "хлопчища"

- "хмиз" → "ріща"

- "папери" → "папіря"

4.3. Church Holiday Names Ending in -я

Examples:

- "Дмитра" → "Дмитря"

- "Михайла" → "Михайля"

4.4. Archaic Genitive Singular Forms

Examples:

- "дня" → "дне"

- "церкви" → "церкве"

- "ременя" → "ремене"

4.5. Hard Stem Influence on Soft Stem Nouns

Examples:

- "батькові" → "ві́тцovi"

- "коневі" → "коньові"
- "батьком" → "вітцём"
- "конем" → "коньом"

4.6. Nominative Plural in -ове

Examples:

- "брати" → "братове"
- "сини" → "синове"
- "сусіди" → "сусідове"

4.7. Remnants of Dual Number in Nominative

Examples:

- "два хлопи" → "два хлопа"
- "дві баби" → "дві бабі"

4.8. Dative Plural Ending -ом (or -ум, -ім)

Examples:

- "волам" → "волом" / "волум"
- "хлопцям" → "хлопцём"
- "гостям" → "госцём"
- "зятям" → "зятім"
- "ведмедям" → "медведім"

4.9. Instrumental Plural with Old Dual Ending -ма (-ома, -има, -іма)

Examples:

- "кіньми" → "кіньма"
- "волами" → "волома"
- "місцями" → "місцьома"

OR archaic ending -и:

- "з волами" → "з воły"
- "перед жнивами" → "перед жнивы"
- "за воротами" → "за вороти"

4.10. Locative Plural Ending -ох

Examples:

- "на конях" → "на коньох"

- "у Гаях" → "у Гайох"

5. Adjective Morphology

5.1. Hard Stem Influence on Soft Stem Adjectives

Examples:

- "пізній" → "пізний"

- "пізня" → "пізна"

- "пізне" → "пізне"

- "торішній" → "торічний"

- "останній" → "остатний"

5.2. Non-Contracted Adjective Forms

Examples:

- "зла" → "злая"

- "зле" → "злоє"

- "злі" → "злії"

- "весела" → "веселая"

- "дурне" → "дурное"

6. Pronouns

6.1. Enclitic Pronoun Forms

Accusative:

- "мене" → "мя" / "мня" / "ня"

- "тебе" → "тя"

- "себе" → "ся"

- "його" → "го"

Dative:

- "мені" → "ми"

- "тобі" → "ти"

- "собі" → "си"

- "йому" → "му"
- "її, їй" → "ї"
- "неї" (after prepositions на, про) → "ню"

6.2. Contracted Possessive Pronoun Forms

In genitive and dative:

Examples:

- "мого" → "мого" (contracted)
- "твого" → "твого"
- "свого" → "свого"
- "моєму" → "мому"
- "твоєму" → "твому"
- "своєму" → "свому"

6.3. Demonstrative Pronouns

- "той" → "тот" / "тота" / "тото" / "тоте" / "тоти"
- "цей" → "сей" / "сесь" / "ся" / "сеся" / "се" / "сесе"
- Limited use: "нон" / "нона" / "ноно"

7. Numerals

7.1. Numeral Forms

Examples:

- "дев'ятнадцять" → "двайцять без єнного" (20 minus 1)
- "двадцять вісім" → "трийцять без двох" (30 minus 2)
- "тридцять три" → "трийцять і три"
- "сорок один" → "сорок і єден"
- "двісті" → "двасто"
- "чотириста" → "штиристо"
- "сімсот" → "сімсто"

8. Verb Morphology

8.1. Infinitive Suffixes -ти and -чи

Examples:

- "бігти" → "бічи"
- "кинути" → "веречи"
- "пекти" → "печи"
- "стригти" → "стричи"

8.2. Loss of Intervocalic [й] in 1st Conjugation -ати Verbs

Examples:

- "питаю" → "питау"
- "питають" → "питаут"

And contracted forms:

- "питаю" → "пита́м"
- "питаєш" → "пита́ш"
- "питає" → "пита́т" (always hard [т])
- "питаємо" → "пита́ме"
- "питаєте" → "пита́те"

8.3. Soft vs Hard [т] in 3rd Person

3rd person singular/plural contracted forms always have hard [т]:

- "читає" → "чита́т"
- "бігає" → "біга́т"

Other forms may have soft [т']:

- "спить"
- "пасуть"

8.4. No [т] Before -ся in 3rd Person Singular Present Tense

Examples:

- "несеться" → "несе́ся"
- "пишеться" → "пише́ся"

8.5. Archaic "суть" (сут) for 3rd Person Plural of "бути"

Examples:

- "чи є корови?" → "Чи́ сут корови?"
- "вони є" → "вни́ сут"

8.6. Past Tense Forms (Remnants of Old Perfect)

1st person singular: -єм / -йим / -їм

2nd person singular: -єсь / -єс

1st person plural: -сьмо / -смо

2nd person plural: -сьте / -сте

Examples:

- "я мав" → "мав'єм" / "мавйим" / "мави́м"

- "ти мав" → "мав'єсь" / "мав'єс"

- "ми мали" → "малисьмо" / "малисмо"

- "ви мали" → "малисьте" / "малисте"

8.7. Analytic Future Tense

Future = auxiliary "бути" + infinitive

Examples:

- "буду робити" → "буду робити"

- "будеш робити" → "будеш робити"

In subdialects near Naddnistrianian:

Future = бути + past tense

Examples:

- "буду робити" → "буду робив"

- "будеш робити" → "будеш робила"

- "будемо робити" → "будемо робили"

8.8. Conditional Mood with Personal Enclitics

Examples:

- "я би ходив" → "ходив бим"

- "ти би ходив" → "ходив бись" / "ходив бис"

- "ми би ходили" → "ходили бисьмо"

- "ви би ходили" → "ходили бисьте"

Enclitics can be in pre-position:

- "щоб ви собі знали" → "бисьте си знали"

9. Adverbs

9.1. Typical Boiko Adverbs

Direction:

- "додому" → "домі" / "домів"
- "вниз, внизу" → "долі" / "долів"
- "догори" → "горі"

Manner:

- "швидко" → "борзо"
- "швидше" → "борше"

Time:

- "минулого року" → "літісь"
- "вчора ввечері" → "сночі"
- "вчора вночі" → "ночось"

Place:

- "он там" → "онде"

Quality:

- "до лиця" → "яло"

Style:

- "по-польськи" → "по-польських" / "по-польський"

10. Prepositions

10.1. Preposition "д" + Dative Case (Instead of "до" + Genitive)

Examples:

- "до нього" → "д ньому"
- "до матері" → "д матери"
- "до хат" → "д хатам"

11. Syntax

11.1. Definite-Personal Sentences with Past Tense/Conditional Verbs

The grammatical subject is expressed by verb enclitics, not separate pronouns.

Examples:

- "Я ходив по гриби" → "Ходив'єм на грибы"
- "Яку ти собі дитину виховав, таку маєш" → "Якус си дітину виховав, таку
↪ маєш"
- "Ми могли б його не зустріти" → "Моглибисьмо го не здибати"

11.2. Similar Sentences with Predicative Adjectives/Nouns

With enclitics -м (from єсмь "I am") and -с (from єси "you are"):

Examples:

- "Ти ж мені не щиренький!" → "Тос ми не щирейкий!"
- "Але я силач" → "Алем моцарь"

12. Lexicon

12.1. Core Boiko Vocabulary

- "тужити" → "банувати"
- "ій-богу" → "бігме"
- "черево, живіт" → "гелево"
- "тиснява" → "глота"
- "кропива" → "жалива"
- "поношений одяг" → "змітки"
- "дерев'яний посуд для молока" → "конов'я"
- "оберемок дров" → "наручя"
- "група хат, частина села" → "постріш"
- "ручна ступа" → "товчка"
- "чистити, очищати" → "харити"
- "знімати кору з дерева" → "чарити"
- "примерзла вода на річці" → "шерен"
- "весна" → "ярь"

12.2. Geographic Terms (Toponyms/Appellatives)

Common in Boiko territory:

- Голиця, Грунь (Грун), Згар, Кичера, Кітлини, Клива, Короста (Корости), Лаз
↪ (Лазы, Лазки), Магура, Обіч (Убіч), Перехресний, Побук, Погар, Розтоки

BOIKO-UKRAINIAN DICTIONARY

Also consider the following Ukrainian-Boiko dictionary for vocabulary

↔ substitutions:

{dictionary}

TRANSLATION EXAMPLES

Ukrainian: Я ходив по гриби.

Boiko: Ходив'єм на грибы.

Ukrainian: Чи є корови?

Boiko: Ци сут корови?

Ukrainian: Він швидко біг.

Boiko: Він борзо біг.

Ukrainian: Я йду додому.

Boiko: Иду домів.

Ukrainian: Він несеться.

Boiko: Він несеся.

Ukrainian: Ти мав книгу.

Boiko: Мав'єсь книгу.

Ukrainian: Ми би ходили.

Boiko: Ходили бисьмо.

Ukrainian: До матері.

Boiko: Д матери.

Ukrainian: Весілля було гарне.

Boiko: Весіля было фayne.

Ukrainian: Нова хата.

Boiko: Новейка хата.

Ukrainian: Моя зла доля.

Boiko: Моя злая доля.

Ukrainian: Піду до нього.

Boiko: Піду д ньому.

Ukrainian: Але я силач.

Boiko: Алем моцарь.

IMPORTANT:

- Preserve the original meaning of the sentence
- Use characteristic Boiko lexical and phonetic features
- Apply rules naturally, don't overdo it
- Return ONLY the translation, without explanations
- Return each translated sentence on a new line
- If multiple rules could apply to the same word, use this priority:
 1. dictionary entries,
 2. translation examples,
 3. general rules.

Б.2 Системний промпт для генерації закарпатського діалекту

You are an expert in the Transcarpathian dialect of the Ukrainian language. Your

- ↪ task is to convert standard Ukrainian sentences into authentic Transcarpathian
- ↪ dialect.

CRITICAL: The Transcarpathian dialect is a UKRAINIAN dialect spoken in

- ↪ Zakarpattia Oblast, Ukraine. It is NOT Belarusian, NOT Slovak, NOT
- ↪ Hungarian-influenced pidgin, NOT Russian. Do NOT produce Belarusian
- ↪ text. The output must remain Ukrainian with Transcarpathian-specific
- ↪ phonetic and morphological features applied on top.

Below is a comprehensive set of grammatical rules to help you convert Ukrainian

- ↪ text into the Transcarpathian dialect.

They focus on phonetic changes, grammatical transformations, and syntactic

- ↪ patterns characteristic of the Transcarpathian dialect.

Note: Apply specific rules such as vowel changes or consonant transformations

- ↪ only when you are certain they are appropriate in the context.

1. Vowel Changes

1.1. Preservation of Archaic [ы]

The phoneme [ы] (a back vowel) is preserved as a continuant of Proto-Slavic and

- ↪ Old Ukrainian sounds.

Examples:

- "мити" → "мыти"
- "мило" → "мыло"
- "син" → "сын"
- "ситий" → "сытий"
- "яблуко" → "яблыко"
- "дрова" → "дрыва"
- "блоха" → "блыха"
- "гинути" → "гынути"
- "киснути" → "кыснути"

- "хитрий" → "хытрый"

1.2. [o] → [y] or [ÿ] in Newly Closed Syllables

In eastern and western subdialects: [o] → [y]

In central subdialects: [o] → [ÿ] (labialized [i])

Examples:

- "віз" → "вус" (eastern/western) / "вÿс" (central)

- "кінь" → "кунь" (eastern/western) / "кÿнь" (central)

- "стіл" → "сціл" / "сцюв"

1.3. [e] → [i] or [y/'ÿ] in Newly Closed Syllables

Examples:

- "осінь" → "ôсінь"

- "приніс" → "принюс" / "прин'ус"

- "лід" → "люд" / "люд'"

- "мед" → "мнют"

- "тітка" → "т'ютка" / "т'ÿтка"

- "привів" → "привйух" / "прив'ÿх"

1.4. Preservation of [a] After Soft Consonants and Sibilants

Examples:

- "тягнути" → "тягнути" (preserved)

- "явір" → "явур" / "явÿр"

- "шапка" → "шапка" (preserved)

- "час" → "час" (preserved)

1.5. Open and Closed [o] Variants

Open [o] before syllables with [o], [a], [e]; closed [ô] before [i], [ÿ], [y] and soft consonants.

Examples:

- "око" → "око" (open)

- "корова" → "корова" (open)

- "в оці" → "в ôц'і" (closed)

- "корові" → "kôrôvi" (closed)

- "кожух" → "kôжух" (closed)

1.6. Narrowing of [e] to [и] Before Soft Consonants

Examples:

- "перший" → "першый" / "піршый"

- "перші" → "пирші"

- "день" → "динь"

- "верх" → "вир'х"

1.7. Initial Stressed [o] → [y] or [ÿ]

Examples:

- "на горісі" → "на ўріс'і"

- "обійти" → "убыйти"

2. Consonant Changes

2.1. Preservation of Soft [p] and [ц]

Examples:

- "рябий" → "p'абый"

- "тепер" → "типир"

2.2. Soft [ч] in Central and Western Subdialects

Examples:

- "чути" → "ч'ути"

- "чорний" → "ч'орний"

2.3. Pre-palatal [л] ("European l")

The consonant [л] has a pre-palatal character before all vowels.

Examples:

- "липа" → "липа" (with European l)

- "молоко" → "молоко" (with European l)

- "лавиця" → "лавиц'а"

- "лупати" → "лупати"

2.4. Absence of Prothetic Consonants

Many words lack the prothetic [г] before [o].

Examples:

- "вулиця" → "улиц'а"
- "вухо" → "ухо"
- "горіх" → "ôріх"
- "гострий" → "острий"

2.5. Secondary [н] After Historically Soft [м]

Examples:

- "сім'я" → "сімн'а"
- "м'яти" → "мн'ати"
- "ім'я" → "имн'а"

2.6. Secondary [л'] After Historically Soft [в] → [љ]

Examples:

- "здоров'я" → "здôрôљ'а"
- "кров'ю" → "крôљ'ôљ"

2.7. Loss of [љ] Before [y/ÿ] from [o] in Newly Closed Syllables

Examples:

- "овес — вівса" → "овес — вÿса / уса"
- "вівця" → "вÿц'а" / "уц'а"

2.8. Nasal [ŋ] Before [к], [г]

Examples:

- "маленький" → "малиŋ'кый"
- "штахетина" → "шпаŋгл'а"

2.9. Affricatization and Vocalization

Examples:

- "жахатися" → "джахатис'а"
- "зяблик" → "дз'апка"
- "ломака" → "ломага"
- "куля" → "гул'а"

2.10. Assimilative Changes

- [ст'] → [с'ц']: "радість" → "радѹс'ц", "стягати" → "с'ц'ігати"
- [рл] → [лл]: "червоний" → "челленный", "терниця" → "теллиц'а"
- [дл] → [лл]: "поганий" → "пѹллый" / "пуллый"
- [дн] → [нн]: "піднімати" → "пуннімати", "полудень" → "пѹлунне"
- [бм] → [мм]: "обмити" → "уммыти"

2.11. Historical [д] → [г] in Past Tense Verb Forms

In verb forms derived from Proto-Slavic clusters тл, дл.

Examples:

- "плів" → "плюг" / "пл'ѹг"
- "мів" → "мйуг"
- "привів" → "привйуг" / "привѹг"
- "пободав" → "збѹг"

3. Noun Morphology

3.1. Weak Differentiation of Hard/Soft Stem Endings

After soft stems, same endings as after hard stems.

Examples:

- "водою — землею" → "вѹдѹ — зимл'ѹ"
- "лавицею" → "лавиц'ѹ"
- "волоів — коневі" → "волѹви — кѹн'ѹви"

3.2. Genitive Plural Ending [-и]

Examples:

- "свиней" → "свини"
- "коней" → "кони"
- "людей" → "люди"
- "гусей" → "гуси"
- "дверей" → "двери"

3.3. Archaic [-и] in Dative and Locative Singular (1st Declension, Feminine)

Examples:

- "землі" (dative) → "земли"

- "на землі" (locative) → "на земли"

3.4. Dative Singular Endings [-ови], [-'ови], [-еви]

Examples:

- "чоловікові" → "чолôвікови"

- "Василеві" → "Василеви"

3.5. Dative Plural Endings [-ум], [-ÿм], [-ім]

Archaic continuation of Old Ukrainian [-омь].

Examples:

- "синам" → "сынум" / "сынÿм" / "сын'ім"

- "волам" → "вôлум" / "вôлÿм" / "вôл'ім"

- "коням" → "кôн'ум" / "кôн'ÿм" / "кôн'ім"

- "ягнятам" → "йагн'атум" / "йагн'атÿм"

3.6. Archaic Instrumental Plural [-ы]

Examples:

- "з волами" → "з волы"

- "з яблуками" → "з яблыкы"

- "під воротами" → "пуд вороты"

- "з ягнятами" → "з йагн'аты"

3.7. Archaic Locative Plural [-іх]

Examples:

- "на волах" → "на вôл'іх"

- "на воротах" → "на вôрôт'іх"

- "на телятах" → "на тил'ат'іх"

3.8. Nominative Plural [-ове] for Kinship Terms

Examples:

- "старости" → "старостове"

- "куми" → "кумове"

- "дружби" → "дружбове"

4. Adjective Morphology

4.1. Non-Contracted Neuter Forms

Examples:

- "добре" → "добро́е" (between Rika and Latorytsya basins)
- "бі́ле" → "біло́е" / "біло́й" (Uzh basin)
- "принесене" → "принесено́е" / "принесено́й"

4.2. Locative Singular Masculine [-ум], [-үм], [-ім]

Examples:

- "на великому" → "на великум" / "великүм" / "великім"

4.3. Dative/Locative Singular Feminine [-үӱ]

Examples:

- "великі́й" → "великүӱ"
- "на сині́й" → "на син'үӱ"

4.4. Hard Consonants Before [-і] in Nominative Plural

Examples:

- "молоді́" → "молоді́" (with hard consonant before і)
- "білі́" → "білі́" (with hard consonant)
- "богати́" → "богати́" (with hard consonant)

4.5. Possessive Adjectives with [-ы] in Nominative Plural

Examples:

- "материні́" → "материни́"
- "братові́" → "братовы́"

4.6. Comparative Degree with [-'ый], [-'ий] and Consonant Alternation

Examples:

- "ширший" → "шир'ый"
- "вужчий" → "ужый"
- "довший" → "доўжый"
- "молодший" → "моложый" / "молоджый"

4.7. Particle "май" for Comparison (Romanian Borrowing)

Unstressed "май" + regular form = comparative

Stressed "май" + regular form = superlative

Examples:

- "бі́льший" → "май вели́кий"
- "найбі́льший" → "майвели́кий" (stressed)
- "моло́дший" → "май молоді́й"
- "наймоло́дший" → "маймоло́дй" (stressed)

Can also apply to nouns and verbs:

- "май жона" = "краща, працьовиті́ша жі́нка"
- "май хыжа" = "бі́льша, краща хата"
- "май рѳбл'у" = "працю́ю бі́льше"

5. Numerals

5.1. Cardinal Numerals

Examples:

- "один" → "йеден"
- "дві" (feminine/neuter) → "дві"
- "дев'яносто" → "ди́ййаддис'ат" / "ди́ййаносто"
- "двісті" → "дві́ста" / "дві́сто" / "два́сто"
- "триста" → "три́ста" / "три́сто"

5.2. Personal-Masculine Forms

Central and eastern: "двоє" → "два́йе", "троє" → "три́йе", "четверо" →
↪ "чоты́ре"

Western: "двом" → "дво́ме", "тры́ом" → "тр'о́ме", "чоты́рьом" → "чотир'о́ме"

5.3. Fractional Numerals

Examples:

- "три з половиною" → "пу(ў)чѳверта" / "пў(ў)чѳверта"

5.4. Declined Numerals with [-ох], [-ом], [-ма]

Examples:

- "п'яти" → "пйат'ох"

- "п'яти" (dative) → "пйат'ом"

- "п'ятьма" → "пйатьма"

6. Pronouns

6.1. Enclitic Forms

Genitive "себе" → "с'а"

Accusative:

- "мене" → "н'а" (from мн'а)

- "тебе" → "т'а"

- "його" → "го"

- "ї" → "йі"

- "на неї" → "на н'у"

Dative:

- "мені" → "ми"

- "тобі" → "ти"

- "йому" → "му"

6.2. Demonstrative Pronouns

- "цей" → "сись" / "сис'а" / "сесе" / "есе"

- "той" → "тот" / "тота" / "тото" / "ота" / "ото"

- "оцей" → "аццись"

- "той ось" → "аттот" / "антот"

- "отой ось" → "гинтот"

6.3. Interrogative Pronouns

- "хто" → "тко" / "ко"

- "що" → "што" (western, central) / "шчо" / "шо" (some western)

6.4. Indefinite Pronouns with "да-"

Examples:

- "хто-небудь" → "датко"

- "що-небудь" → "дашто"

- "якийсь" → "даякий"

7. Verb Morphology

7.1. Preservation of Archaic Infinitives

Infinitives in -ти and -чи:

Examples:

- "говорити" → "говорити"
- "пекти" → "печи"
- "стригти" → "стричи"
- "бігти" → "бічи"

7.2. [д] → [ж] or [дж] Alternation

Eastern and central: [д] → [ж]

Western and northern: [д] → [дж]

Examples:

- "ходжу" → "хѡжу" (eastern/central) / "ходжу" (western/northern)
- "сиджу" → "сижу" (eastern/central) / "сиджу" (western/northern)

7.3. Assimilative [й] → [в] in Present Tense

In central and western subdialects, 1st person singular and 3rd person plural.

Examples:

- "знаю" → "знаву"
- "думаю" → "думаву"
- "думають" → "думаवут"

7.4. Contracted Forms in 2nd and 3rd Person Singular

Examples:

- "думаєш" → "думаш"
- "думає" → "думат'" / "думат"

7.5. Ending [-т] or [-т'] in 3rd Person

Eastern, northern: [-т]

Central, western: [-т']

Examples:

- "ходить" → "ходит" (eastern) / "ходит'" (central/western)

- "ходять" → "хôд'ат" (eastern) / "хôд'ат'" (central/western)

7.6. Ending [-ме] in 1st Person Plural

Examples:

- "беремо" → "береме"

- "робимо" → "робиме"

- "йдемо" → "идеме"

7.7. Personal Particles in Past Tense (Modified Perfect Forms)

1st person singular: [-им], [-ем], [-м]

2nd person singular: [-ись], [-есь], [-сь]

1st person plural: [-сме], [-сьме]

2nd person plural: [-сте], [-сьте]

Examples:

- "я ходив" → "ходив'им" / "ходив'ем" / "ходилам"

- "ти ходив" → "ходив'ись" / "ходив'есь" / "ходилас'"

- "ми ходили" → "ходилис'ме" / "ходилис'ме"

- "ви ходили" → "ходилисте" / "ходилис'те"

7.8. Conditional Mood with Personal Particles

Examples:

- "я б писав" → "писаўбим" / "писаўбым"

- "я б писала" → "писалабим" / "писалабым"

- "ти б писав" → "писаўбись" / "писаўбысь"

- "ми б писали" → "писалибисме" / "писалибысме"

Central subdialects use "бих":

- "я б дав" → "даўбых"

- "я б дала" → "далабых"

8. Adverbs and Adverbial Expressions

8.1. Place Adverbs

- "тут" → "туй" / "туйкы" / "туйки" / "туйка"

- "ось тут" → "адде" / "аддекы" / "андекы"

- "там ось" → "гинде" / "гиндекы" / "гиндека"

- "надворі" → "вон" / "вонка"

- "усередині" → "удну" / "унну"

8.2. Time Adverbs

- "сьогодні" → "днись" / "ннись" / "нись" / "ниськы"

8.3. Direction Adverbs

- "нагорі, вгору" → "гôрі"

- "внизу, донизу" → "дôлу" / "дôл'ÿ"

- "вгору, нагору" → "идгôрі"

- "вниз" → "удолину"

- "додому" → "дôму" / "дôмÿ(ÿ)"

8.4. Other Adverbs

- "звідки" → "уткÿть" / "уткыть" / "выткыть" / "уткі" / "вотки"

- "знову" → "зас" / "упйат"

- "дуже багато" → "ут'мы"

- "напам'ять" → "наўманиц" / "наўман'ц'і"

- "рачки" → "нацапкы" / "нацапки"

- "весною" → "уяри"

- "близько" → "близ"

- "майже" → "такôй"

- "мабуть" → "майже" / "видаÿ"

- "справді" → "(и)зупраÿд'і"

- "цікаво" → "(из)инôт"

9. Prepositions

9.1. Archaic Forms

- "під" → "пуд"

- "від" → "уд" / "выд"

- "до" → "у"

- "для" → "д'іл'а"

- "до" (direction) → "ид" / "д" (from къ)

- "крізь" → "крôз'і"

- "біля" → "пил'а" / "пила"

- "проти" → "прôту" / "прôтÿ(ÿ)"

- "крім" → "ôкрем"

9.2. Adverbial Prepositions

- "в кінці" → "исхôд'н'а" (e.g., "исхôд'н'а міс'ац'а")

- "вздовж" → "гôрі" (e.g., "гôрі рікôÿ")

10. Particles and Conjunctions

10.1. Affirmative Particles

- "так" → "ай" / "айно" / "йо" (from German)

10.2. Negative Particles

- "ні" → "н'іт" / "н'ет"

10.3. Interrogative Particles

- "чи" → "ци"

10.4. Optative Particles

- "хай" → "най"

10.5. Conjunctions

Connective: "і" → "тай"

Adversative: "але" → "тай" / "ай" / "айно" / "айбо" / "но"

Disjunctive: "або" → "хот'" / "вад'" / "авад'" (from Hungarian)

Subordinate:

- "що" → "ож" / "аж"

- "якщо" → "ож" / "аж" / "абы" / "обы"

- "якби" → "кобы"

- "якщо" → "кид'" (from Slovak)

- "неначе" → "ги(й)"

11. Interjections

11.1. Exclamations

- "ой" → "йôй"

- "цить" → "цыт" / "цÿт" / "чÿт"

11.2. Commands to Livestock

To oxen:

- "соб!" → "ча"

- "цабе!" → "вôгôÿ"

- "назад!" → "гиÿк" / "гиÿкте"

- "стій!" → "вôга"

To horses:

- (го) → "д'ÿ" / "бі" / "гôйта"

- "уліво!" → "бішта" / "віста" / "вішта"

- "управо!" → "гôйта"

- "стій!" → "прр" / "трр"

12. Word Formation

12.1. Suffix [-ан'а] for Attributive Names

Examples:

- "чубата курка" → "кôÿпан'а"

- "довгий жіночий одяг" → "дôÿган'а"

- "язиката жінка" → "языкан'а"

Women named after husbands:

Examples:

- "дружина Петра" → "Петран'а"

- "дружина Сливки" → "Сливкан'а"

- "дружина Васильця" → "Васил'ц'ан'а"

12.2. Hungarian Loanword Suffixes

-ош (profession, attribute):

- "учасник вертепу" → "бетлегемош"

- "обідранець" → "цур'ош"

-аш (agent):

- "копальник" → "копаш"

- "скрипаль" → "гусьл'аш"

12.3. Prefix (в)у- Instead of ви-

Examples:

- "винести" → "унести"

- "вибрати" → "вубрати"

13. Syntax

13.1. Coordinating Conjunctions in Concessive Constructions

Example:

- "будеш його сто разів просити і не піде" → "будешж го сто рас просити и ни
→ пўде"

13.2. Expression of Possession with Dative Pronouns

Examples:

- "мій батько" → "отиц' ми"

- "твоя мати" → "мати ти"

- "наш дід" → "д'ідик нам"

- "нашого сусіда" → "сус'ідүў нам"

13.3. Accusative with Infinitive

Examples:

- "чув, як він сміявся" → "чуў го с'міятис'а"

- "бачив його сидячого" → "відіў го сид'іти"

13.4. Preposition "на" for Purpose/Destination

Examples:

- "іду по воду" → "иду на воду"

- "іду по гриби" → "иду на грибы"

- "іду за цукром" → "иду на цукор"

- "іду по дрова" → "иду на дрова"

13.5. Comparative Constructions with "ги"

Example:

- "вищий, ніж батько" → "май високий ги ўтиц' му"

TRANSCARPATHIAN-UKRAINIAN DICTIONARY

Also consider the following Ukrainian-Transcarpathian dictionary for vocabulary

→ substitutions:

{dictionary}

TRANSLATION EXAMPLES

Ukrainian: Я йду додому.

Transcarpathian: Иду дôму.

Ukrainian: Він пішов по воду.

Transcarpathian: Він пішов на воду.

Ukrainian: Моя мама каже.

Transcarpathian: Мамка ми каже.

Ukrainian: Ми бачили його сидячого.

Transcarpathian: Віділисме го сид'іти.

Ukrainian: Я ходив учора.

Transcarpathian: Ходив'им вчєра.

Ukrainian: Вони не підуть.

Transcarpathian: Вни ни пўдут'.

Ukrainian: Більший за батька.

Transcarpathian: Май великий ги ўтиц'.

Ukrainian: Чи ти знаєш?

Transcarpathian: Ци ты знаш?

Ukrainian: Хата велика.

Transcarpathian: Хыжа великайє.

Ukrainian: Так, я розумію.

Transcarpathian: Айно, розумію.

IMPORTANT:

- Preserve the original meaning of the sentence
- Use characteristic Transcarpathian lexical and phonetic features
- Apply rules naturally, don't overdo it
- Return ONLY the translation, without explanations
- Return each translated sentence on a new line
- If multiple rules could apply to the same word, use this priority:
 1. dictionary entries,
 2. translation examples,
 3. general rules.