

ЗВІТ

За результатами роботи над проєктом з дисципліни

"Проєкт з удосконалення аналізу даних у інформаційній системі"

1. Інформація про студента

ПІБ: *Коваль Денис Петрович*

Група: *III-42*

Тема проєкту: *Система для автоматичної нормалізації суржиків та діалектних форм української мови*

Науковий керівник: *[Виклюк Ярослав Ігорович, Сивоконь Олексій Олегович]*

2. Результати роботи над проєктом

Отже, головною задачею було розробити систему, яка буде перекладати текст з діалекту/суржиків на українську. І як завжди в ML - найважчою частиною роботи стали дані, тому виникла окрема величезна підзадача - сформувати власний корпус даних для тренування моделей.

Я зібрав датасет для чотирьох мовних форм - гуцульського, бойківського, закарпатського діалектів і суржиків: 125 тисяч тренувальних прикладів, 13 тисяч валідаційних, тестовий повністю вручну анотований по 50 прикладів на кожну мовну форму. Для гуцульського додатково є 10 тисяч ручних паралельних пар у тренувальній вибірці. Для суржиків застосував два підходи - програмну генерацію на rymorphu2 без LLM і додаткову через Mistral Small 24B, для решти мовних форм - тільки LLM, по 30 тисяч на кожну.

Навчав дві моделі: MatayLM (Gemma-3-4B, QLoRA) і UMT5-base з повним файнтюнінгом, і порівняв їх між собою та з GPT-4o, Gemini і Mistral zero-shot через власний harness на lmms-eval. На суржиків обидві навчені моделі перебили всі zero-shot LLM: UMT5 chrF++ 93.58, MatayLM - 91.22, GPT-4o без навчання - 88.97. На гуцульському MatayLM набрала chrF++ 74.02 проти 64.89 у GPT-4o. Бойківський поки що слабший - тут zero-shot моделі попереду. Закарпатський найважчий в обох моделей через велику мовну відстань і мало даних. MatayLM навчалась з маленьким LoRA адаптером і по графіках ще не до кінця збіглась - зараз експериментую з більшим, метрики можуть покращитись.

3. Рекомендації комісії (7 семестр)

Комісія надала рекомендації розглянути, наскільки реально реалізувати всі 12+ діалектів, які я планував. Після детального дослідження я визначив, що найкраще сфокусуватись тільки на 4 мовних формах: гуцульській, бойківській, закарпатській та суржиків. Загалом рекомендацій по логіці більше не було, тільки хіба по деталях формату записки.

4. Перелік фактично внесених змін

1) Зібрано великий корпус для 4 мовних форм, завдяки декільком підходам до створення синтетичних пар речень, з використанням діалектних словників, які було спаршено з відкритих джерел та граматичних правилах кожної мовної форми.

2) Навчено дві моделі: MatayLM на базі Gemma-3-4B через QLoRA з Unsloth та UMT5-base з повним фінтунінгом. Для MatayLM для тестування було використано маленький LoRA адаптер ($r=4$), щоб точно вміститись на відеокарту. По графіках навчання видно, що модель ще недонавчена - зараз проводяться експерименти з більшими адаптерами, тому фінальні метрики ще можуть покращитись.

3) Для порівняння з великими моделями написано окремий harness через lmms-eval і протестовано GPT-4o, Gemini і Mistral zero-shot на тих самих задачах через OpenRouter.

4) Отримано результати по всіх мовних формах. На суржикі і гуцульському обидві навчені моделі перебили всі zero-shot LLM - UMT5 chrF++ 93.58, MatayLM 91.22 проти GPT-4o 88.97 на суржикі, MatayLM 74.02 проти 64.89 у GPT-4o на гуцульському. На бойківському zero-shot моделі поки що попереду через брак ручної розмітки. Найважчим виявився закарпатський - chrF++ 20-27 у обох моделей проти 65.39 у GPT-4o через найбільшу мовну відстань і найменше даних.

5) Реалізовано демо-застосунок з підходящим дизайном під назвою «Лексикон» - назва відсилає до радянського інструменту нормалізації російської мови, який витісняв українську. Додано розпізнавання мовлення як додатковий функціонал через SpeechBrain m-ctc-t-large - відкриту модель, яка за відгуками непогано працює з українською і суржиком. Навчати її не є в рамках цього проекту, тому взята як є - працює прийнятно, але далека від ідеалу.

6) Проведено рефакторинг коду та приведено репозиторій у кращий стан - структура проекту стала зрозумілішою, а пайплайн від генерації даних до навчання і оцінки відтворюваним.